

1 本研究要回答什么问题？

我们真正想知道什么。 在这个任务中，被试一边观察刺激，一边根据反馈寻找正确的分类规则。我们真正想知道的是：在每一个试次，被试更相信哪些规则？收到新的反馈以后，他对这些规则的相信程度怎样改变？这里所说的“规则信念”，就是被试在当时对每一条候选规则的相信程度。模型的目的是把已经发生的选择拟合得越像越好，而是用一个尽量简单的过程，描述被试怎样形成、保留和改变这些规则信念。

模型怎样回答这个问题。 模型假设，被试不会从一开始就只认定一条规则，而是会同时考虑若干可能的规则。每个试次开始时，模型根据过去看到的刺激、做出的选择和得到的反馈，估计被试当前更相信哪些规则；这些规则共同决定当前选择。选择完成后，模型再利用反馈更新规则信念，进入下一个试次。整个过程可以简单地写成：

过去的经验 → 当前对各条规则的相信程度 → 当前选择 → 反馈 → 下一试次的规则信念。

规则信念本身看不见，所以仅仅能够解释选择还不够。我们还要检查它能否解释被试选择时的反应时，以及被试亲口说出的规则。

每一种数据分别用来做什么。 不同数据在研究中承担不同任务：

1. **刺激和正确类别**由实验任务给定，是模型每个试次接收到的外部信息。独立的知觉任务用于估计被试看刺激时有多大的知觉噪声。
2. **选择**是核心模型主要学习的数据。原则上使用被试的全部试次，而不是只用最初64个试次估计一个固定基线，再让模型独立生成后面的行为。
3. **反馈**告诉被试刚才的选择是否正确，因此它是更新规则信念的依据。模拟实验时，模型先产生选择，再由该选择和正确类别得到反馈。反馈可以被模型重现，但不是需要一个单独拟合的结果，因为它已经由选择和正确答案决定。
4. **反应时和口头规则报告**原则上不用于估计核心学习模型，而是用来检验模型。比如，如果模型认为某个试次被试在几条规则之间很犹豫，那么被试是否真的反应更慢？如果模型认为被试主要相信某条规则，那么被试口头说出的规则是否也更接近它？

什么放进拟合目标，什么不放。 核心拟合只问一个问题：根据此前的经历，模型给被试实际做出的选择多大的概率？我们不把选择、反应时和口头报告按照人为设定的权重混合成一个总分。核心学习模型拟合并固定以后，可以再加两个尽量简单的“测量通道”，分别把模型的不确定性对应到反应时，把模型的规则信念对应到口头报告。口头报告不需要由模型逐字生成，而是先转换成候选规则或规则区域上的分布，再与模型的规则信念比较。如果反应时和口头报告也参与了核心参数优化，就不能再把它们称为外部检验。

模型应该多复杂。 我们的原则是从最简单、最容易解释的模型开始。基础模型只包含候选规则、由独立任务确定的知觉噪声、一个简单的记忆或遗忘过程，以及一个相对稳定的“从规则信念到选择”的转换过程。之后一次只增加一种机制，例如双通道记忆、有限的规则容量，或者随时间变化的选择波动。一个复杂机制只有在以下情况下才值得保留：它能稳定改善对新试次或新被试选择的预测；它的参数能够从模拟数据中重新找

回来；而且它还能对反应时或口头报告给出额外的、事先可以说明的预测。否则，我们应当选择更简单的模型。

如果不同机制看起来都能解释选择，怎么办。 这是本研究必须正面处理的问题。例如，记忆变差、同时考虑的规则变少，或者选择过程变得更随机，都可能造成相似的错误选择。我们的做法不是只比较谁对选择拟合得更好，而是比较它们对反应时和口头报告的不同预测：记忆衰减应使选择和口头报告都更依赖最近的反馈；规则容量受限可能导致被试在负反馈后突然换一条口头规则；选择过程暂时变得更随机，则可能表现为选择更分散、反应更慢，但口头说出的规则相对稳定。如果现有数据仍然不能区分两个机制，我们就明确承认它们在本实验中无法区分，并选择较简单的模型作为工作模型，而不声称其中某一个一定是真实的心理机制。

最后怎样判断模型是否成功。 一个令人信服的模型至少要做到四点：第一，按真实的试次顺序预测被试的选择；第二，由选择估计出的规则信念能够进一步预测反应时和口头报告；第三，模型和参数能够通过模拟恢复检验；第四，模型能够在固定的实验刺激下重新生成选择、反应时、口头报告以及由选择决定的反馈，并重现实验数据的主要特征。即使满足这些要求，我们的结论仍然应保持克制：模型支持的是一种与多种行为证据相符的最简解释，而不是对被试真实心理过程的直接读取。

与下文 C1 模型的关系。 下文保留了此前 C1 模型的完整设计，方便我们逐项检查和比较。现阶段应把 C1 看作一个候选模型，而不是已经确定的最终模型。尤其是随试次变化的 readout concentration，只有在它比稳定的选择过程、记忆变化或规则容量限制提供了可以恢复、而且能够被反应时和口头报告支持的额外解释时，才有理由保留。

2 模型总体思路

下文首先记录条件 1 此前冻结的 C1 工作模型。该模型旨在解释被试如何在任务给定的候选规则之间积累证据，并生成逐试次的类别选择。模型拟合使用物理刺激、被试选择和反馈；独立知觉任务用于确定被试特异的知觉噪声；口头规则报告不参与参数选择，只用于拟合后的外部验证。在本轮重构完成前，C1 的角色是可审计的候选模型，而不是预先指定的最终唯一机制。

C1 延续原模型的基本信息流。物理刺激首先转化为带噪声的内部知觉表征；每条候选规则根据该表征给出类别预测；反馈通过贝叶斯似然和双通道记忆更新完整假设空间上的信念；假设特异的动态 beta 调节每条规则的类别边界锐度；最后，连续随机 readout 将当前假设信念映射为外显选择。简写为

$$\mathbf{x}_t \longrightarrow \tilde{\mathbf{x}}_t \longrightarrow \{q_{t,h}(i)\}_{h \in \mathcal{H}} \longrightarrow \pi_t^- \xrightarrow{\rho_{s,t}} P_t(C_i) \longrightarrow c_t, r_t \longrightarrow \pi_t^+, \beta_{t+1,h}. \quad (1)$$

这里唯一随学习时程持续波动的新增量是 readout concentration $\rho_{s,t}$ 。它改变不同候选规则对当前选择的相对影响，但不新增、删除或替换规则。条件 1 中的正式模型始终在全部 38 条带标签规则上维持分布式信念。

3 任务定义的几何假设空间

候选规则。 每个假设 $h \in \mathcal{H}$ 将四维单位超立方体 $[0, 1]^4$ 划分为两个带类别标签的区域：

$$R_{h,i} = \{\mathbf{x} \in [0, 1]^4 : A_{h,i}\mathbf{x} \leq \mathbf{b}_{h,i}\}, \quad i \in \{1, 2\}. \quad (2)$$

条件 1 包含 19 个基础几何划分：4 个单维轴向边界 $x_i = 0.5$ 、6 个二维等值边界 $x_i = x_j$ 、6 个二维求和边界 $x_i + x_j = 1$ ，以及 3 个四维混合边界 $x_i + x_j = x_k + x_l$ 。实验配置对每个几何划分同时保留原始和反向类别标签，因此

$$\mathcal{H} = \mathcal{H}^{\text{base}} \times \{(1, 2), (2, 1)\}, \quad |\mathcal{H}| = 19 \times 2 = 38. \quad (3)$$

这里的 38 指带类别标签的假设；标签反转共享同一几何边界，但交换两个区域及其类别原型的标签。

原型与规则内类别概率。 每个 $R_{h,i}$ 对应一个原型 $\boldsymbol{\mu}_{h,i} \in [0, 1]^4$ 。轴向规则在诊断维度上取 0.25/0.75、其余维度取 0.5；等值规则在两个相关维度上采用 (1/3, 2/3) 与 (2/3, 1/3) 的镜像原型；求和规则在两个相关维度上共同取 1/3 或 2/3；四维混合规则使等式两侧的维度采用相反的 1/3 与 2/3 排列。所有原型均需通过所属区域约束检查。

给定内部知觉刺激 $\tilde{\mathbf{x}}_t$ ，其到假设 h 下类别 i 原型的距离为

$$d_{t,h,i} = \|\tilde{\mathbf{x}}_t - \boldsymbol{\mu}_{h,i}\|_2. \quad (4)$$

规则 h 使用距离 softmax 产生类别概率：

$$q_{t,h}(i) = P(C_i | \tilde{\mathbf{x}}_t, h, \beta_{t,h}) = \frac{\exp[-\beta_{t,h}d_{t,h,i}]}{\sum_{j=1}^2 \exp[-\beta_{t,h}d_{t,h,j}]}. \quad (5)$$

$\beta_{t,h}$ 越大，假设 h 的类别预测越集中于最近原型； $\beta_{t,h}$ 越小，其类别预测越接近均匀。

4 贝叶斯更新

反馈前信念。 模型在完整假设空间上维持概率分布。第一试次使用均匀先验，

$$\pi_1^-(h) = \frac{1}{|\mathcal{H}|}, \quad h \in \mathcal{H}, \quad (6)$$

之后令当前反馈前信念继承上一试次反馈后信念：

$$\pi_t^-(h) = \pi_{t-1}^+(h), \quad t > 1. \quad (7)$$

因此， π_t^- 只包含截至试次 $t-1$ 的信息，可用于预测试次 t 的选择； π_t^+ 已吸收试次 t 的反馈，只能解释反馈后的信念或预测下一试次。

反馈事件与似然。 令 $c_t \in \{1, 2\}$ 为被试选择， $r_t \in \{0, 1\}$ 为确定性反馈。与反馈相容的真实类别集合为

$$\mathcal{Y}_t = \begin{cases} \{c_t\}, & r_t = 1, \\ \{1, 2\} \setminus \{c_t\}, & r_t = 0. \end{cases} \quad (8)$$

假设 h 对当前反馈事件的支持为

$$L_t(h) = P(r_t | \tilde{\mathbf{x}}_t, c_t, h, \beta_{t,h}) = \sum_{i \in \mathcal{Y}_t} q_{t,h}(i). \quad (9)$$

数值实现将小于 10^{-15} 的 $L_t(h)$ 提升至 10^{-15} ，以避免对数运算溢出。若不考虑记忆差异，规范性的一步更新为

$$\pi_t^+(h) = \frac{\pi_t^-(h)L_t(h)}{\sum_{u \in \mathcal{H}} \pi_t^-(u)L_t(u)}. \quad (10)$$

正式 C1 使用下一节的双通道记忆实现跨试次证据积累，但仍保留“反馈前信念乘以当前似然”的因果骨架。

5 有限理性与动态读出模块

被试特异的知觉输入。 被试真正用于分类的刺激表征写为

$$\tilde{\mathbf{x}}_{s,t} = \text{clip}(\mathbf{x}_{s,t} + \epsilon_{s,t}, 0, 1), \quad (11)$$

其中截断逐维执行。知觉参数来自独立于类别学习的 Task 1b 测量，并按照每名被试在 Task 2 中实际使用的四个 feature 顺序重排。被试 101--124、201--224 和 301--324 使用阈限半宽

$$\epsilon_{s,t,d} \sim \text{Uniform}(-a_{s,d}, a_{s,d}), \quad (12)$$

其中 $a_{s,d}$ 来自 Task1b_errorsummary_72.csv 的 threshold_mean_mean 绝对值。被试 125--132、225--232、325--335 和 401--424 使用

$$\epsilon_{s,t,d} \sim \mathcal{N}(\mu_{s,d}, \sigma_{s,d}^2), \quad (13)$$

其他未列入上述预设集合的被试也默认使用正态误差。 $\mu_{s,d}$ 和 $\sigma_{s,d}$ 来自 Task1b_errorsummary_24.csv 的 error_mean 与 error_std。每条反事实轨迹在每个试次重新抽样知觉误差，因此相同物理刺激不必产生完全相同的内部输入。

双通道证据记忆。 模型为每条假设同时保存近期衰减证据 $F_t(h)$ 和长期累积证据 $S_t(h)$ 。在当前反馈进入之前，两条轨道先与 π_t^- 对齐，同时保留上一试次两条轨道之间的差异。令

$$\Delta_{t,h} = S_{t-1}(h) - F_{t-1}(h), \quad (14)$$

并取一个对所有假设相同、归一化后会抵消的常数 C_t ，则

$$F_{t-}(h) = \log \pi_t^-(h) + C_t - w_0 \Delta_{t,h}, \quad (15)$$

$$S_{t-}(h) = \log \pi_t^-(h) + C_t + (1 - w_0) \Delta_{t,h}. \quad (16)$$

由此

$$w_0 S_{t-}(h) + (1 - w_0) F_{t-}(h) = \log \pi_t^-(h) + C_t,$$

所以同步不会改变反馈前信念，也不会抹去长短期轨道的相对差异。第一试次令 $F_{1-}(h) = S_{1-}(h) = \log \pi_1^-(h)$ 。

当前反馈随后写入两条轨道：

$$F_t(h) = \gamma F_{t-}(h) + \log L_t(h), \quad (17)$$

$$S_t(h) = S_{t-}(h) + \log L_t(h). \quad (18)$$

两条轨道按

$$\ell_t(h) = w_0 S_t(h) + (1 - w_0) F_t(h) \quad (19)$$

合并，并在完整假设空间上归一化：

$$\pi_t^+(h) = \frac{\exp[\ell_t(h)]}{\sum_{u \in \mathcal{H}} \exp[\ell_t(u)]}. \quad (20)$$

正式 C1 固定 $\gamma = 0.55$ 、 $w_0 = 0.10$ 。因此，模型主要读取近期轨道，同时保留少量不会指数衰减的长期证据。

假设特异的动态 beta。 所有假设初始化为

$$\beta_{1,h} = \beta_0 = 5, \quad \beta_{\min} = 0.1, \quad \beta_{\max} = 25. \quad (21)$$

为判断当前反馈对假设 h 是正证据还是负证据，先令 $s_{t,h} = L_t(h)$ 。二分类反馈事件在均匀预测下的机会概率为 $1/2$ ，所以标准化反馈一致性为

$$\xi_{t,h} = 2 \left[s_{t,h} - \frac{1}{2} \right] \in [-1, 1]. \quad (22)$$

当前反馈出现后，beta 更新为

$$\begin{aligned} \beta_{t+1,h} = \text{clip} \left[\beta_{t,h} + \eta_+ \max(\xi_{t,h}, 0) \frac{\beta_{\max} - \beta_{t,h}}{\beta_{\max}} \right. \\ \left. - \eta_- \max(-\xi_{t,h}, 0) \beta_{t,h}, \beta_{\min}, \beta_{\max} \right], \end{aligned} \quad (23)$$

其中 $\eta_+ = 0.50$ 、 $\eta_- = 0.15$ 。正证据使该规则的类别映射逐渐锐化，且接近上界时增量减小；负证据使其类别映射按当前 beta 的比例变平。式 23 必须在使用 $\beta_{t,h}$ 计算当前选择和似然之后执行，更新后的 $\beta_{t+1,h}$ 只从下一试次开始生效。

C1 连续随机 readout。 内部信念 π_t^- 不直接按线性平均映射为选择。模型用正的 concentration $\rho_{s,t}$ 重新分配每条假设对当前选择的权重：

$$\omega_{s,t,h} = \frac{[\pi_{s,t}^-(h)]^{\rho_{s,t}}}{\sum_{u \in \mathcal{H}} [\pi_{s,t}^-(u)]^{\rho_{s,t}}}, \quad (24)$$

$$P_{s,t}(C_i) = \sum_{h \in \mathcal{H}} \omega_{s,t,h} q_{s,t,h}(i). \quad (25)$$

当 $\rho_{s,t} = 1$ 时，式 25 是标准 posterior expectation；当 $\rho_{s,t} > 1$ 时，高 posterior 假设更支配选择；当 $0 < \rho_{s,t} < 1$ 时，权重分布被压平，较弱的竞争规则也更容易影响选择。例如，当两个规则的信念为 $(0.8, 0.2)$ 时， $\rho = 0.5, 1, 2$ 分别产生约 $(0.667, 0.333)$ 、 $(0.800, 0.200)$ 和 $(0.941, 0.059)$ 的 readout 权重。

正式 C1 不预先指定若干离散的“混乱”“陡降”或“恢复”状态，而令 log concentration 服从持续的 AR(1) 过程。对被试 s 的一条反事实重复轨迹 r ，

$$\log \rho_{s,t}^{(r)} = a_s^{(r)} + u_{s,t}^{(r)}, \quad (26)$$

$$u_{s,t}^{(r)} = 0.95u_{s,t-1}^{(r)} + \sigma_s^{(r)}\xi_{s,t}^{(r)}, \quad \xi_{s,t}^{(r)} \sim \mathcal{N}(0, 1), \quad (27)$$

初始 $u_{s,0}^{(r)} = 0$ 。被试间异质性由同一共享分布上的随机效应表示：

$$a_s^{(r)} \sim \mathcal{N}(\log 0.50, 0.35^2), \quad (28)$$

$$\sigma_s^{(r)} = 0.20 \exp(0.50z_{\sigma,s}^{(r)}), \quad z_{\sigma,s}^{(r)} \sim \mathcal{N}(0, 1). \quad (29)$$

a_s 控制被试通常以多大集中程度读取当前信念， σ_s 控制其 readout 容易出现多大幅度的持续波动。二者在一条轨迹内保持稳定，但其后验不确定性由多个粒子表示；预测边界以后，每条自主轨迹从该被试的加权粒子分布抽取一个可能状态。数值实现将 $\rho_{s,t}$ 截断到 $[0.05, 20]$ ，只用于防止指数权重的浮点退化。

$\rho_{s,t}$ 不直接修改 likelihood、memory、beta 或 posterior。它只有在候选规则对当前刺激给出不同类别预测时才会明显改变行为；如果高质量规则意见一致， $\rho_{s,t}$ 的变化几乎不影响选择。不过，在自主生成中，readout 会改变实际抽到的选择，而选择又决定实验反馈，后续学习轨迹因此可以通过“选择--反馈--更新”闭环间接分叉。C1 能由连续波动产生渐变、陡升、陡降与恢复，但这些可观察形态不是模型预先编码的离散认知状态。

6 完整逐试次算法

每个粒子在第一试次将 π_1^- 初始化为 38 条规则上的均匀分布，将 $F_{1-} = S_{1-} = \log \pi_1^-$ 、 $\beta_{1,h} = 5$ 和 $u_{s,0} = 0$ ，并从式 29 抽取其被试层 readout 特征。随后对 $t = 1, \dots, T$ 严格按以下顺序执行：

1. 由上一试次的 $u_{s,t-1}$ 推进式 27，得到当前 $\rho_{s,t}$ ；该步不读取当前选择或反馈；
2. 读取物理刺激 $\mathbf{x}_{s,t}$ ，按被试特异误差分布抽样并截断，得到 $\tilde{\mathbf{x}}_{s,t}$ ；
3. 使用反馈前信念 $\pi_{s,t}^-$ 、当前 pre-feedback $\beta_{s,t,h}$ 和 $\tilde{\mathbf{x}}_{s,t}$ ，按式 5 计算 38 条规则类别概率；
4. 按式 24--25 计算当前选择分布。真实前缀滤波时，用该分布评价已观察到的选择；自主后缀生成时，从该分布抽取模拟选择；
5. 根据当前选择和任务正确类别生成反馈，并按式 8--9 计算每条规则的反馈似然；
6. 按式 16--20 更新两条记忆轨道和反馈后信念 $\pi_{s,t}^+$ ；
7. 保存本试次使用的 $\beta_{s,t,h}$ ，再按式 23 生成下一试次的 $\beta_{s,t+1,h}$ ，并令 $\pi_{s,t+1}^- = \pi_{s,t}^+$ 。

这一顺序保证试次 t 的选择只能使用截至 $t-1$ 的学习状态。同一试次的反馈不能进入产生该选择的 π_t^- 、 $\beta_{t,h}$ 或 $\rho_{s,t}$ 。

7 模型拟合与评价

粒子滤波的作用。 知觉噪声、readout 创新以及被试层 readout 特征的不确定性，使相同参数设定能够产生多条潜在轨迹。模型用 R 个粒子近似同一被试在预测边界处的潜在状态分布。试次 t 选择发生前的边际预测为

$$\bar{P}_{s,t}(C_i) = \sum_{r=1}^R w_{s,t-1}^{(r)} P_{s,t}^{(r)}(C_i), \quad (30)$$

其中 $w_{s,t-1}^{(r)}$ 只以截至 $t-1$ 的行为为条件。观察到选择 $c_{s,t}$ 后，粒子权重才更新：

$$\tilde{w}_{s,t}^{(r)} = w_{s,t-1}^{(r)} P_{s,t}^{(r)}(C_{c_{s,t}}), \quad (31)$$

$$w_{s,t}^{(r)} = \frac{\tilde{w}_{s,t}^{(r)}}{\sum_{r'=1}^R \tilde{w}_{s,t}^{(r')}}. \quad (32)$$

有效样本量

$$\text{ESS}_{s,t} = \frac{1}{\sum_{r=1}^R [w_{s,t}^{(r)}]^2} \quad (33)$$

低于 $0.5R$ 时进行系统重采样。粒子滤波只是对潜在状态和参数不确定性的数值积分；粒子数不是被试拥有的策略数，重采样也不是心理状态转移。

一步预测评分。 因果选择预测使用多类别 Brier score

$$\mathcal{L}_{\text{Brier}} = \frac{1}{|\mathcal{T}_s|} \sum_{t \in \mathcal{T}_s} \sum_{i=1}^2 [\bar{P}_{s,t}(C_i) - I(c_{s,t} = i)]^2 \quad (34)$$

和负对数似然

$$\mathcal{L}_{\text{NLL}} = -\frac{1}{|\mathcal{T}_s|} \sum_{t \in \mathcal{T}_s} \log \bar{P}_{s,t}(C_{c_{s,t}}). \quad (35)$$

二者都使用选择发生前的边际概率，不能用吸收了当前选择后的粒子权重反向评价同一选择。

自主 posterior-predictive 轨迹。 同一名被试实际观察到的学习轨迹被视为随机生成过程的一次实现，而不是模型必须逐点复刻的确定性路径。即使稳定的个体特征、物理刺激顺序和正确类别顺序都相同，知觉抽样、外显选择及其诱发的反馈历史仍可能不同，早期偶然差异也会通过后续更新逐渐放大。令 $\mathbf{y}_{s,1:T}$ 表示任务预先规定的正确类别序列， Ω_s 表示被试的稳定参数与预测边界处潜在状态。模型检验的是，真实轨迹能否作为下式分布中的非边缘实现被生成。落入模型校准后的 95% 预测区域表示模型能够生成这种行为；它不等于恢复了真实的逐试次潜变量，也不证明该机制是唯一解释。

$$\tilde{\mathbf{c}}_{s,1:T}^{(r)} \sim p_{\mathcal{M}}(\mathbf{c}_{1:T} \mid \mathbf{x}_{s,1:T}, \mathbf{y}_{s,1:T}, \Omega_s), \quad (36)$$

长时程评价以第一实验块结束为预测边界。边界以前的真实选择与反馈只用于形成粒子权重和潜在状态分布；边界以后固定被试实际经历的物理刺激与正确类别顺序，但知觉、选择和由选择产生的反馈全部由模型自主生成，不再读取任何未来真实选择或真实反馈。主运行使用 256 个滤波粒子，并从边界处分布生成 1024 条独立后缀；独立随机种子复核使用 128 个粒子和 512 条后缀。

轨迹位置和离散度首先用长度 12、且不跨实验块的滚动正确率计算经验 CRPS。若第 j 个窗口的真实正确率为 y_j ，第 r 条自主轨迹为 $\hat{y}_{j,r}$ ，则

$$\text{CRPS}_j = \frac{1}{R} \sum_{r=1}^R |\hat{y}_{j,r} - y_j| - \frac{1}{2R^2} \sum_{r=1}^R \sum_{r'=1}^R |\hat{y}_{j,r} - \hat{y}_{j,r'}|. \quad (37)$$

最终 CRPS 对窗口取平均；同时报告点状 95% 区间宽度，但点状区间不能代替整条轨迹的联合检验。

联合轨迹检验使用 15 个预先定义的描述量：总体、开头和末尾正确率，正确率斜率，相邻窗口最大上升和最大下降，趋势方向反转数，突降事件数及最长持续时间，最长连续错误，低正确率窗口最长连续段，优势反应比例，选择熵，反应切换率和错误后保持率。模型生成轨迹依次作为伪观测，形成最大稳健标准化偏差及滚动曲线同时偏差的模型内 95% 阈值。真实轨迹只有同时通过摘要量和曲线检验才计为联合通过；因此通过人数可直接与“模型自身为真”时的通过人数分布比较。

阶段形态检验。 “混乱”“陡升”“陡降”“渐变”“恢复”和“稳定高水平”只作为可观察轨迹描述，不作为潜在状态标签。每个实验块分别按 8、12 和 16 试次切成不重叠窗口；12 试次为主尺度，其余尺度用于检验窗口依赖性。在每个尺度计算接近随机水平窗口占比、最长混乱段占比、稳定高水平窗口占比、首次进入高水平的相对时间、陡升数、陡降数、陡降后恢复数、连续渐变段数、方向反转数和经历的阶段种类数，共得到 30 个阶段描述量。相邻窗口变化至少 0.25 才定义为陡升或陡降；渐变要求至少两个连续同方向的小变化且累计变化至少 0.25。30 维联合检验同样由模型伪观测校准，而不是事后寻找最匹配的若干轨迹。

开发与保留队列。 8 名开发被试 (103、105、111、112、117、118、127、131) 只用于冻结共享 C1 设定和覆盖--锐度门槛；其余 24 名条件 1 被试构成保留队列，不再选择参数。开发门槛同时要求群体通过人数与模型自身分布相容、逐被试异常不形成系统性 FDR 失败、曲线 CRPS 可接受，且点状 95% 区间宽度中位数不超过 0.50。保留队列上的主结果与独立种子复核均使用完全冻结的模型。

个体异质性的增量审计。 C1 的正式信息流在上述步骤中已经完整定义。为了检验被试差异是否必须进入 readout 以前的学习过程，我们另外建立一个不参与 C1 选择的候选审计：每次只改变一个认知环节，同时在固定 readout ($\rho_{s,t} = 0.50$) 和 C1 动态 readout 下运行。前者问“更深层的异质性能否替代动态 readout”，后者问“它能否在 C1 之上提供增量”。四个候选家族及其冻结网格为

$$F: \kappa \in \{0.40, 0.70, 1.00, 1.40, 2.00\}, \quad \log L_t^{(\kappa)}(h) = \kappa \log L_t(h), \quad (38)$$

$$M: \gamma \in \{0.20, 0.40, 0.55, 0.70, 0.90\}, \quad (39)$$

$$H: K \in \{3, 5, 10, 38\}, \quad (40)$$

$$P: \zeta \in \{0, 0.50, 1.00, 1.50, 2.00\}, \quad \eta_+^{(\zeta)} = 0.50\zeta, \quad \eta_-^{(\zeta)} = 0.15\zeta. \quad (41)$$

F 改变一次反馈写入两条记忆轨道的证据强度； M 改变近期轨道保留旧证据的比例； P 同比例改变正、负反馈推动 beta 的速度。各家族的参考值分别为 $\kappa = 1$ 、 $\gamma = 0.55$ 和 $\zeta = 1$ 。

H 是“有限活跃假设集加固定反馈驱动替换”的整体候选，而不是纯容量参数。每个粒子只让 K 条规则具有非零质量。若 $K < 38$ ，试次 t 开始时依据上一试次反馈抽取

$$Z_{s,t} \sim \text{Bernoulli}[\theta(1 - r_{s,t-1})], \quad \theta = 0.75. \quad (42)$$

若 $Z_{s,t} = 1$ ，删除当前活跃集合中 posterior 最低的一条规则，并从非活跃规则中均匀抽入一条；新规则获得 $1/K$ 的质量，幸存规则按原 posterior 比例分享其余质量。新规则的 beta 重新置为 β_0 。 $K = 38$ 是完整假设空间参考，此时 $\theta = 0$ 、不发生替换。因而，若 H 有预测优势，最多能归因于“受限且可替换的假设集”这一设计包，不能单独归因于容量。为进一步检验动态策略是否还需要被试特异化，开发集另在 $K = 3$ 下比较 $\theta \in \{0, 0.25, 0.50, 0.75, 1\}$ ；该 S 审计只改变交换敏感性。

候选值没有用保留集后缀选择。令 $e_{s,j}$ 为被试 s 在预测边界以前、候选 j 的因果选择 log predictive density, q_j 为开发队列的群体候选先验。有限混合的责任度和带单位 Dirichlet 平滑的先验更新为

$$\lambda_{s,j} = \frac{q_j \exp(e_{s,j})}{\sum_{v=1}^J q_v \exp(e_{s,v})}, \quad (43)$$

$$q_j = \frac{\sum_{s=1}^{S_{\text{dev}}} \lambda_{s,j} + 1}{S_{\text{dev}} + J}. \quad (44)$$

式 43--44 在 8 名开发被试上迭代至收敛；所得 q_j 随后冻结。保留被试只用自己的第一实验块更新 $\lambda_{s,j}$ ；只有一个实验块的被试使用前四分之一。每条自主后缀先从 $\text{Categorical}(\lambda_s)$ 抽取一次候选，并在整条反事实轨迹中保持不变。因此，候选混合表达的是“哪种稳定设定可能生成该被试”，不是每个试次在 F/M/H/P 机制之间跳转，也不会读取未来选择或反馈。

家族审计分别在 F、M、H 和 P 内拟合有限混合；全局预测候选库则保留一个共同基础候选，加上四个家族的全部非参考候选，共 16 个候选。全局库只检验预测等价性，不输出心理机制标签。开发筛查使用 64 个粒子和每个候选 128 条后缀；冻结保留集使用 64 个粒子和 256 条后缀；预先选定的 H 高精度复核使用 128 个粒子和 512 条后缀。这些辅助运行不替代正式 C1 的 256 粒子、1024 后缀主结果。

增量评价同时报告曲线 CRPS、15 维轨迹摘要偏差、联合校准统计量、联合 95% 覆盖人数和点状区间宽度。效应定义为“候选混合减参考”，以被试为配对单位进行 20,000 次 sign-flip 检验，并在同一审计内用 Benjamini--Hochberg 控制 FDR；覆盖差异只使用两模型结论不一致的被试作精确二项检验。模型恢复另在真实刺激和正确类别顺序上由已知候选生成新行为，再用相同程序反推候选；它回答候选值或家族在模型为真时能否被认回。最后，冻结的选择前缀权重还接受三项未参与选择的外部约束：后缀逐试次 NLL、被试内 log(RT) 与选择惊讶度的 Spearman 相关，以及选择条件化假设分布与口头报告中心的相似度。

8 当前结果与解释边界

冻结 C1 在 24 名保留被试中有 23/24 人通过联合轨迹检验。模型自身期望通过 22.96 人，95% 范围为 [21, 24]，群体下尾校准 $p = 0.659$ ；滚动曲线平均 CRPS 为 0.0825，点状 95% 区间宽度中位数为 0.500。独立随机种子复核有 22/24 人通过，模型自身期望 22.94 人、95% 范围 [20, 24]， $p = 0.269$ ，CRPS 为 0.0823，区间宽度中位数仍为 0.500。因此，C1 的群体生成充分性不依赖某一次 Monte Carlo 种子。

冻结后的阶段形态检验同样有 23/24 人通过，模型自身期望 22.95 人、95% 范围为 [21, 24]， $p = 0.651$ 。在 24 名保留被试中，混乱、陡升、陡降、渐变和恢复分别见于 13、16、14、10 和 7 人；这些形态并非少数异常个案，而冻结 C1 能够把它们作为同一连续随机生成过程下的不同实现产生。没有任何同一方向的阶段残差在主尺度出现、又在另一窗口尺度得到至少 4 名被试的共同支持，因此当前结果没有要求再加入一个共享的离散阶段机制。

这一结果的含义限定在生成层。首先，预测区间宽度恰好达到预设的 0.50 上限，说明模型是边界性通过，而不是已经达到很高精度。其次，119 号被试在两次随机种子运行中都留下联合残差，但其是否跨过逐被试 FDR 阈值并不稳定；这支持继续记录个案误差，却不足以据此建立新的群体机制。再次，由真实前缀形成的个体 σ_s 后验均值与后缀突降数、最长突降、方向反转、最大下降和学习斜率的相关区间均跨 0。因此，当前数据支持“允许被试间波动强度不同”，但尚不能可靠测出每个人唯一的真实波动强度，更不能根据单条轨迹给被试命名为某种动态类型。

更深层个体异质性的保留集检验。 开发队列的两个 Monte Carlo 种子中，只有固定 readout 下的 H 候选在两次运行中都降低轨迹摘要偏差，但该开发信号没有通过全体比较的 sign-flip FDR；它只用于触发预先冻结的保留集检验。保留集结果表明，更深层的异质性确实能补足过于简单的固定 readout。相对于同批次固定 readout 参考，H 将联合覆盖从 10/24 提高到 24/24（成对 FDR $q = 0.00098$ ），轨迹摘要偏差平均降低 3.102（ $q = 0.0012$ ），联合校准统计量平均提高 0.438（ $q = 0.0012$ ）。128 粒子、512 后缀的独立高精度复核仍得到 11/24 到 24/24 的覆盖变化（ $q = 0.00049$ ）、摘要偏差降低 2.835（ $q = 0.00015$ ）。P 也把固定 readout 的覆盖从 10/24 提高到 23/24（ $q = 0.00098$ ），并降低摘要偏差 1.408（ $q = 0.0012$ ）。F 只改善联合校准统计量，M 没有通过 FDR 的有利效应；二者均未可靠改善联合覆盖。

上述优势没有在 C1 上形成同等增量。在同一 64 粒子、256 后缀辅助运行中，F、M、H、P 四个家族加入 C1 后的联合覆盖均保持在 22/24，没有任何家族的 CRPS、摘要偏差或联合校准效应通过 FDR。把 16 个候选合并成全局预测库后，C1 的覆盖仅由 22/24 变为 23/24（ $q = 1$ ）；联合校准统计量虽提高 0.159（ $q = 0.031$ ），点状 95% 区间却同时增宽 0.070（ $q = 0.00090$ ），而 CRPS 没有改善。这说明该校准增量至少部分来自更宽的生成分布，不能单独视为更准确的解释。

固定 readout 的全局候选库相对于固定参考同时降低 CRPS 0.0221（ $q = 0.0058$ ）和摘要偏差 3.278（ $q = 0.00013$ ），覆盖由 10/24 提高到 23/24（ $q = 0.00049$ ），但区间也增宽 0.188（ $q = 0.00013$ ）。更关键直接比较是：固定 readout 全局库与冻结 C1 在 CRPS、摘要偏差和联合校准上均无可靠差异，覆盖为 23/24 对 22/24（精确 $p = 1$ ），但全局库的点状区间比 C1 宽 0.049（ $q = 0.019$ ）。因此，跨机制混合能够成为 C1 的预测等价替代，但没有在相同锐度标准下胜过更简洁的 C1。

外部约束与机制恢复。 外部验证说明固定 readout 下的改善并非只由轨迹区间变宽造成。H 相对于其固定参考将后缀 NLL 平均降低 0.0657（ $q = 0.0042$ ），把被试内 RT--惊讶度 Spearman 相关提高 0.0389（ $q = 0.022$ ），并把口头报告中心相似度提高 0.00561（ $q = 0.0042$ ）；P 也降低后缀 NLL 0.0321（ $q = 0.0106$ ）。固定 readout 的全局库在三项外部指标上均通过 FDR：NLL 降低 0.0723、RT--惊讶度相关提高 0.0324、口头中心相似度提高 0.00450，相应 q 值分别为 0.00015、0.00045 和 0.00030。这些结果支持“假设空间及学习层面的异质性含有行为预测信息”，但尚未在同一外部指标上证明它优于 C1。

预测价值不等于机制可识别性。在家族内恢复中，F 和 M 的精确候选恢复率分别为 0.422 和 0.400（五候选机会水平 0.20），且真实值与后验均值保留排序信息；H 的精确恢复率为 0.250，恰等于四候选机会水平，真实 K 与后验均值的 Spearman 相关仅为 0.026。将四个家族放在同一候选库后，两次独立计算的合并家族恢复率为 0.215，接近 0.20 的机会水平。因而，H 的真实数据权重不能写成被试的心理容量，甚至不能区分是有限集合、反馈敏感性、记忆稳定性还是 beta 可塑性造成了相似轨迹。 $K = 3$ 下开放被试特异交换敏感性 θ 也没有任何通过 FDR 的有利效应，多个指标反而指向恶化，故当前不再增加动态策略参数。

综合这些证据，C1 继续作为条件 1 的正式工作模型：它已经在冻结保留集上达到生成充分性，并以更窄的预测分布达到与跨机制库相当的轨迹误差。H、P 和全局候选库保留为重要的预测等价性与敏感性审计，用来说明非单调轨迹不只可能由 readout 波动生成；它们不并入正式 C1，也不用于给被试贴机制标签。模型不声称任一次陡降必然由 readout 波动造成，更不声称 C1 是唯一心理解释。今后只有在预先规定的 choice、RT 或口头报告方向性预测上稳定优于 C1，而非仅靠扩大预测区间时，才应把某一更深层机制加入正式模型。

9 口头规则报告的独立验证

口头报告不参与模型参数估计。若报告在被试作出选择之后、反馈出现之前获得，则用于比较的假设分布应吸收当前选择，但不能吸收当前反馈。由式 24 的选择前 readout 权重得到

$$\pi_{s,t}^{\text{oral}}(h) = \frac{\omega_{s,t,h} q_{s,t,h}(c_{s,t})}{\sum_{u \in \mathcal{H}} \omega_{s,t,u} q_{s,t,u}(c_{s,t})}. \quad (45)$$

若口头规则编码为四维中心 $\mathbf{v}_{s,t}$ ，则将其与每个假设在所选类别下的原型比较：

$$d_{s,t}^{\text{oral}}(h) = \|\boldsymbol{\mu}_{h,c_{s,t}} - \mathbf{v}_{s,t}\|_2. \quad (46)$$

若口头规则编码为线性区域，则在同一组预先生成的 $[0, 1]^4$ Monte Carlo 点上比较口头区域与 R_{h,c_t} 的交并比。中心距离或区域重叠转换为定义在 $\mathcal{H}$ 上的口头假设分布后，使用 Jensen--Shannon similarity

$$\text{JSSim}(p, q) = 1 - \frac{\frac{1}{2} D_{\text{KL}}(p \| m) + \frac{1}{2} D_{\text{KL}}(q \| m)}{\log 2}, \quad m = \frac{1}{2}(p + q), \quad (47)$$

评价潜在假设分布与口头报告的一致性。由于口头报告没有参与行为模型选择，该检验提供独立的表征效度证据。

10 实现冻结与最低报告要求

正式代码、结果文件和论文报告至少需要满足以下要求：

1. 明确条件 1 包含 19 个基础几何划分和 38 条带标签假设，并保存每条假设的边界、原型和类别映射；
2. 报告独立知觉数据文件、被试噪声模式、feature 重排规则及逐试次截断抽样；
3. 始终区分反馈前信念 π_t^- 与反馈后信念 π_t^+ ；当前选择只能读取前者；
4. 保存两条记忆轨道、pre-feedback 与 post-feedback beta、 $\rho_{s,t}$ 、readout 权重和类别选择概率；
5. 冻结并报告 $\gamma = 0.55$ 、 $w_0 = 0.10$ 、 $\beta_0 = 5$ 、 $\eta_+ = 0.50$ 、 $\eta_- = 0.15$ 、 $\phi = 0.95$ 、群体中位 $\rho = 0.50$ 、创新尺度 0.20、两项 log 随机效应尺度 0.35 和 0.50，以及 $\rho \in [0.05, 20]$ 的数值边界；
6. 报告粒子数、后缀轨迹数、ESS 阈值、重采样比例、独立随机种子复核和所有数值截断常数；
7. 一步预测使用选择发生前的边际概率；自主后缀不得读取未来真实选择或真实反馈；
8. 同时报告 Brier、NLL、曲线 CRPS、15 维轨迹联合覆盖、30 维阶段联合覆盖和预测区间宽度；
9. 阶段词汇只用于描述外显轨迹，不得直接当作已经恢复的潜在认知状态；
10. 8 名开发被试只用于冻结模型，24 名保留被试不得重新选择参数或评价阈值；

11. 口头规则报告只用于行为模型冻结后的独立验证；
12. 个体异质性审计必须保存候选网格、开发群体先验、保留被试前缀 log evidence、候选后验和每条自主轨迹实际抽取的候选；候选在整条后缀内保持不变；
13. 明确区分固定 readout 上的替代效应与 C1 上的增量效应，并把 CRPS、联合覆盖和区间宽度放在一起解释，不能用更宽区间单独支持机制；
14. 模型恢复失败时，候选后验只能解释为预测不确定性，不得用作被试的容量、反馈敏感性、记忆稳定性或可塑性标签；
15. 新机制只有在冻结 C1 上同时改善预测位置、保持或提高锐度，并在预先规定的外部观测上给出同方向增量时，才可一次加入一个并重新进行自主生成和恢复检验。

综上，C1 保留了原模型最清楚的认知主线：学习者在任务定义的候选规则上积累反馈证据，知觉噪声、双通道记忆和动态 beta 分别刻画输入不确定性、证据的时间整合以及单条规则的类别锐度；连续随机 readout 则允许同一内部信念在不同试次表现为不同程度的规则竞争。该模型足够灵活，可以生成平稳渐进、混乱、陡升、陡降和恢复等多样轨迹，同时保持单一、连续且可审计的信息流。异质性审计进一步表明，受限且可替换的假设集和 beta 可塑性也能产生相近预测，但它们尚未在锐度受控的比较中优于 C1，亦不能从当前单次学习轨迹中被唯一恢复；因此这些设计被保留为等价解释边界，而不是叠加进正式模型。