

0.0.1 模型目标、理论承诺与架构边界

本研究的计算目标不是只复现被试的平均正确率，而是从逐试次的刺激、选择和反馈中恢复一个随学习进程变化的内部假设状态。模型的核心理论承诺是有限容量的假设检验：实验任务定义了一个完整但可能很大的候选假设空间 $\mathcal{H}$ ，然而被试在任一试次并不会同时维持和比较 $\mathcal{H}$ 中的全部假设，而只在一个容量受限的活跃集合 $A_t \subset \mathcal{H}$ 内进行推断。反馈历史可以使某些假设被保留、放弃或重新引入，但每个试次的并行表征负荷始终受到 $|A_t| \leq M$ 的约束。

这一“完整假设空间”与“有限活跃集合”的区分对于实验条件 2 和 3 尤其重要。条件 1 的基础几何假设空间包含 19 个划分，而四分类的条件 2 和 3 包含 116 个划分；若再无约束地扩展类别标签排列，候选数还会进一步组合爆炸。因此，完整集合 $\mathcal{H}$ 只定义学习者可能搜索到什么，活跃集合 A_t 才表示学习者当前实际维持什么。把全部假设同时激活的 full-set 模型仅作为非心理性的计算消融，用于检验有限容量假设的必要性；它不属于正式理论候选，也不参与以个体拟合优劣决定“容量受限或无限容量”的模型选择。

模型拟合只使用正式学习任务中的物理刺激 $\mathbf{x}_t$ 、被试选择 c_t 与反馈 r_t 。口头报告不参与参数选择，而在拟合完成后用于检验模型潜变量的外部效度。因而，若模型产生的假设轨迹能够预测未参与拟合的口头报告，所得一致性不能简单归因于用同一报告反向定义模型状态。

当前实现与发表版模型的区分。 当前代码中的 V14 配置是一个用于架构搜索的超模型：它包含标签反转、个体化知觉噪声、四种转移 profile、可选持续性潜在状态、双通道记忆和离散 readout 等机制。下文首先完整描述这一可运行实现，随后在“主模型、扩展模型与消融模型”一节中根据配对消融结果明确哪些机制应进入发表版主模型，哪些只能保留为亚组扩展或诊断对照。这样可以避免把“代码中能够开启”错写成“论文主模型中同时存在”。

0.0.2 符号、观测与状态变量

对被试 s 的第 t 个试次，观测记为

$$O_{s,t} = (\mathbf{x}_{s,t}, c_{s,t}, r_{s,t}), \quad \mathbf{x}_{s,t} \in [0, 1]^4, \quad (1)$$

其中 $\mathbf{x}_{s,t}$ 为四维物理刺激， $c_{s,t} \in \{1, \dots, N\}$ 为被试选择的类别， $r_{s,t}$ 为反馈。条件 1 中 $N = 2$ 且 $r_t \in \{0, 1\}$ ；条件 2 中 $N = 4$ 且 $r_t \in \{0, 1\}$ ；条件 3 中 $N = 4$ 且 $r_t \in \{0, 0.5, 1\}$ ，分别表示错误、家族层级正确和精确类别正确。

全文使用以下状态记号：

- $\mathcal{H} = \{h_1, \dots, h_K\}$ ：任务定义的完整候选假设空间；

- $A_t \subset \mathcal{H}$: 试次 t 的有限活跃假设集合, $m_t(h) = I(h \in A_t)$ 为其掩码;
- $\pi_t^-(h)$: 当前刺激与选择发生时、整合反馈 r_t 之前的假设先验;
- $\pi_t^+(h)$: 整合当前试次证据后的假设后验;
- $\tilde{\mathbf{x}}_t$: 知觉模块产生的内部刺激;
- $q_{t,h}(i) = P(C_i | \tilde{\mathbf{x}}_t, h, \beta_{t,h})$: 假设 h 下的类别概率;
- $L_t(h) = P(r_t | \tilde{\mathbf{x}}_t, c_t, h, \beta_{t,h})$: 反馈似然;
- $\beta_{t,h}$: 假设特异的逆温度或决策陡峭度;
- $F_t(h)$ 与 $S_t(h)$: 近期衰减记忆轨道和长期累积记忆轨道;
- z_t : 可选的持续性 ``信念不稳定性" 状态;
- $\omega_{t,h}$: 将假设信念读出为外显类别概率时使用的权重。

需要特别区分 π_t^- 与 π_t^+ 。前者可以用于预测试次 t 的选择, 后者已经吸收试次 t 的反馈, 只能解释反馈后的信念变化或预测下一试次。任何以 π_t^+ 回看同一试次选择的分析都会产生反馈泄漏。

0.0.3 任务特异的候选假设空间

统一的几何表示。 每个假设 $h \in \mathcal{H}$ 都把四维单位超立方体 $\mathbf{X} = [0, 1]^4$ 划分为 N 个带类别标签的区域。第 i 个区域写为

$$R_{h,i} = \{\mathbf{x} \in [0, 1]^4 : A_{h,i}\mathbf{x} \leq \mathbf{b}_{h,i}\}, \quad i = 1, \dots, N. \quad (2)$$

矩阵 $A_{h,i}$ 与向量 $\mathbf{b}_{h,i}$ 由一个或多个线性分界面及其方向组合而成。每个区域同时对应一个原型中心 $\boldsymbol{\mu}_{h,i}$ 。当前实现对每个假设、每个类别使用一个原型, 因此原型数组的形状为

$$K \times 1 \times N \times 4.$$

区域表示用于边界距离、假设相似性和口头区域报告的比较; 原型表示用于当前正式配置中的类别概率计算和口头中心报告的比较。

条件 1: 二分类的 19 个基础划分。 当 $N = 2$ 时, 基础空间 $\mathcal{H}_1^{\text{base}}$ 包含以下四类可解释规则:

1. 单维轴向边界 $x_i = 0.5$, 共有 4 个;
2. 二维等值边界 $x_i = x_j$, 共有 $\binom{4}{2} = 6$ 个;

3. 二维求和边界 $x_i + x_j = 1$, 共有 $\binom{4}{2} = 6$ 个;

4. 四维混合边界 $x_i + x_j = x_k + x_l$, 共有 3 个互不重复的维度配对。

因此

$$|\mathcal{H}_1^{\text{base}}| = 4 + 6 + 6 + 3 = 19. \quad (3)$$

轴向规则的两个类别中心在诊断维度上分别取 0.25 和 0.75, 其余维度取 0.5; 等值规则在两个相关维度上使用 (1/3, 2/3) 和 (2/3, 1/3) 的镜像中心; 求和规则在相关维度上共同取 1/3 或 2/3; 四维混合规则则使等式两侧的维度采用相反的 1/3 与 2/3 排列。

条件 1 的标签反转扩展。 当前 V14 代码配置设置了 `include_label_reversals=true`, 因而给每个基础几何划分增加一个交换类别 1 与类别 2 的副本:

$$|\mathcal{H}_1^{V14}| = 19 \times 2 = 38. \quad (4)$$

反转副本的几何边界不变, 但 $R_{h,1}$ 、 $R_{h,2}$ 及相应原型的类别标签对调。该扩展能够表达“几何规则正确但类别标签学反”的持续低于机会水平行为。然而, 修正后的配对消融并未支持把它保留在通用主模型中, 而且四分类若使用全部标签排列将使每个几何划分产生 $4! = 24$ 个标签版本。因此, 发表版 v2 将 19 个基础划分作为条件 1 主空间, 把标签反转保留为针对持续低于机会水平个体的预先限定扩展或消融模型, 而不把 38 个状态写成默认假设空间。

条件 2 和 3: 四分类的 116 个划分。 条件 2 和 3 共享四分类几何空间 $\mathcal{H}_{2,3}$ 。其划分由两个或三个超平面构成四个带标签区域, 具体计数如下:

$$\begin{aligned} |\mathcal{H}_{2,3}| = & 6_{\text{axis+axis}} + 6_{\text{equality+sum}} + 12_{\text{axis+equality}} + 12_{\text{axis+sum}} \\ & + 3_{\text{equality+equality}} + 3_{\text{sum+sum}} + 24_{\text{three axes}} \\ & + 24_{\text{axis+equality+sum}} + 12_{\text{equality+two axes}} + 12_{\text{sum+two axes}} \\ & + 1_{\text{dimension max}} + 1_{\text{dimension min}} = 116. \end{aligned} \quad (5)$$

其中, 三条轴向边界的顺序以及“轴向--等值--求和”中后两条边界的顺序都会改变四个区域的类别标签, 所以在计数中保留这些排列。dimension-max 规则把“四维中哪一维最大”映射为四个类别, dimension-min 规则同理把最小维度映射为类别。

四分类原型使用与相应区域一致的代表点: 轴向切分主要使用 0.25/0.75; 等值与求和关系主要使用 1/3 与 2/3; 二维等值--求和的四扇区使用 1/6、1/2 与 5/6; dimension-max 原型把目标维度设为 0.8、其余维度设为 0.4, dimension-min 则把目标维度设为 0.4、其余维度设为 0.8。所有原型均按区域标签顺序构造, 并经过区域约束的一致性检查。条件 2 和 3 不默认生成四分类标签排列副本。

完整空间并不等于同时激活。 在当前 V14 条件 1 配置中, $M = 5$, 所以每个试次至多有 5 个状态参与竞争, 即便代码定义了 38 个候选。向条件 2 和 3 扩展时仍保持有限的 M , 而不是把 M 设置为 116。由此, 模型复杂度的增长主要体现在“可搜索的长期可能性”, 而不是“单试次并行工作记忆负荷”。

实现索引与理论假设的区分。 代码内部使用从 0 开始的假设索引。当前枚举中, 条件 1 的目标轴向规则为索引 0; 条件 2/3 的目标三轴层级规则为索引 42。它们只是由当前枚举顺序产生的实现标签, 不具有可跨版本解释的心理含义。论文和保存结果应同时记录规则的几何定义, 不能只写“hypothesis 0”或“hypothesis 42”。刺激始终按每名被试 feature1--feature4 的实际顺序进入模型, 因此目标索引的含义以该被试已经重排后的坐标系为准。

0.0.4 假设下的类别概率

原型距离。 当前正式 V14 配置采用原型模式。给定内部刺激 $\tilde{\mathbf{x}}_t$, 类别 i 的距离为

$$d_{t,h,i}^{\text{proto}} = \min_{p=1,\dots,P} \|\tilde{\mathbf{x}}_t - \boldsymbol{\mu}_{h,p,i}\|_2, \quad (6)$$

当前 $P = 1$, 因此上式退化为到单一原型的欧氏距离。

边界距离。 边界模式把距离定义为刺激到类别多面体的最短欧氏距离:

$$d_{t,h,i}^{\text{bdry}} = \min_{\mathbf{z} \in R_{h,i}} \|\tilde{\mathbf{x}}_t - \mathbf{z}\|_2. \quad (7)$$

若刺激已位于 $R_{h,i}$ 内, 距离为 0; 否则代码通过半空间与 $[0, 1]^4$ 盒约束的迭代投影近似最近点。原型和边界模式共享完全相同的后续概率接口, 因此可以作为几何表征的稳健性检验, 而不改变其他模块。

距离 softmax。 无论使用哪种距离, 假设 h 对类别 i 的预测均为

$$q_{t,h}(i) = \frac{\exp[-\beta_{t,h} d_{t,h,i}]}{\sum_{j=1}^N \exp[-\beta_{t,h} d_{t,h,j}]}. \quad (8)$$

$\beta_{t,h}$ 越大, 假设产生的类别判断越接近确定性; $\beta_{t,h}$ 越小, 类别概率越接近均匀分布。这里的 β 属于“单个假设如何把刺激映射为类别”, 不能与后文 readout concentration 混同; 后者控制“多个活跃假设如何共同生成一个外显选择”。

0.0.5 逐试次因果顺序

每个试次严格按照以下顺序处理:

1. 试次开始时，暂将上一试次后验复制为当前先验；
2. 知觉模块把物理刺激 $\mathbf{x}_t$ 映射为 $\tilde{\mathbf{x}}_t$ ；
3. 假设转移模块只使用截至 $t-1$ 的反馈和选择历史，从上一活跃集合与上一后验产生 A_t 和 π_t^- ；
4. 似然模块使用当前选择 c_t 、当前反馈 r_t 以及尚未吸收 r_t 的 $\beta_{t,h}$ 计算 $L_t(h)$ ；
5. 记忆模块将 π_t^- 、历史证据状态和 $L_t(h)$ 整合为 π_t^+ ；
6. beta 模块先保存本试次实际使用的 $\beta_{t,h}$ ，再根据 r_t 更新 $\beta_{t+1,h}$ ；
7. 当前观测被写入历史，供试次 $t+1$ 的假设转移使用。

因此，本试次的预测使用 $(\pi_t^-, \beta_t, \tilde{\mathbf{x}}_t)$ ：

$$P(c_t = i \mid \mathcal{D}_{1:t-1}, \mathbf{x}_t) = \sum_{h \in A_t} \omega_{t,h} q_{t,h}(i), \quad (9)$$

而不是使用已经看过 r_t 的 π_t^+ 或 β_{t+1} 。当前评价代码从第二个试次开始计算预测损失，第一个试次只用于初始化状态。

当前实现是条件状态滤波器。 当前 engine 在每个试次读取真实被试的 c_t 和 r_t 来更新潜在状态，并没有在内部生成一个模型选择再据此生成反馈。重复 ``simulation" 的含义是：在同一条观测行为序列条件下，重复抽取知觉噪声、profile 和 newcomer 等潜在随机量，以 Monte Carlo 方式积分状态不确定性。默认 agenda 中不含 DecisionModule，且该模块的 process() 尚未实现；外显类别概率由 engine 之外的 choice-readout 评价层计算。因此，当前损失是因果的一步预测损失，而不是闭环自主 agent 的似然。若未来要模拟干预下的全新行为轨迹，必须另外实现 ``生成选择--由任务规则返回反馈--再更新状态" 的闭环。

0.0.6 有限容量的动态假设转移

初始化与硬容量。 模型初始化时从指定候选池中无放回抽取 M_0 个假设。V14 的默认值为 $M_0 = 5$ 、 $M = 5$ 。候选池可以是全部假设、仅基础标签版本或仅标签反转版本；V14 默认从全部候选中抽取，也允许通过 init_hypotheses 强制包含预先指定的状态。任一转移产生超过 M 个候选时，只保留上一后验最高的 M 个。若转移意外产生空集，则从上一活跃集合中选择后验最高的假设作为兜底。

控制器只读取过去信息。在试次 t 选择转移策略时，控制器构造历史特征向量

$$\mathbf{f}_t = (1, e_{t-1}, \bar{a}_t, 1 - \bar{a}_t, \Delta a_t, H_t, 1 - H_t, z_t, \psi_t, \tau_t, \phi_t), \quad (10)$$

其中：

$$e_{t-1} = 1 - r_{t-1}^{\text{exact}}, \quad (11)$$

$$\bar{a}_t = \frac{1}{W} \sum_{j=t-W}^{t-1} r_j^{\text{exact}}, \quad (12)$$

$$\Delta a_t = \frac{1}{W} \sum_{j=t-W}^{t-1} r_j^{\text{exact}} - \frac{1}{W} \sum_{j=t-2W}^{t-W-1} r_j^{\text{exact}}, \quad (13)$$

$$H_t = \frac{-\sum_{h \in \mathcal{H}} \pi_{t-1}^+(h) \log \pi_{t-1}^+(h)}{\log |\mathcal{H}|}, \quad (14)$$

$$\tau_t = \min \left(\frac{t-1}{160}, 1 \right), \quad (15)$$

$$\phi_t = \exp \left[-\frac{1}{2} \left(\frac{\tau_t - 0.35}{0.12} \right)^2 \right], \quad (16)$$

$$\psi_t = \left\{ 1 + \exp \left[-8 \left(\frac{z_t}{z_{\max}} - \frac{z_{\text{thr}}}{z_{\max}} \right) \right] \right\}^{-1}. \quad (17)$$

V14 使用 $W = 8$ ，历史不足时以机会水平 $1/N$ 填充。 H_t 是按完整空间大小归一化的后验熵， $1 - H_t$ 被称为后验置信度。由于实际后验只在至多 5 个活跃状态上有非零质量，用 $\log |\mathcal{H}|$ 而非 $\log |A_t|$ 归一化会系统性提高“置信度”的数值；这是当前实现需要在最终冻结前明确保留或修正的语义选择。

反馈门控的 profile 选择。 控制器包含若干 profile k 。每个 profile 的激活得分与抽样概率为

$$u_{t,k} = \mathbf{a}_k^\top \mathbf{f}_t, \quad P(K_t = k) = \frac{\exp(u_{t,k}/T)}{\sum_{\ell} \exp(u_{t,\ell}/T)}, \quad (18)$$

其中 $T > 0$ 为 profile 温度。控制器从该分布抽样一个 profile，再由其策略产生 A_t 。随机抽样不是数值噪声，而是模型预测分布的一部分，因此每组参数必须通过重复模拟积分，而不能只报告一条最好轨迹。

四种当前实现的基础 profile。 V14 代码实现了以下四种转移原语：

1. *Conservative*: 保持上一活跃集合不变，不引入 newcomer；只在旧集合为空时选择一个最高分假设。幸存者继承全部先验质量。
2. *Stable*: 通常保留 $M - 1$ 个旧假设并引入 1 个 newcomer。旧假设按后验或 choice-informed 得分加权无放回抽样；若集合已满且仍有未激活候选，至少空出一个位置用于探索。
3. *Aggressive*: 只保留最高分的一个旧假设 h^* ，并根据

$$n_t^{\text{new}} = \text{clip} \left[\text{round} \{ (1 - \pi_{t-1}^+(h^*)) n_{\max} \}, n_{\min}, n_{\max} \right] \quad (19)$$

引入多个 newcomer；newcomer 总先验质量为 $1 - \pi_{t-1}^+(h^*)$ 。

4. *Stubborn*: 确定性保留得分最高的 n_{retain} 个旧假设, 并以

$$p_t^{\text{explore}} = p_0 + p_{\text{correct}}(1 - e_{t-1}) + p_{\text{error}}e_{t-1} \quad (20)$$

的概率引入至多一个 newcomer; 若引入, 其总先验质量为预设的小值。

这些名称表示算法行为, 不应被直接当作未经验证的心理类型。配对消融表明 stable profile 的增益最稳定; aggressive profile 的平均贡献为负, 因而在发表版 v2 中应移出通用主模型; conservative 与 stubborn 更适合在下一轮实现中合并为一个低探索状态, 而不是长期保留两套高度相近的复杂分支。

V14 的六个控制器家族。 当前超参数搜索使用 6 个控制器家族, 每个家族都包含上述四个基础 profile, 但改变激活系数、温度以及转移细节:

1. *stable_dominant*, $T = 0.85$: stable 的截距最高, 主要描述稳定保留加少量探索;
2. *error_aggressive*, $T = 0.70$: 错误、高熵和低近期正确率更强地激活 aggressive;
3. *early_explore_late_stable*, $T = 0.80$: 早期提高 aggressive, 随 τ_t 增大提高 stable/conservative;
4. *conservative_heavy*, $T = 0.75$: 高正确率和高置信度显著提高 conservative;
5. *error_choice_newcomer*, $T = 0.65$: 用近期错误选择给 survivor 和 newcomer 打分;
6. *choice_volatile_refresh*, $T = 1.10$: 同样使用 choice-informed 得分, 但保留更高的 profile 随机性和刷新概率。

这 6 个家族不是同时叠加的六个模块, 而是被试层面的离散候选; 每名被试在超参数搜索中选择其中一个家族。

六个家族的精确激活系数。 为避免只报告 profile 名称而遗漏其实际含义, 令

$$A = \bar{a}_t, \quad E = 1 - \bar{a}_t, \quad e = e_{t-1}, \quad H = H_t, \quad C = 1 - H_t, \quad \tau = \tau_t, \quad \psi = \psi_t.$$

在 state-off 时, 六个家族中 conservative、stable、aggressive 和 stubborn 的四个 logit 依次为:

$$\begin{aligned} \text{stable_dominant: } (u_C, u_S, u_A, u_B) = & (0.1 + 0.7A + 0.5C, 1.0 + 0.5H + 0.3A, \\ & -0.4 + 0.7E + 0.6H, -0.3 + 0.7e + 0.5C), \end{aligned} \quad (21)$$

$$\begin{aligned} \text{error_aggressive: } (u_C, u_S, u_A, u_B) = & (-0.2 + 0.9A + 0.6C, 0.2 + 0.4H + 0.4A, \\ & 0.3 + 1.2e + 1.2E + 0.8H, -0.5 + 0.3e + 0.4C), \end{aligned} \quad (22)$$

$$\text{early_explore_late_stable: } (u_C, u_S, u_A, u_B) = (-0.2 + 1.2\tau + 0.8A, 0.3 + 0.8\tau + 0.5H,$$

$$0.5 + H - 1.2\tau, -0.3 + 0.8e + 0.5C), \quad (23)$$

$$\text{conservative_heavy}: (u_C, u_S, u_A, u_B) = (1.0 + A + C, 0.2 + 0.6H, -1.0 + 0.5E, -0.6 + 0.5e), \quad (24)$$

$$\begin{aligned} \text{error_choice_newcomer}: (u_C, u_S, u_A, u_B) = & (-1.5 + A - 0.5E + 0.8C, -1.0 + 0.8A + 0.4C - 0.5H, \\ & -1.2 + 0.5e + E + H - 0.5C, 0.8 + 0.7e + 0.4E + C), \end{aligned} \quad (25)$$

$$\begin{aligned} \text{choice_volatile_refresh}: (u_C, u_S, u_A, u_B) = & (-1.5 + A - 0.5E + 0.8C, -0.2 + 0.9H + 0.2A, \\ & 0.9e + 1.4E + H, -0.1 + 0.8e + 0.4E + 0.6C). \end{aligned} \quad (26)$$

下标 B 在此表示 stubborn (为避免与 stable 的 S 重复)。在 state-on 版本中, 除 early-explore 家族外, aggressive logit 中的 recent-error 项被 1.5ψ 替代; early-explore 家族则 在原 aggressive logit 上额外加入 1.5ψ 。其余三个 profile 的激活式不变。

六个家族的精确 policy 参数。 四个不使用 choice-informed 得分的家族都以普通后 验给 survivor 加权、从 inactive pool 均匀抽取 newcomer, 并使用 $M = 5$ 、stable 的 $\text{explore_count} = 1$ 、aggressive 的 $\text{max_newcomers} = 4$ 、stubborn 的 $\text{retain_count} = 2$ 。 其差异为:

- **stable_dominant:** stable retain temperature 为 0.8、 $\alpha_{\min} = 0.04$; aggressive 的 $n_{\min} = 0$; stubborn 使用 $(p_0, p_{\text{correct}}, p_{\text{error}}, \nu) = (0.03, 0.18, 0, 0.02)$ 。
- **error_aggressive:** stable retain temperature 为 1.0、 $\alpha_{\min} = 0.05$; aggressive 的 $n_{\min} = 1$; stubborn 使用 $(0.02, 0.20, 0, 0.02)$ 。
- **early_explore_late_stable:** stable retain temperature 为 0.9、 $\alpha_{\min} = 0.04$; ag-
gressive 的 $n_{\min} = 1$; stubborn 使用 $(0.02, 0.16, 0, 0.02)$ 。
- **conservative_heavy:** stable retain temperature 为 0.8、 $\alpha_{\min} = 0.03$; aggressive
的 $n_{\min} = 0$; stubborn 使用 $(0.02, 0.15, 0, 0.02)$ 。

两个 choice-informed 家族对式 27 使用不同的 (a, b) , 并对式 28 使用不同的 choice weight b_c 与 newcomer temperature T_c :

- **error_choice_newcomer:** conservative 和 stable 使用 $(a, b, b_c, T_c) = (0.8, 1.2, 2.0, 0.7)$; aggressive 使用 $(0.6, 1.4, 2.4, 0.6)$ 且 $n_{\min} = 1$; stubborn 使用 $(0.5, 1.5, 2.8, 0.5)$, 并设置 $(p_0, p_{\text{correct}}, p_{\text{error}}, \nu) = (0.10, 0.02, 0.25, 0.25)$ 。stable retain temperature 为 0.7, $\alpha_{\min} = 0.05$ 。
- **choice_volatile_refresh:** conservative 和 stable 同样使用 $(0.8, 1.2, 2.0, 0.7)$; ag-
gressive 使用 $(0.6, 1.4, 2.2, 0.8)$ 且 $n_{\min} = 2$; stubborn 使用 $(0.5, 1.5, 2.8, 0.5)$, 并设
置 $(0.12, 0.02, 0.20, 0.12)$ 。stable retain temperature 为 1.5, $\alpha_{\min} = 0.05$ 。

所有 choice-informed newcomer 均只读取最近 8 个错误试次。Conservative 的 newcomer mass 为 0；stable 使用 similarity--novelty 映射；aggressive 和 stubborn 使用各自的显式先验质量覆盖规则。

标准与 choice-informed 假设得分。 标准 survivor 得分为上一后验。choice-informed 版本把上一选择的可解释性加入得分：

$$s_t^{\text{surv}}(h) \propto [\pi_{t-1}^+(h)]^a [q_{t-1,h}(c_{t-1})]^b. \quad (27)$$

对未激活候选，模型可以只使用最近 $W_c = 8$ 个错误试次，计算

$$\log \tilde{s}_t^{\text{new}}(h) = \frac{b_c}{|\mathcal{E}_t|} \sum_{j \in \mathcal{E}_t} \log q_{j,h}(c_j), \quad \mathcal{E}_t = \{j < t : r_j < 1\} \cap \{t - W_c, \dots, t - 1\}. \quad (28)$$

随后经温度变换和归一化进行无放回抽样。该机制能够选择能解释被试近期错误选择的假设，但也最容易把具体选择序列重新编码进潜在状态。当前消融仅在 4 名实际选中此类控制器的代表性被试上成立，平均 Brier 收益较小且 CRPS 变差，因此它只应作为预先限定的亚组扩展，不能作为所有被试的默认机制。

0.0.7 活跃集合变化时的 posterior-to-prior 映射

设上一活跃集合为 A_{t-1} ，新集合为 A_t ，幸存者和新进入者分别为

$$S_t = A_{t-1} \cap A_t, \quad N_t = A_t \setminus A_{t-1}. \quad (29)$$

假设转移不仅改变掩码，还必须把 π_{t-1}^+ 映射为定义在 A_t 上的 π_t^- 。当前实现支持四类映射。

相似性--新颖性映射。 默认 stable profile 使用

$$c_t = \text{Conf}(\pi_{t-1}^+), \quad (30)$$

$$s_t(h) = \sum_{u \in A_{t-1}} \text{Sim}(h, u) \frac{\pi_{t-1}^+(u)}{\sum_{v \in A_{t-1}} \pi_{t-1}^+(v)}, \quad (31)$$

$$n_t(h) = 1 - \max_{u \in A_{t-1}} \text{Sim}(h, u), \quad (32)$$

$$\tilde{\pi}_t^-(h) = \begin{cases} \pi_{t-1}^+(h), & h \in S_t, \\ \alpha_t [c_t s_t(h) + (1 - c_t) n_t(h)], & h \in N_t, \\ 0, & h \notin A_t, \end{cases} \quad (33)$$

$$\alpha_t = \max(1 - c_t, \alpha_{\min}), \quad \pi_t^-(h) = \frac{\tilde{\pi}_t^-(h)}{\sum_u \tilde{\pi}_t^-(u)}. \quad (34)$$

V14 的 stable 家族通常使用 $\alpha_{\min} = 0.03$ -- 0.05 。默认 c_t 为最大后验，也可以由熵、近期正确率或 $1 - z_t$ 定义。高置信度使 newcomer 更偏向与旧解释相似的局部扩展，低置信度使结构上新颖的候选获得更多质量。

保守继承。 Conservative profile 将总质量 $1 - \nu$ 按幸存者后验重新归一化，并把 ν 均匀分给 newcomer。V14 中 $\nu = 0$ ，所以没有 newcomer 时完全继承旧信念。

Aggressive 与 stubborn 的显式质量分配。 Aggressive 保留 top-1，并把 $1 - \pi_{t-1}^+(h^*)$ 分配给 newcomer；stubborn 把预设质量 $\nu \in [0.02, 0.25]$ 分配给至多一个 newcomer，其余质量按幸存者得分归一化。这两类 profile 会覆盖通用的相似性--新颖性映射。

错误增强与随机重置。 代码还实现了两个未进入当前 V14 正式候选的扩展：其一根据近期错误率和 z_t 在预设上下限之间增加 newcomer 总质量；其二以固定概率从 Gamma 分布抽取活跃假设权重，从而形成 Dirichlet 型随机重置。后者的 concentration 参数只控制随机先验在活跃假设间是集中还是均匀，与 choice readout 的 concentration 不是同一个参数。因为当前 V14 配置没有启用这两条分支，发表版主方法不应把它们描述为已拟合机制。

假设相似性。 相似性矩阵在 $[0, 1]^4$ 中均匀抽取 $B = 100,000$ 个点，并比较两个假设对每个点的带标签类别分配：

$$\text{Sim}(h, u) = \frac{1}{B} \sum_{b=1}^B I\{g_h(\mathbf{x}_b) = g_u(\mathbf{x}_b)\}. \quad (35)$$

因此该相似性同时考虑几何边界和类别标签；标签反转的几何虽然相同，但带标签相似性会显著降低。矩阵按维数、类别数、标签配置和抽样数缓存，避免在每次拟合中重新计算。

0.0.8 可选的持续性信念不稳定状态

V14 还搜索一个持续性状态 z_t ，用于表达一次错误对后续若干试次的策略选择产生延迟影响。当前配置中

$$z_t = \text{clip} \left[\delta z_{t-1} + g e_{t-1} (1 - H_{t-1}) + b + g_a \max \left(0, \frac{a_{\text{thr}} - \bar{a}_t}{a_{\text{thr}}} \right), 0, z_{\text{max}} \right]. \quad (36)$$

V14 固定 $\delta = 0.80$ 、 $b = 0$ 、 $g_a = 0$ 、 $a_{\text{thr}} = 0.55$ 、 $z_{\text{max}} = 1$ ，并搜索 $g \in \{0, 0.20, 0.35, 0.50\}$ ； $g = 0$ 即 state-off。 z_t 本身不直接改变似然或后验，只通过式 17 的 logistic pressure ψ_t 提高 aggressive profile 的激活概率。

这一状态在实现上是因果的： z_t 只读取 r_{t-1} 及更早历史。然而，修正后的配对消融中其平均 Brier 改善约为 0.001，CRPS 没有改善，且它主要驱动的 aggressive profile 本身缺乏通用收益。因此， z_t 不应进入发表版通用主模型，只能作为预先限定亚组的扩展。代码中另有把 z_t 或近期错误转化为显式 prior reset 的开关，但当前 V14 的 reset 强度全为 0，故不属于当前有效路径。

0.0.9 反馈似然与贝叶斯证据

精确正确和错误反馈。 令被试选择类别的概率为

$$q_{t,h}^{\text{choice}} = q_{t,h}(c_t). \quad (37)$$

当反馈只区分正确和错误时,

$$L_t(h) = \begin{cases} q_{t,h}^{\text{choice}}, & r_t = 1, \\ 1 - q_{t,h}^{\text{choice}}, & r_t = 0. \end{cases} \quad (38)$$

对四分类任务, $r_t = 0$ 的第二行等于该假设分配给其余三个类别的总概率, 而不是试图从错误反馈中确定唯一正确类别。

家族层级反馈。 条件 3 中 $r_t = 0.5$ 表示类别家族正确但精确类别错误。对每个假设和被选类别, 代码根据类别原型在多少个维度上不同建立家族邻接集合 $\mathcal{F}_h(c_t)$, 并使用

$$L_t(h) = \sum_{j \in \mathcal{F}_h(c_t)} q_{t,h}(j), \quad r_t = 0.5. \quad (39)$$

因此反馈似然可以区分精确正确、家族正确和完全错误三种信息强度。最终似然在假设维度上归一化后写入 engine; 这一归一化只增加一个对所有假设相同的对数常数, 不改变同一试次内的贝叶斯比。

这里存在一个条件 3 必须在冻结前修正的实现语义: 实验中的类别家族是由任务标签固定定义的, 但当前 `connectivity_map` 是根据每个假设的原型是否“恰好只在一个维度上不同”动态建立的。116 个假设中有些得到标签对 (1,2) 与 (3,4), 有些得到另一种配对, 有些甚至没有邻接类别。因而, 当前代码中的 $r_t = 0.5$ 似然在不同假设下并不总是表示同一个实验事件。条件 3 的正式实现应使用任务固定的家族映射, 并把这一映射作为观测模型而非假设几何的属性。

规范性基线。 若不启用记忆扩展, 标准更新为

$$\pi_t^+(h) = \frac{\pi_t^-(h)L_t(h)m_t(h)}{\sum_{u \in \mathcal{H}} \pi_t^-(u)L_t(u)m_t(u)}. \quad (40)$$

完整实现用下述记忆状态替代简单的一步乘法, 但仍保留“先验乘似然”的规范性骨架。

0.0.10 双通道记忆及其边界模型

两条对数证据轨道。 `DualMemoryModule` 为每个假设维护近期衰减轨道 $F_t(h)$ 和长期累积轨道 $S_t(h)$:

$$F_t(h) = \gamma F_{t-1}(h) + \log L_t(h), \quad (41)$$

$$S_t(h) = S_{t-1}(h) + \log L_t(h), \quad h \in A_t, \quad (42)$$

其中 $\gamma \in [0, 1]$ 。两条轨道按

$$\ell_t(h) = w_0 S_t(h) + (1 - w_0) F_t(h) \quad (43)$$

混合，并在当前活跃集合内归一化：

$$\pi_t^+(h) = \frac{\exp[\ell_t(h)] m_t(h)}{\sum_{u \in \mathcal{H}} \exp[\ell_t(u)] m_t(u)}. \quad (44)$$

$w_0 = 0$ 是 fade-only, $w_0 = 1$ 是 static-only; 只有 $0 < w_0 < 1$ 才是真正双通道混合。 γ 越小, 近期轨道越偏重最近试次; 当 $w_0 = 1$ 时 γ 不再影响后验。

集合转移与记忆状态同步。 当假设转移模块把后验映射为新的 π_t^- 时, 记忆模块必须保证混合前状态与该先验一致。对每个仍然活跃的假设, 令

$$\Delta_h = S_{t-1}(h) - F_{t-1}(h), \quad T_h = \log \pi_t^-(h) + C_t,$$

其中 C_t 是不影响归一化的共同平移。同步后的状态满足

$$F_{t-1}^{\text{sync}}(h) = T_h - w_0 \Delta_h, \quad S_{t-1}^{\text{sync}}(h) = T_h + (1 - w_0) \Delta_h. \quad (45)$$

于是

$$w_0 S_{t-1}^{\text{sync}}(h) + (1 - w_0) F_{t-1}^{\text{sync}}(h) = T_h,$$

同时保留每个假设自己的长期--近期差值 Δ_h 。新进入假设没有历史差值时使用基线轨道的差值; 被移除假设的两条状态设为 $-\infty$ 。当前修正版在每个试次都执行这一同步, 而不只在掩码变化时执行, 从而保证 engine 中的 π_t^- 与记忆模块内部状态一致。基线轨道每个试次加入 $\log(1/|\mathcal{H}|)$ 作为共同参考似然; 该共同项在活跃假设间归一化时抵消, 只用于计算集合迁移所需的数值平移。

当前搜索与发表版地位。 当前 V14 网格搜索

$$\gamma \in \{0.25, 0.50, 0.70, 0.85, 0.95\}, \quad w_0 \in \{0.01, 0.05, 0.10, 0.20, 0.50\}.$$

这一网格遗漏了 $w_0 = 0$ 与 $w_0 = 1$ 两个边界。配对消融表明双通道明显优于 fade-only, 却没有优于 static-only。因此, 在补齐端点并重新优化之前, 最简约的发表版基线应为 static-only; 双通道只能作为需要重新竞争的扩展, 不能依据旧网格直接宣称为必要机制。下一轮至少应搜索

$$w_0 \in \{0, 0.01, 0.05, 0.10, 0.20, 0.50, 1\},$$

并在同一随机种子、同一控制器和同一 readout 下比较 static-only、fade-only 与内部混合值。

0.0.11 假设特异的动态 beta

初始化。 每个假设拥有独立的 $\beta_{t,h}$ 。V14 固定

$$\beta_{\text{init}} = 5, \quad \beta_{\text{min}} = 0.1, \quad \beta_{\text{max}} = 25.$$

新进入活跃集合的假设根据其迁移先验初始化：

$$\beta_{t,h}^{\text{new}} = \text{clip} \left[\beta_{\text{init}} + \lambda \frac{\pi_t^-(h)}{\max_{u \in N_t} \pi_t^-(u)}, \beta_{\text{min}}, \beta_{\text{max}} \right], \quad \lambda = 3. \quad (46)$$

非活跃假设的 beta 在本试次更新后置为 0；若其以后重新进入，将按式 46 重新初始化。

二分类的反馈更新。 对条件 1，反馈可以唯一确定正确类别：

$$y_t^* = \begin{cases} c_t, & r_t = 1, \\ 3 - c_t, & r_t = 0. \end{cases}$$

令 $\hat{y}_{t,h} = \arg \max_i q_{t,h}(i)$ 。反馈后的 beta 更新为

$$\beta_{t+1,h} = \begin{cases} \min \left[\beta_{\text{max}}, \beta_{t,h} + \eta_+ \frac{\beta_{\text{max}} - \beta_{t,h}}{\beta_{\text{max}}} \right], & \hat{y}_{t,h} = y_t^*, \\ \max[\beta_{\text{min}}, \beta_{t,h} - \eta_- \beta_{t,h}], & \hat{y}_{t,h} \neq y_t^*, \end{cases} \quad (47)$$

其中 V14 使用 $\eta_+ = 0.5$ 、 $\eta_- = 0.15$ 。奖励随接近上界而递减，惩罚与当前 beta 成比例。

四分类反馈的实现边界。 在四分类中，错误反馈不能唯一确定真实类别。当前 `inferred_correct_category` 模式在 $r_t < 1$ 时只惩罚把被选类别预测为 modal 类别的假设，对预测其他类别的假设不更新；对 $r_t = 0.5$ 也使用同一回退逻辑。因此，这一 beta 更新并未完整利用条件 3 的家族信息。代码另提供 `probabilistic-feedback` 模式：

$$E_t(h) = r_t q_{t,h}(c_t) + (1 - r_t)[1 - q_{t,h}(c_t)], \quad (48)$$

$$\xi_t(h) = 2[E_t(h) - 0.5], \quad (49)$$

并按 $\xi_t(h)$ 的正负连续奖励或惩罚 beta。该模式避免从四分类错误反馈推断不存在的唯一正确类别，但 $r_t = 0.5$ 时 $\xi_t(h) = 0$ ，仍不会利用家族结构。因而，条件 2/3 的最终发表版需要让 beta 更新与式 39 的多层反馈似然一致，而不能未经验证地照搬条件 1 的硬类别更新。

因果记录与效应地位。 当前修正版先记录产生试次 t 选择概率的 $\beta_{t,h}$ ，再用 r_t 更新 $\beta_{t+1,h}$ 。在代表性被试的配对消融中，动态 beta 相对固定 $\beta = 5$ 是收益最大且最一致的机制，因此应保留。但正式结论仍需把它与“为每名被试优化的静态 beta”比较，而不能只与任意固定值 5 比较。

0.0.12 从假设信念到外显选择的 readout

假设后验表示学习者对规则的不确定性，但外显选择未必等于在所有规则上的线性期望。模型使用 readout 权重 $\omega_{t,h}$ 把 π_t^- 转换为类别概率。

Expectation。

$$\omega_{t,h} = \pi_t^-(h), \quad \hat{P}_t(C_i) = \sum_{h \in A_t} \pi_t^-(h) q_{t,h}(i). \quad (50)$$

Sharpened expectation。

$$\omega_{t,h}(\rho) = \frac{[\pi_t^-(h) + \epsilon]^\rho}{\sum_{u \in A_t} [\pi_t^-(u) + \epsilon]^\rho}, \quad \rho > 0. \quad (51)$$

这里 ρ 是 readout concentration: $\rho = 1$ 等于 expectation; $\rho > 1$ 逐渐把选择集中到高先验假设; $\rho \rightarrow \infty$ 接近 MAP; $0 < \rho < 1$ 则使多个假设的贡献更均匀。当前 V14 代码使用 $\epsilon = 0$, 并只搜索 $\rho = 2$ 和 $\rho = 4$ 。

MAP hypothesis。

$$h_t^* = \arg \max_h \pi_t^-(h), \quad \omega_{t,h} = I(h = h_t^*). \quad (52)$$

当前 V14 因而搜索四个离散 readout: expectation、 $\rho = 2$ 、 $\rho = 4$ 和 MAP。配对消融支持保留 readout 灵活性，但正式 v2 更适合把这些分支写成同一条连续 concentration 轴: $\rho = 1$ 是完全平均，有限 $\rho > 1$ 是不同程度的集中，MAP 是极限情形。这样可以减少“四套输出机制”的表面复杂度。不过，连续 ρ 进入正式方法之前必须先代码中实现连续搜索并完成重新拟合；当前结果仍来自四个离散候选。

Readout 只改变如何从同一条 π_t^- 计算预测选择概率，不回写 active set、likelihood、memory 或 beta；因此，在其他参数和随机种子相同时，不同 readout 共享同一条潜在状态轨迹。它在当前架构中属于观测/测量层，而不是学习状态转移层。

代码还实现按先验抽取单个假设、sticky sampling 和 stubborn-sticky readout，但当前 V14 超参数空间没有启用这些分支，故它们不属于当前有效模型，也不应写入论文主模型。

0.0.13 个体化知觉噪声

知觉模块把物理刺激变换为

$$\tilde{x}_{t,j} = \text{clip}(x_{t,j} + \varepsilon_{t,j}, 0, 1). \quad (53)$$

对匹配任务校准的被试，

$$\varepsilon_{t,j} \sim \mathcal{N}(\mu_{s,j}, \sigma_{s,j}^2), \quad (54)$$

其中 $\mu_{s,j}$ 与 $\sigma_{s,j}$ 来自 Task1b_errorsummary_24.csv; 对阈限判断校准的被试,

$$\varepsilon_{t,j} \sim \mathcal{U}(-a_{s,j}, a_{s,j}), \quad (55)$$

其中 $a_{s,j}$ 来自 Task1b_errorsummary_72.csv 的 threshold_mean_mean。所有参数都根据 Task2_processed.csv 中每名被试实际看到的四个特征顺序重排。当前自动分组把 101--124、201--224、301--324 归为 uniform 分支, 把 125--132、225--232、325--335 归为 normal 分支; 代码还预留 401--424 的 normal 编号。

该模块有清楚的外部测量来源, 但配对消融中关闭知觉噪声反而改善了大多数代表性被试的行为拟合。因此, 发表版不应声称它提高了选择拟合, 也不宜让它成为主模型不可分割的一部分。更稳妥的层级是: 主行为模型使用 $\tilde{\mathbf{x}}_t = \mathbf{x}_t$, 个体化噪声作为由独立知觉任务约束的 robustness model; 若它改善口头报告或跨任务预测, 可作为外部效度结果单独报告。

0.0.14 当前 V14 的数值配置与超参数空间

固定结构参数。 当前条件 1 V14 基础配置为: 4 个刺激维度、2 个类别、标签反转开启、原型距离、 $M_0 = M = 5$ 、动态 beta 参数

$$(5, 0.1, 25, \eta_- = 0.15, \eta_+ = 0.5, \lambda = 3),$$

控制器历史窗口 8、试次进程尺度 160、latent-state 衰减 0.8、阈值 0.55。默认 YAML 示例值为 $\gamma = 0.55$ 、 $w_0 = 0.06$ 、sharpened expectation $\rho = 2$; 这些只是未覆盖时的基础值, 并不是所有被试的最终最优参数。

被试层面的搜索坐标。 当前 V14 搜索以下三个坐标:

1. 25 个记忆组合: 5 个 γ 与 5 个 w_0 的笛卡尔积;
2. 24 个假设转移组合: 6 个控制器家族 $\times$ 4 个 latent-state 设置 $g \in \{0, 0.20, 0.35, 0.50\}$;
3. 4 个 readout: expectation、 $\rho = 2$ 、 $\rho = 4$ 与 MAP。

完整笛卡尔积名义上有 $25 \times 24 \times 4 = 2400$ 个组合, 但当前程序使用随机重启坐标下降而非穷举。

坐标下降与模拟预算。 每名被试运行 3 个随机重启, 每个重启最多 6 轮外循环; 每次重启随机打乱坐标顺序, 连续 2 轮没有至少 0.0005 的改善时提前停止。粗阶段对每个候选运行 128 次重复模拟, 细阶段运行 256 次; 固定参数的最终确认配置运行 1024 次。

所有同一被试内的成对模型使用 common random numbers, 使差异主要来自架构改变而非随机轨迹不匹配。

当前 V14 超参数 YAML 只列出 8 名代表性条件 1 被试 (103、105、111、112、117、118、127、131), 用于架构筛选和效应核验。它不能替代对全部 32 名条件 1 被试的最终重拟合, 更不能直接当作条件 2/3 的冻结参数。

0.0.15 行为损失、边际预测与轨迹校准

边际类别概率。 由于知觉、profile 选择、新假设抽样和部分 readout 均可能是随机的, 参数组合 Ω 对同一被试产生 R 条预测轨迹。正式评分先对重复模拟的类别概率取边际平均:

$$\bar{P}_t(C_i | \Omega) = \frac{1}{R} \sum_{r=1}^R \hat{P}_{t,r}(C_i | \Omega). \quad (56)$$

这回答 ``该模型总体给观测选择多少概率'', 而不是 ``大量随机运行中是否偶尔有一条特别像数据''。

Choice Brier。 主损失为多类别 Brier score:

$$\mathcal{L}_{\text{Brier}}(\Omega) = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \sum_{i=1}^N [\bar{P}_t(C_i | \Omega) - I(c_t = i)]^2. \quad (57)$$

代码同时报告 choice negative log-likelihood:

$$\mathcal{L}_{\text{NLL}}(\Omega) = -\frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \log \bar{P}_t(C_{c_t} | \Omega). \quad (58)$$

轨迹 CRPS。 对每个长度为 16 的滑动窗口, 记被试正确率为 y_j , 第 r 次模拟的预测正确率为 $\hat{y}_{j,r}$ 。经验 CRPS 为

$$\text{CRPS}_j = \frac{1}{R} \sum_{r=1}^R |\hat{y}_{j,r} - y_j| - \frac{1}{2R^2} \sum_{r=1}^R \sum_{r'=1}^R |\hat{y}_{j,r} - \hat{y}_{j,r'}|, \quad (59)$$

最终对窗口取平均。第一项惩罚与观测轨迹的偏离, 第二项奖励适当的预测分布宽度, 因此 CRPS 同时评价位置、离散度和校准, 而不只比较平均曲线。

目标次序。 当前 V14 首先最小化边际 choice Brier; 在相对容差 1%、绝对容差 0.001 内的候选再比较 trajectory CRPS, 后者使用相对容差 3%、绝对容差 0.002。旧版的 ``best 10% runs'' 只保留为诊断, 不再决定超参数。该规则防止随机性较大的模型仅凭少数幸运轨迹获胜。

0.0.16 口头报告的独立验证

口头报告发生在被试作出选择之后，因此默认比较的模型状态不是反馈后的 π_t^+ ，而是 choice-conditioned prior：

$$\pi_t^{\text{oral}}(h) = \frac{\pi_t^-(h)q_{t,h}(c_t; \beta_{\text{oral}})}{\sum_u \pi_t^-(u)q_{t,u}(c_t; \beta_{\text{oral}})}, \quad \beta_{\text{oral}} = 10. \quad (60)$$

这一状态吸收了被试已经作出的选择，但不吸收尚未出现的反馈。

中心报告。 若口头报告被编码为四维中心 $\mathbf{v}_t$ ，则对每个假设计算所选类别原型与报告中心的距离

$$d_t^{\text{oral}}(h) = \|\boldsymbol{\mu}_{h,c_t} - \mathbf{v}_t\|_2.$$

距离通过自适应 softmax 转为口头假设分布：以最小距离为基准，以“距离中位数减最小值”作为尺度；若该尺度为 0，则退回距离标准差；若所有距离相同，则在所有最近假设上均匀分配质量。

区域报告。 若口头报告为线性区域 $(A_t^{\text{oral}}, \mathbf{b}_t^{\text{oral}})$ ，代码在 $[0, 1]^4$ 中使用固定随机种子抽取 1,000 个点，计算报告区域与每个假设所选类别区域的 Monte Carlo intersection-over-union，并把非负 IoU 归一化为口头假设分布。

分布一致性。 模型分布与口头分布使用归一化 Jensen--Shannon similarity：

$$\text{JSSim}(p, q) = 1 - \frac{\frac{1}{2}D_{\text{KL}}(p\|m) + \frac{1}{2}D_{\text{KL}}(q\|m)}{\log 2}, \quad m = \frac{1}{2}(p + q). \quad (61)$$

对区域报告还计算 fuzzy IoU、fuzzy cosine、模型质量落入口头区域的比例、口头区域被模型覆盖的比例，以及两者的期望体积。由于口头报告完全不参与 Brier/CRPS 超参数选择，这些指标构成对潜在假设轨迹的独立约束。

0.0.17 主模型、亚组扩展与消融模型的发表版层级

根据修正因果时序后的 8 名代表性被试、每配置 256 次 common-random-number 重复模拟，保留某机制的收益定义为

$$\Delta = \text{Loss}(\text{删除机制}) - \text{Loss}(\text{保留机制});$$

$\Delta > 0$ 表示保留机制改善拟合。该核验用于决定架构层级，但不能替代全样本确认。发表版 v2 应采用以下分层。

配对消融效应的完整方向。 平均 Brier 收益依次为：动态 beta 相对固定 $\beta = 5$ 为 +0.0542 (8/8 被试改善)，有限动态 active set 相对 full-set 诊断为 +0.0285 (5/8)，灵活 readout 相对 expectation 为 +0.0233 (8/8)，删除 stable profile 的代价为 +0.0203 (6/8)，stubborn 为 +0.0048 (6/8)，conservative 为 +0.0031 (5/8)，而 aggressive 为 -0.0047 (仅 2/8 支持保留)。持续性 latent state 为 +0.0009，对应 CRPS 收益为 -0.0004；choice-informed transition 在实际启用它的 4 名被试中为 +0.0053，但 CRPS 为 -0.0067。双通道相对 fade-only 为 +0.0243，相对 static-only 却为 -0.0046。个体化知觉噪声为 -0.0046；排除初始化混淆后的标签反转为 -0.0161 (7 名可比被试中仅 1 名受益)。这些数值说明有限 active set、动态 beta、readout 灵活性和 stable 转移具有最明确的保留理由，同时也说明“代码中存在”不能作为其他分支进入主模型的依据。

通用主模型。

1. **有限活跃集合必须保留。**它是模型的认知理论前提，而不是与 full set 对等竞争的便利选项。full set 只能作为诊断消融。
2. **动态假设特异 beta 保留。**相对固定 $\beta = 5$ ，平均 Brier 收益约 0.054，8/8 被试改善；但仍需补做优化静态 beta 对照。
3. **灵活 readout 保留并统一参数化。**相对 expectation，平均 Brier 收益约 0.023，8/8 改善；建议用连续 ρ 统一 expectation、sharpened 和 MAP 极限。
4. **stable 转移机制保留。**删除 stable 的平均 Brier 损失约 0.020，6/8 被试受益，是四个 profile 中最稳定的结构贡献。
5. **条件 1 使用 19 个基础几何划分，条件 2/3 使用 116 个划分。**默认不加入标签排列副本。
6. **主行为模型以无知觉噪声和 static-only 作为简约起点。**前者由独立校准 robustness model 检查，后者与补齐端点后的双通道重新竞争。

需要重构后再进入主模型的部分。 Conservative 和 stubborn 的平均 Brier 收益分别约 0.003 和 0.005，效应较小但后者在 6/8 被试方向为正。下一实现应将二者合并为一个参数化的低探索状态，再与 pure stable controller 做配对比较；在此之前，当前四-profile 控制器属于可运行 V14，而不是已经冻结的最简发表版。

预先得定的亚组扩展。

1. choice-informed survivor/newcomer 得分只用于能独立识别的持续错误亚组；
2. 标签反转只用于预先定义的持续低于机会水平亚组；

3. latent volatility state 只用于有明确持续性波动证据的亚组；
4. aggressive profile 只作为特殊刷新机制单独检验，不进入通用控制器；
5. 个体化知觉噪声作为跨任务外部校准的稳健性模型；
6. 双通道记忆在补齐 $w_0 \in \{0, 1\}$ 后作为 static-only 的扩展。

仅作诊断的消融。 Full-set、fade-only、固定 beta、固定 expectation readout、去除 stable、关闭假设转移等模型用于回答结构必要性问题，不代表同等可信的心理架构。尤其是 full-set，即便对少数被试获得较低经验损失，也不能据此推断被试同时维持 19 或 116 个假设；它至多说明当前有限集合的具体转移规则对这些个体仍需改进。

0.0.18 跨条件推广时必须解决的实现问题

当前 state-based V14 的正式 YAML、代表性架构搜索和修正后效应核验均集中在条件 1。虽然 Partition 类已实现 116 个四分类划分，LikelihoodModule 也能处理 0、0.5、1 三层反馈，但把条件 1 的冻结参数直接复制到条件 2/3 并不构成有效推广。至少需要完成以下步骤：

1. 为条件 2 和 3 分别建立明确的模型结构、超参数与模拟配置，而不是依赖缺省的 $N = 4$ ；
2. 保持 M 为有限容量参数，绝不因 $|\mathcal{H}| = 116$ 而启用 full set；
3. 重新校准熵归一化，因为 $\log 116$ 会进一步压低当前 H_t 的数值；
4. 把条件 3 的类别家族定义为任务固定映射，而不是由每个假设的原型邻接关系重新定义；
5. 使动态 beta 的反馈更新与四分类错误反馈及条件 3 的家族反馈一致；
6. 明确四分类类别标签映射，但不使用 $4!$ 个全排列复制每个几何假设；
7. 在每个条件内独立搜索或层级估计 readout concentration、容量和记忆参数；
8. 使用条件特异机会水平（条件 1 为 $1/2$ ，条件 2/3 为 $1/4$ ）填充早期历史并计算校准指标；
9. 在全部被试上用独立或交叉验证的随机种子确认架构，而不是沿用 8 名条件 1 代表被试的局部结论。

0.0.19 可复现性记录与最低报告要求

正式论文和补充材料至少应报告：

1. 每个条件的完整假设数、活跃容量 M 、是否包含标签排列，以及每类几何划分的计数；
2. 逐试次模块顺序，并明确 π_t^- 与 pre-feedback β_t 用于预测；
3. 所有固定参数、被试层面搜索空间、端点、重启数、停止规则和模拟重复数；
4. 每名被试最终选择的控制器家族、readout、记忆参数、state 设置与随机种子；
5. 边际 Brier、NLL、trajectory CRPS，而不是只报告最好若干随机轨迹；
6. 主模型、亚组扩展和消融模型的预先区分；
7. 口头报告未进入拟合，并说明其与 choice-conditioned prior 的时间对齐；
8. 对条件 2/3 的多类别 beta 更新、家族反馈与熵归一化所采用的最终修正；
9. 对动态 beta 与优化静态 beta、static-only 与完整 w_0 网格、无噪声与知觉校准模型的配对确认结果。

综上，模型的最小理论核心不是“把所有可能改善拟合的模块同时叠加”，而是一个容量受限、因果更新的动态假设系统：学习者在任务定义的几何假设空间中维持少量活跃规则；过去反馈控制规则的保留与替换；当前刺激、选择和反馈在活跃集合内形成贝叶斯证据；假设特异 beta 控制每条规则的决策锐度；一个可参数化的 readout 把内部规则信念转化为外显选择。记忆混合、知觉噪声、标签反转、choice-informed transition 和持续性潜在状态只有在独立证据和全样本复核支持时，才作为有边界的扩展进入最终模型。