

Model 0826 Plus: 怎样拟合, 怎样检验

从个体参数搜索到可信的行为与规则解释

内部工作说明

2026年9月20日修订

现在采用什么流程? 每个人先做有覆盖的搜索, 再按问题分配计算: 还在找到更好的参数, 就继续找; 参数的得分分不清, 就提高评分精度; 碰到人为范围边缘, 就记录范围问题。**追加都有上限, 到顶仍不清楚就如实保留不确定。** 算完和各项检查通过分别记录, 不要求每个人都算到通过。

本文说明 Model 0826 的默认拟合入口及其解释边界, 认知方程仍由 `model_0826.tex` 定义。当前采用有预算上限的 v2 工作方案, 保持现有共同参数范围。九人完整拟合及定向检查已结束; 接下来复用兼容的九人原结果, 准备运行剩余87人。**方案固定, 不代表所有人的参数都已稳定或唯一。** 本次只完成准备, 尚未启动剩余被试; 旧配置和旧文档均保留。

1 先分清三件事: 找参数、算得分、看状态

搜索覆盖决定有没有到过较好的参数区域; 评分精度决定能否分清候选的高低; 状态精度决定最后画出的内部过程是否稳定。三者不能互相替代。

粒子滤波 (particle filter, PF) 用有限样本近似模型内不可见的随机过程。粒子数 R 是一次计算保留多少条可能过程; 重复数 B 是用多少组独立随机种子重算。二者是计算预算, 不是人的工作空间容量或学习次数。很多次低粒子运行不自动等价于一次高粒子运行。

S129 曾在低预算搜索后明显落后于历史候选, 问题是搜索覆盖不足; S229 的固定参数也曾有较大评分波动, 问题是数值精度。进一步搜索和增加粒子各有用途, 不能一律给所有人增加相同预算。

2 默认拟合怎样执行

2.1 第一步: 分散起点, 保留不同的较好候选

同一条件使用一致的数据约定、参数支持和评分方式。默认从45个分散起点开始, 覆盖当前九种容量/执行组合, 并使记忆、搜索和精度参数也变化。发现候选用 $R32 \times B4$; 较好、较分散以及少量随机抽查的候选再用 $R128 \times B16$ 比较。后续起点由后者决定, 不能把不同预算的分数混排。

低预算筛选仍可能遗漏好参数。随机抽查和分散候选只降低这个风险, 不能证明没有遗漏。默认数值是有上限的工作设置, 不是对所有被试都足够的定理。新入口直接读取当前数据与引擎, 不依赖旧试点目录或历史赢家。

2.2 第二步: 既单独调整, 也同时改多个参数

普通坐标下降每次只改一个参数块。假设当前分数是10, 只改A得11, 只改B得12, 同时改A和B却得8, 那么单块下降会停住, 联合移动可以直接到8, 不需要先接受11或12。

已有 (M, χ) 、 (E_C, δ_E) 和 (g_0, c_G) 联合块。新流程另外尝试跨块移动: 局部调整、整块远跳以及同时改变两个块, 并从多个较好候选继续。每轮还加入分散新点, 以覆盖需要更多参数共同

改变的区域。参数关系始终保持合法，例如 E_E 随 E_C, δ_E 推导，不被当成另一个独立坐标。

默认每轮至多两个起点、每个48个提案，局部/整块/跨块预算比例为25%/25%/50%，另提议18个分散点，重复点不重算。比例是提案配额，去重后实际数量可减少。有限联合移动不能保证全局最优。

2.3 第三步：准备停止时，检查还有没有可靠改善

默认最多四轮常规追加；连续两轮的引导评分改善不超过平均 NLL 0.001，记为平台。到达轮数上限不等于平台。

随后做一轮联合挑战，另提议90个分散点，并对最多两个近优边界候选各追加4个混合提案和4个方向提案。边界点本来就全部进入引导评分，因此省去它们无用的低预算评分。挑战前代表、挑战后代表和最终提名代表在独立检查前冻结；不同角色可以是同一个点。

只用一层新的独立种子，同时回答两个问题：最终提名相对复核库最佳者的平均 NLL 损失，是否已小于0.005；挑战是否带来了超过0.005的可靠改善。复核库保留常规搜索前4名、挑战前4名和必要代表。不要求把两个明显较差候选的差异也算得很准。

独立检查从 $R128 \times B16$ 开始。尚未确定需要重搜且评分仍分不清时，升到 $R256 \times B32$ ；通过后不再强制另做一遍全库复评。同一批概率回答两个问题，所以不是两份独立证据； $\alpha = 0.05$ 按两个问题、两个预算档和最多两个循环预分配，每项每次0.00625。

只有挑战被独立确认有实用改善、提名代表被确认较差，或常规搜索仍未出现平台，才开启下一个搜索循环，最多两循环。引导评分的一点改善不自动触发重搜。用已见审查结果指导下一轮可以，但下一轮必须换新的审查种子；不能在同一批审查里换赢家后称其独立通过。数值不确定到顶时保留 unresolved 和近优候选。

这些调整不改认知方程，但会改变搜索覆盖和最终估计；首批完整验收仍发现未解决项。单独省去必选边界点的低预算评分，则不改变该点的引导分数。

2.4 第四步：碰到参数边缘，先区分是哪一种边缘

参数	当前初始支持	边缘如何解释
M, χ	$M = 1, \dots, 5; \chi = 0, 1$	$M = 1$ 只留 $\chi = 0$ ； $M = 5$ 是人为上限
γ	0--0.97	上限需复核；1表示关闭额外遗忘
E_C, δ_E	0.02--0.75；0--3.2	联合检查； $\delta_E = 0$ 是有意义的机制边界
g_0, c_G	0--1	自然定义域，到端点不自动向外扩展
c_A	0--6	0允许关闭累积增益；6是人为上限
β_0	0.5--20	位于固定动态边界0.1--25之内
η_+, η_-	0.005--0.32；0.01--1	正值下限与 η_+ 上限需复核；零值另定义消融

表中是离散搜索表的范围，不表示任意连续值都已搜索。范围仍是共同工作设置，尤其 condition 3 不能因沿用相同取值而视为已校准。触边可能来自范围限制，也可能来自多套参数相互补偿，不能仅凭次数决定扩大范围。

默认先检查代表及得分接近的候选。自然边界保留解释；人为边界若没有预先配置的扩展点，就标记 boundary_review_required。当前扩展配置为空，因此默认边界提案仍在原支持内，不能代替范围外检查。确需扩展时，应先共同声明合法取值、比较方式和计算上限；边缘参数可以与其他块联合改变。不同被试使用同一套允许范围，追加工作量可不同；触边本身不触发无限重搜。

不能为消除触边而删被试、强迫零值为正、无限扩大网格或改变固定常数。扩大 β_0 的搜索范围与改变 $\beta_{\max}$ 不是一回事，后者直接改变动态更新方程。默认入口不修改固定认知设置，也不自动给所有参数加先验或惩罚。

2.5 第五步：交付代表参数、近优候选和诊断

只有搜索出现平台、联合挑战未留下可靠改善、选参精度通过独立复核、人为边界检查没有待解决项时，才记为“在本次已检验范围内暂时停止”。其他情况保留参数和候选库，但明确记录预算上限、评分波动、挑战改善或边界问题。

目前入口交付选参结果、逐试次选择概率及诊断，不自动宣称最终心理状态已可靠。规则信念、活跃概率与执行轨迹应在固定参数下另行生成并检查精度。多个近优参数的状态解释不同，也需要保留；增加同一个点的粒子不能消除参数之间的差异。

3 九人结果告诉我们什么

首批六人完整拟合耗时11.74小时，冻结规则后的三人核查耗时5.27小时。它们检查流程能否执行、什么时候该停以及计算成本；不代表群体参数已得到验证。九人的原始整库独立评分通过4人，严格整体停止为0人：所有人仍有原始人为边界标记，S118还未形成搜索平台。

condition	可复用的原拟合	需要一起保留的原始诊断
1	S102、S118、S122	三人独立评分通过；S118搜索未形成平台；三人触边
2	S206、S221、S222	S206评分通过，另外两人评分不确定；三人触边
3	S307、S314、S315	S307原提名被判较差，另外两人评分不确定；三人触边

后续定向检查另行附上，不能覆盖这张原始记录。S221/S314在固定两点的复核中通过，不等于原来整库审查通过；S307的固定三点即使追加至 $R256 \times B64$ 仍不确定，也没有回答全部参数搜索问题。

最新范围检查保留S122/S222/S315每人的全部8个原入围点，并加入容量、记忆、事件概率和更新率等单独或联合变化，共55点、1760次PF、约86分钟。S122和S315的原范围内已有候选能在容差内媲美本组外侧点；S222仍不确定。三人的最佳内侧损失上界分别为0.000937、0.005139、0.004053，门槛预定为0.005。没有可靠的实质改善证据要求扩大共同范围，**但这不是所有范围外组合都无用的证明。**

S222/S315只增加旧缓存的bootstrap次数，原评分不确定性仍未消除。因此本轮按上限结束，保持共同范围和默认预算，保留近优多解与未解决项。数值检查的门槛不因接近通过而放宽，原三人的整体状态也不改写。

详见：[results/model_0826/frozen_boundary_check_20260920/report/README.md](#)

S129 后续仍有两套参数几乎同样好：每试次 NLL 约0.50512和0.50565，255个计分试次的总差约0.134。它们可以保留为近优解释，不能据此挑一套宣称唯一心理参数。两套预测也并非完全一样：平均概率差约1.93个百分点，内部状态尚未比较。

详见：[results/model_0826/precision_followup_20260919/README.md](#)

0.005是探索性实用容差，不是普适统计标准。S229有1087个计分试次，它对应总 NLL 约5.44；关心更小模型差异时必须收紧。重采样完整PF种子得到的区间只描述固定数据、候选库及有限粒子下的数值波动，不是心理参数置信区间，也不证明粒子积分收敛。

Task 1/2/3 对应 condition 1/3/2。Condition 2 的二值错误反馈不能推出唯一正确类别；condition 3 使用三值反馈和未知反应配对学习，不能用 condition 2 引擎代替。当前默认入口支持这三个条件的PMH选择拟合；condition 3 的联合状态精度、恢复和标签支持审计尚未完成。exp4/exp5 不由此入口隐式开放。

等价缓存、似然合并和并行属于工程加速。改变候选、粒子或种子属于估计方案调整，可能改变拟合参数；两者都不在这里改写认知方程。采用新入口不表示旧恢复配置或旧Hyper-CD记录被改写。

4 读懂拟合结果：得分好不等于内部过程已被证明

4.1 我们到底在给什么评分

对同一参数点，先把 B 个 PF 重复的逐试次概率平均，再取对数：

$$\bar{p}_t(c) = \frac{1}{B} \sum_{b=1}^B \hat{p}_t^{(b)}(c), \quad L(\theta) = -\frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \log \bar{p}_t(y_t). \quad (1)$$

NLL 越低，模型给实际选择的概率总体越高。这里不是先分别求每次 NLL 再平均，也不是选择最贴近数据的一条潜在路径。

当前约定保留完整 trial 序列递推，但首次试次不进入默认评分掩码。因此 S129 的256个试次中有255个计分，S229 的1088个中有1087个计分。原始时间顺序、session/block边界和反应编码保持不变；不能为了稳定分数删掉高波动试次。

每次选择必须由作答前状态预测，再用已观察的选择与反馈更新状态。即使每一步递推严格遵守时间顺序，只要参数用整段数据拟合，成绩仍然是样本内拟合。独立 PF 种子只使计算复核独立，不会让同一份行为数据变成留出测试集。

4.2 规则信念、活跃概率与完整路径不要混用

规则信念表示各规则获得多少支持，归一化后总和为1；活跃概率表示规则进入工作空间的可能性，其总和通常等于容量。两者不能相互替代。持续执行结构 $\chi = 1$ 下还有执行规则； $\chi = 0$ 的信念混合读出没有这个变量。不能把最大信念规则的变化直接称为被试的执行切换。

作答前状态只使用此前信息；过滤后状态吸收了当前选择，需注明是否也已吸收反馈；利用整段记录回溯的祖先路径还使用了后续信息。这些输出回答不同问题，图和分数要使用一致的信息时点。最佳完整路径适合辅助解释，不能每个试次挑一条不同的路径拼成“真实认知过程”。

较稳定的平均 NLL，也可能对应不同的规则信念或内部策略。所以结果应分开回答：选择预测是否稳定、参数是否近似等价、状态解释是否一致。真实被试没有已知的心理状态真值，历史拟合也只能作为参照，不能当作真值。

5 拟合完成后，还需要哪些证据

5.1 行为：分开检查拟合、留出预测与自主生成

样本内检查用于发现问题：学习曲线、类别偏向、错误模式、逐类别概率和极低概率选择。正式泛化分析需按时间前缀拟合，在共同后缀评价冻结参数；比例应提前确定，不能随机打乱学习 trial。若预测后继续吸收已发生的后缀选择与反馈，应称为固定参数的在线一步预测。

主比较以同一被试、同一评价试次的 NLL 差为单位，同时使用均匀、类别偏向及适当的简单学习基线。不同类别数下先做任务内比较，不直接把二分类和四分类的原始 NLL 排名解释为模型优劣。群体结果每个点代表一名被试；PF种子、重叠滑窗和时间段不能冒充独立被试。失败或未稳定的个案也需要报告，不能只展示成功例。

5.2 恢复：能找回什么，就解释到什么程度

用模型自己生成的选择与反馈建立已知真值，再重新拟合。分别检查模块架构、执行结构、连续参数和潜在状态；其中一项通过不代表其余都通过。生成轨迹不能先平均成一个虚拟被试，每条轨迹应独立拟合。

参数恢复还要检查边界堆积、零值与正值混淆，以及参数之间的补偿。状态恢复需在相同信息时点比较规则信念、活跃集合、执行与切换。若多种状态产生近似相同选择，应报告不可区分

范围，不把其中一条当作唯一心理解释。现有恢复设计和已生成数据不等于完整恢复结论已经成立。

5.3 口述：检验它是否增加选择之外的信息

口述没有进入当前选择目标函数，但规则目录和编码开发曾参考口述，因此应保留开发与验证来源记录。正式分析冻结编码尺度和规则目录，明确有效新报告、缺失、不可解析与沿用历史报告之间的区别。当前报告在作答后、反馈前，模型状态的对齐时点也应事先确定。

可以比较完整规则目录上的模型分布 $q_t(h)$ 与口述分布 $o_t(h)$ ：

$$O_t = \sum_h \min\{q_t(h), o_t(h)\} = 1 - \frac{1}{2} \sum_h |q_t(h) - o_t(h)|. \quad (2)$$

重叠接近1说明两种分布接近，不等于规则识别准确率，也未自动扣除机会一致性。仅仅提到同一个特征，或两者都不支持目标规则，也不能证明双方采用同一条规则。

需要与静态偏好、共同刺激和选择所能解释的对应关系，以及保留时间结构的零模型比较。主评分使用固定完整目录；仅在模型活跃集合内重归一化口述会改变比较问题。在选择拟合近似相同的候选之间，口述能否进一步区分，是更直接的附加约束检验。若用某批口述挑选模型，就需要新的留出报告或将结论明确标为探索性。

5.4 自主生成与模型比较：让解释接受更强的挑战

自主生成需要模型自己选择，环境据此给反馈，再由模型自己的历史更新。继续输入真实人的选择与反馈是条件化重放，不是自主生成。比较多条完整生成轨迹中的学习平台、改善、反转、持续错误和达到学习标准的时间分布，不能只挑最像人的一条。有限日程结束仍未达标时，要记录删失，不能当作真实完成时间。

P、PM、PH、PMH 比较用于检验记忆与工作空间搜索的贡献；P 仍包含信念学习和动态规则精度，不能称为没有学习。四种结构都保留动态精度，因此要证明动态精度本身有贡献，还需专门对照。各模型应独立重拟合，采用共同评价集和对等的计算质量。固定完整模型参数后关掉一个模块，只是敏感性检查，不能代表简化模型能达到的最佳表现。

模型内“错误累积后搜索增多”部分由方程决定。要解释人的机制，还需独立口述变化、未来行为或其他测量的约束。拟合、消融和事件相关本身不构成人类心理过程的因果证明。

6 论文里怎样呈现

Fig2 的工作顺序为：a 说明模型怎样形成选择，b/c/d 展示 condition 1/3/2 的个体过程，e 检查共同评价集上的推广，f 检查口述能否增加选择之外的约束，g 比较核心结构。全部个体、停止诊断、预算敏感性和恢复等覆盖性证据放入补充材料；关键证据在正文给出摘要。图必须注明预测与状态时点，每个群体点对应一人，保留未解决个案。三任务不能用相同规则编号或拉伸后的 trial 轴制造可比性；这些分工不表示正式结果已经齐备。

7 默认入口、执行顺序与复现记录

先检查，再启动。入口为 `python -m src.Bayesian_state.run_model_0826_fit`。默认配置为 `configs/exp123/specific_models/model_0826_adaptive_fit.yaml`。用 `--dry-run` 核查条件、被试、范围和预算；用 `--subjects 103 --smoke --output-dir NEW` 作单被试短序列检查；正式运行去掉 `--smoke` 并指定新的输出目录。`--resume` 只继续同一份配置、数据、代码和数值环境的运行。显式指定后缀为 `_v1.yaml` 的配置可使用原两层检查规则；默认配置现为 `schema 2`。

全体第一轮按以下顺序推进。先核查已有九人的数据、源码、环境、种子、支持和缓存；兼容结果按原参数与原状态保留。可复用表示无需重复同一工作，不表示诊断已经通过。后三人的配置只在报告名称上不同；新增的独立诊断入口不改变拟合算法，但旧目录的严格续跑仍需当时源码清单，不能改旧哈希强行续跑。

三个condition各32人，已各有3份兼容完整拟合，因此各剩29人，共87人。具体清单、输入指纹和可执行命令保存在本次准备目录。新任务另建目录，只拟合这87人，不把旧诊断的范围外点或新赢家混成统一流程的正式结果。已有九人用于开发或诊断，不能再称为独立行为验证样本。

详见：[results/model_0826/cohort_preparation_20260920/README.md](#)

全体完成后，先汇总每人的原代表、近优候选、评分精度、搜索平台、挑战与边界问题，再检查任务内学习曲线、选择偏向和错误模式。全部被试都保留，按诊断分组作敏感性分析，不能删掉不确定者后只报好看的结果。只有群体结果显示某个问题反复且实质影响结论时，再提出有上限的定向补算。

解释心理参数前做参数恢复；预测推广需另按时间前缀拟合和后缀评价；内部轨迹需另查状态精度。没有通过的参数可用于带标记的描述，不能当作稳定心理差异。exp4/exp5和condition 3消融仍属后续独立工作。

按各条件单位试次成本外推，全部96人约6.9天，低/高成本情景约6.0--7.6天；不含未解决项、范围扩展、状态和恢复的补算，也不是时限保证。仍有待检验的精简空间：例如提名已通过、仅挑战比较不清时，只给挑战双方增加评分。本轮没有v1配对运行，不报告提速倍数。

正式运行最多128个进程、每个一个数值线程，跨被试、候选和种子调度，只有一层进程并行，不预留核。就绪任务不足时不增加无必要计算。smoke仅用1进程、1人、32试次的小预算检验管线。

运行保存输入与源码指纹、候选来源、预算种子、计分掩码、逐轮改进、独立审查、边界和停止原因。旧结果不覆盖；续跑复用完整缓存。独立检查未通过时，不输出标为正式稳定的心理轨迹。

入口与证据：模型定义；拟合入口与配置；历史试点命令；选参精度与平台挑战；搜索与评分波动；六人验收与成本；全体拟合方案与复用约定；恢复设计。