Model 0923：有限候选与反馈学习

以认知模块为线索的完整模型说明

2026年10月13日：完整参数搜索与逐被试评估

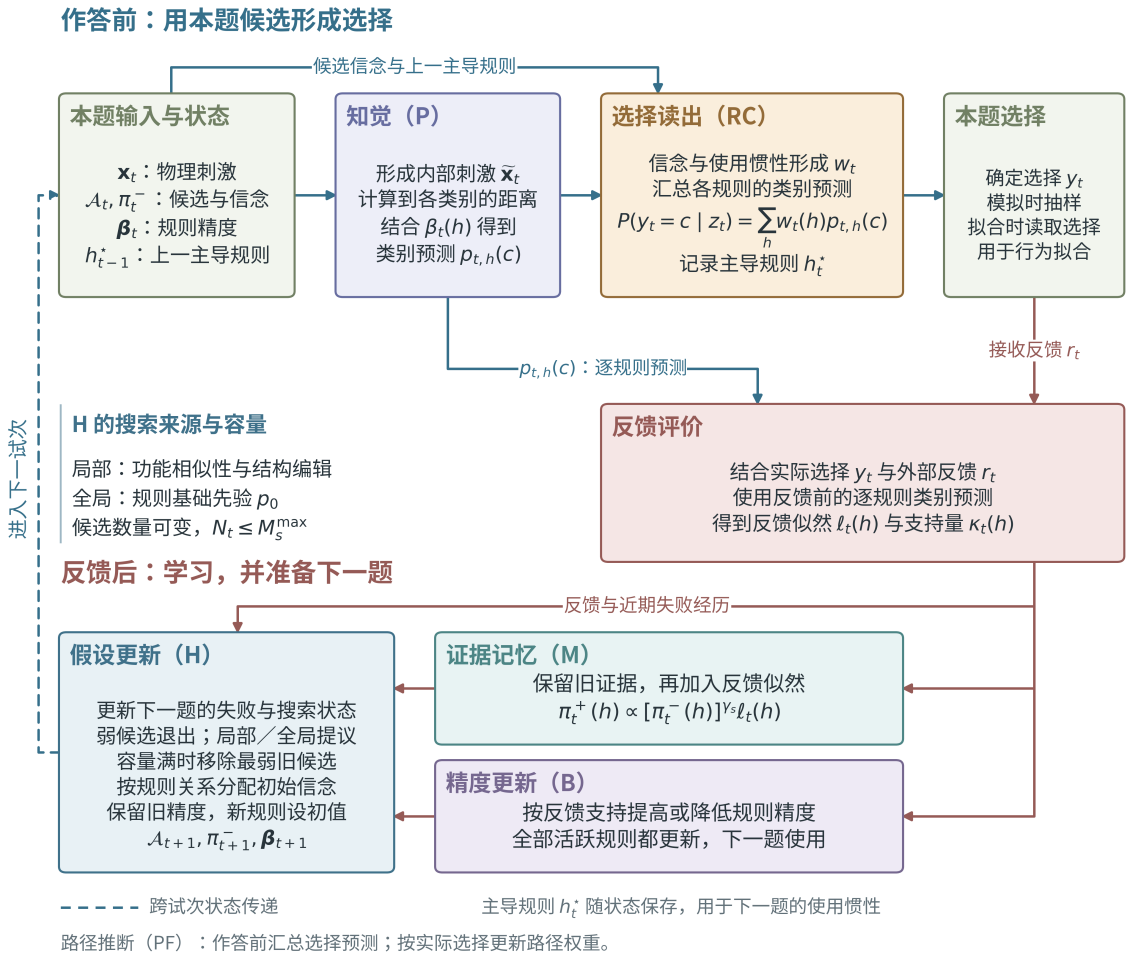


图 1: Model 0923 的机制总览。知觉模块形成内部刺激，各条规则的类别预测供选择读出和反馈评价共用。选择读出汇总作答概率。收到反馈后，证据记忆与精度更新并行调整规则信念和预测精度，假设更新为下一题准备候选。虚线表示跨试次状态传递。选择数据用于估计参数和更新粒子权重。图中 κ 表示反馈对数似然对精度的梯度，定义见第6节。图中反馈更新以二值任务为例，条件3的配对学习见第8节。

本文给出 Model 0923 的修订设计。目标是用简洁、容易解释的机制，保持0826的行为预测能力。候选管理、连续作答权重、单学习率精度校准及条件3的分层遗忘已在共享模型核心中以 `0923-full-v3` 接入。2026年10月12日修订统一了三种反馈条件的精度更新，并规定条件3的规则信念与条件配对信念分别遗忘、分别归一化，行为参数共13项。2026年10月13日补充第11节的完整参数搜索、独立数值审查、边界与停止规则，沿用 Model 0826 Plus 的有界工作流程。已有12人完成初始有限预算搜索及后分析；第12节规定固定参数后的逐被试评估步骤与报告契约，完整参数验收、参数恢复和行为生成验收继续分别记录。配置入口与运行步骤见Model 0923 实现与运行说明。

正文先介绍任务、规则表示和证据更新，再说明各认知模块怎样完成一次学习过程。第5节统一说明假设更新模块的搜索与候选管理，第7节说明选择读出。被试参数在同一被试内保持不变，状态随试次递推。

行为参数由选择数据估计。规则信念由反馈更新，粒子权重按实际选择更新。

目录

1 模型概述：几个认知模块怎样一起工作 3
2 任务输入、规则目录与潜在状态 4
3 知觉模块（P）：从刺激到规则预测 6
4 证据记忆模块（M）：根据反馈更新规则信念 7
5 假设更新模块（H）：搜索与候选管理 7
6 精度更新模块（B）：调整规则预测的明确程度 13
7 选择读出模块（RC）：从规则权重到类别选择 15
8 条件3：层级反馈与配对学习 17
9 单试次顺序：哪些信息何时使用 19
10 粒子滤波：推断可能的内部路径 20
11 个体参数估计：估计什么，怎样评价 21
12 个体评估：固定参数后逐人检查什么 24
13 从模块状态到认知机理解释 27
A 四分类目录的完整分组 28
B 辅助符号索引 29

1　模型概述：几个认知模块怎样一起工作

模型假设，学习者每次只考虑少量规则。他可能同时保留“看脖子长短”和“比较脖子与尾巴”这两种解释，却在当前题主要使用其中一条。收到反馈后，他会重新评价这些解释，也可能想到一条新规则，或不再考虑某条弱规则。候选数量可以变化，容量只规定最多能同时保留多少条。

规则信念表示“在当前候选中，更相信哪条”；作答权重表示“本题判断受哪条影响较多”；规则精度表示“按这条规则判断，类别预测有多明确”。作答权重由信念和上一题的主导规则共同形成，权重分散时多条规则共同影响回答，集中时一条规则主导回答。精度越高，单条规则的类别预测越集中；这条规则是否可信，仍由反馈评价。

学习者先作答，之后收到外部反馈。模型根据这次反馈更新规则信念和精度，并为下一题准备候选。

模型按功能分为知觉（P，perception）、证据记忆（M，memory）、假设更新（H，hypothesis updating）和精度更新（B）四个模块。B 对应精度参数 β。选择读出模块（RC，choice readout）将各规则的类别预测汇总为选择概率。各模块的职责如下。

模块	处理的问题	主要输出
知觉（P）	形成怎样的内部刺激？各条规则怎样预测类别？	内部刺激 $\tilde{\boldsymbol{x}}_t$；类别概率 $p_{t,h}(c)$。
证据记忆（M）	反馈怎样改变候选的可信程度？	反馈后信念 π_t^+；条件3还更新配对信念。
假设更新（H）	何时搜索？哪些规则进入或退出候选集合？	失败状态 F_{t+1}、搜索概率 e_{t+1}、全局比例 g_{t+1}；下一题候选 $\mathcal{A}_{t+1}$ 及信念 π_{t+1}^-。
精度更新（B）	怎样调整预测的明确程度，使规则更好地解释反馈？	更新后的规则精度 $\beta_{t+1}(h)$。
选择读出（RC）	各候选对本题作答有多大影响？选择概率是多少？	作答权重 w_t、主导规则 $h_t^\star$ 与选择概率 $P(y_t = c \mid z_t)$。

模型统一命名为 `model_0923`，完整模型称为 full model。后续消融名称按保留的 P、M、H、B 模块组合，例如 PMH；RC 的设置随配置说明。每种消融还需规定被去掉模块的固定设置和状态处理。完整模型的学习结构为 PMHB，当前运行入口为 full。

选择读出使用本题内部刺激、规则预测和作答权重，得到的选择概率用于行为拟合。

粒子滤波（particle filter，PF）用于推断这些隐藏过程。每个粒子代表一条可能的内部学习路径。把多条路径的预测按权重汇总，可以同时计算行为预测和内部状态的不确定性。

2　任务输入、规则目录与潜在状态

2.1　每题输入什么

对被试 s 的第 t 题，物理刺激、实际选择和外部反馈分别记为

$$\boldsymbol{x}_{s,t} \in [0,1]^4, \qquad y_{s,t} \in \{1,\dots,C\}, \qquad r_{s,t}. \tag{1}$$

四维刺激记录四个部位的归一化长度，按该被试任务的实际特征顺序排列。

条件1为二分类二值反馈，$C = 2$，$r_t \in \{0,1\}$；条件2为四分类二值反馈，$C = 4$，$r_t \in \{0,1\}$；条件3为四分类三值反馈，$r_t \in \{0, 0.5, 1\}$。下文省略观测量和状态量的被试下标 s，被试层面参数始终保留 s。

实际选择用于计算行为分数和修正粒子权重，选择与反馈随后用于被试模型的学习。反应时不进入本版模型。

运行入口在模型执行前跳过标记为 `miss=1` 的漏答记录。本版的学习步按有效作答试次递推，漏答期间不执行知觉、搜索或反馈更新，下一条有效记录延续已有状态。输出保存原始试次标识，以便与行为和MEG时序对应。

搜索和学习根据历史反馈与候选状态进行。真实类别用于环境评分和结果评价。条件3从三种配对等可能的初始信念开始学习。

2.2　固定规则目录

目录记为 $\mathcal{H} = \{1,\dots,J\}$。条件1有29条规则：

规则形式	判断例子或边界	数量
单特征阈值	$x_i \le 0.5$，按某个部位的长短分类。	4
两个特征的顺序	$x_i \le x_j$，比较脖子和尾巴。	6
两个特征的和	$x_i + x_j \le 1$。	6
两组特征和的顺序	$x_i + x_j \le x_k + x_l$。	3
两个特征是否接近	$\lvert x_i - x_j \rvert \le 0.10$。	6
单特征是否在中间	$\lvert x_i - 0.5 \rvert \le 0.10$。	4

条件2和3使用152条四分类规则，包括两个判断的交叉组合、条件分支、最大／最小特征，以及共享判断特征的组合。完整分组见附录A。其中，有12条规则围绕同一个部位做两次比较，例如同时判断脖子是否比腿长、是否比尾巴长；另有12条规则先判断两个部位是否相近，再判断第三个部位的长短。相近的容差为0.10，第三个部位的长短分界为0.5。三条件分别使用与各自类别数相匹配的规则目录。

每条规则的类别区域及标签固定。目录定义模型允许考虑的解释范围；被试当前考虑的规则由候选集合表示。

基础先验 p_0 表示尚无学习证据时各条规则被考虑的概率，在相应目录内均匀：

$$p_0(h) = 1/J, \qquad h \in \mathcal{H}. \tag{2}$$

它为初始候选、全局搜索和按功能相似性进行的局部搜索提供基础权重，各被试使用同一目录定义。

2.3 容量上限与初始候选

容量参数为 $M_s^{\max}$，实际集合为 $\mathcal{A}_t$，数量为 N_t：

$$\mathcal{A}_t \subset \mathcal{H}, \qquad N_t = |\mathcal{A}_t|, \qquad 1 \le N_t \le M_s^{\max}. \tag{3}$$

实际候选数量随学习过程变化。第一题从 p_0 抽取一条规则，令 $\mathcal{A}_1 = \{h_1\}$，由它作答。要求整数 $2 \le M_s^{\max} < J$，以允许旧候选和新规则同时保留，并使目录中存在非活跃候选；实际数量仍可以为1。

只保留一条候选时，其候选内信念为1，表示当前的相对信念全部集中在这一个解释上。它的精度继续根据反馈调整，近期失败也继续影响后续搜索。因此，模型可以从一条候选开始，并在需要时考虑新规则。

2.4 需要保存哪些状态

候选、信念和精度等内部量无法从行为中直接观察，统称为潜在状态。每条内部路径保存一组可能的状态；作答前状态记为

$$z_t = \big(\widetilde{\boldsymbol{x}}_t, \mathcal{A}_t, \pi_t^-, F_t, \boldsymbol{\beta}_t, h_{t-1}^\star, \Pi_t^- \ \text{（仅条件3）}\big). \tag{4}$$

其中，内部刺激记录本题被知觉到的特征；候选集合与信念记录当前考虑哪些解释，以及各解释的可信程度。失败状态汇总此前反馈，精度向量保存各规则的预测精度，上一题主导规则用于计算使用惯性。条件3还保存规则与配对方案的联合信念 Π_t^-，详见第8节。

π_t^- 在活跃集合内归一化，非活跃规则的信念为0。上一题主导规则可能已退出当前集合；第一题尚无上一主导规则，惯性加成统一为1。模型由这些状态计算本题作答权重 w_t 和主导规则 $h_t^\star$。

2.5 符号约定与阅读方法

下标 t 表示试次，s 表示被试，j 表示刺激特征，h 表示规则，k 表示条件3的配对方案。参数保留被试下标，状态和观测省略这一层下标。粗体表示向量，花体表示集合；附录B集中列出各模块的辅助符号，个体参数见第11节。

规则信念的上标用于标明时点或处理阶段：$-$ 表示候选管理完成后的作答前信念，$+$ 表示本题反馈更新后的信念，ret 表示退出处理后，keep 表示容量处理后。后两个量都是从第 t 题走向第 $t+1$ 题时的中间结果。这些上标均为标签。

符号	含义
$\boldsymbol{x}_t, \widetilde{\boldsymbol{x}}_t$	物理刺激与知觉形成的内部刺激。
y_t, r_t	实际选择与外部反馈。
$\mathcal{H}, J, C$	完整规则目录、规则总数与类别总数。
$\mathcal{A}_t, N_t, M_s^{\max}$	活跃候选集合、实际候选数与被试容量上限。
$\pi_t^-(h), \pi_t^+(h)$	作答前、反馈后的相对规则信念。
$\pi_t^{\text{ret}}, \pi_t^{\text{keep}}$	退出后、容量处理后的旧规则信念，各自在对应集合内归一化。
$\beta_t(h), p_{t,h}(c)$	规则精度，以及该规则给类别 c 的预测概率。

符号	含义
$\ell_t(h), \kappa_t(h)$	反馈似然，以及反馈对数似然对精度的梯度。
f_t, F_t	本题失败程度，以及进入本题的累计失败状态。
e_t, g_t	搜索启动概率，以及搜索发生时采用全局来源的概率。
$w_t(h), h_t^\star$	规则的作答贡献，以及贡献最大的主导规则。
$\Pi_t^{\pm}(h,k)$	规则与配对方案的联合信念。
$q_t^{\pm}(k \mid h), \bar{q}_t^{+}(k)$	给定规则的条件配对信念，以及反馈后的整体配对信念。
$z_t, \boldsymbol{\theta}_s$	一条内部路径的作答前状态，以及被试行为参数向量。
$N_{\mathrm{PF}}, W_t^{(n),\mathrm{pre}}$	粒子数，以及第 n 条路径的作答前权重。

π_t、w_t 和 $W_t^{(n),\mathrm{pre}}$ 分别描述规则可信程度、规则作答贡献和研究者对内部路径的权重。前两者在一条路径内部定义，粒子权重用于汇总多条路径的预测。

3 知觉模块（P）：从刺激到规则预测

知觉模块将物理刺激转为带有误差的内部刺激。随后，各条规则结合自己的精度，给出类别预测。这些预测供选择读出和反馈评价共同使用。

3.1 形成带有误差的内部刺激

同一物理刺激在不同试次可以引起略有差异的知觉：

$$\widetilde{x}_{t,j} = \mathrm{clip}(x_{t,j} + \varepsilon_{t,j}, 0, 1). \tag{5}$$

$\mathrm{clip}(v,0,1) = \min\{1, \max\{0, v\}\}$ 将内部刺激限制在合法特征范围。误差参数来自学习任务前的独立知觉测量，并按实际特征顺序排列。当前个体化配置通常使用测量得到的逐维正态误差；共享模块也允许按测量定义使用均匀误差。具体分布与参数以运行配置为准。

各条规则使用本题的同一内部刺激形成预测。粒子分别模拟可能的知觉结果，随机流独立且可复现。

3.2 单条规则怎样给出类别概率

规则 h 将刺激空间划分为类别区域 $\mathcal{C}_{h,1}, \ldots, \mathcal{C}_{h,C}$。每个区域包含按该规则会被分到同一类别的所有刺激。例如，以脖子长度0.5为界的规则，把脖子不超过0.5和超过0.5的刺激分别划入两个区域。

距离表示当前内部刺激至少改变多少，才能进入某个类别区域。模型计算到各区域的最短欧氏距离：

$$d_{t,h,c} = \inf_{\boldsymbol{\xi} \in \mathcal{C}_{h,c}} \|\widetilde{\boldsymbol{x}}_t - \boldsymbol{\xi}\|_2. \tag{6}$$

内部刺激落在某类别区域内时，到该区域的距离为0；一个类别有多个分离区域时，取最近区域的距离。模型再用精度参数将这些距离转为类别概率：

$$p_{t,h}(c) = \frac{\exp[-\beta_t(h) d_{t,h,c}]}{\sum_{a=1}^{C} \exp[-\beta_t(h) d_{t,h,a}]}. \tag{7}$$

精度越高，较近类别越占优势；精度越低，预测越接近均匀。知觉误差改变输入，精度改变对距离的反应，作用位置不同。

这里得到的是每条规则对各类别的预测。选择读出按规则权重汇总这些预测；收到反馈后，证据记忆和精度更新模块用同一组预测评价结果。

4 证据记忆模块（M）：根据反馈更新规则信念

证据记忆模块在收到反馈后，重新比较各条活跃规则的可信程度。它先计算每条规则能以多大概率解释这次反馈，再将当前证据与保留下来的旧证据结合。

4.1 规则是否能解释当前反馈

给定实际选择 y_t，规则 h 预测到本次二值反馈的概率，即反馈似然，为

$$\ell_t(h) = r_t p_{t,h}(y_t) + (1 - r_t)[1 - p_{t,h}(y_t)]. \tag{8}$$

答对支持能预测已选类别的规则；答错支持倾向其他类别的规则。四分类错误反馈提供“当前所选答案错误”这一信息，对应其余三个类别的总概率 $1 - p_{t,h}(y_t)$。

条件3的0分和半分含义不同，使用第8节的联合概率。

4.2 保留旧证据，再加入新证据

反馈后信念为

$$\pi_t^+(h) = \frac{\mathbb{I}(h \in \mathcal{A}_t)[\pi_t^-(h)]^{\gamma_s}\ell_t(h)}{\sum_{v\in\mathcal{A}_t}[\pi_t^-(v)]^{\gamma_s}\ell_t(v)}, \qquad 0 \le \gamma_s \le 1. \tag{9}$$

公式包含三个步骤。先将旧信念取 γ_s 次幂，保留或压缩候选之间原有的差异；再乘以反馈似然，使更能解释本题反馈的规则得到更大权重；最后归一化，使活跃集合内的信念总和为1。

例如，两条规则原有信念为0.9和0.1，比例为9比1。$\gamma_s = 0.5$ 时，加入新反馈前的比例变为3比1；本题反馈再根据两条规则的似然改变这一比例。γ_s 越大，旧差异保留得越多；越小，差异压缩得越强。$\gamma_s = 1$ 表示完整保留旧证据的顺序更新；$\gamma_s = 0$ 时，活跃候选按当前反馈重新比较。

条件3分别对规则信念和每条规则下的配对信念应用同一个保持参数。其规则边际也遵循式(9)，其中反馈似然按遗忘后、加入本题反馈前的配对信念求平均；具体定义见第8节。

规则信念随反馈递推。候选管理负责设置新集合的初始信念，证据记忆模块负责将后续反馈累积到这些信念中。

所有活跃候选都接受同一结果的评价，包括贡献很小的备选，表示“如果按另一条候选判断，能不能解释这个结果”。反馈学习作用于当前活跃集合。

5 假设更新模块（H）：搜索与候选管理

证据记忆模块根据第 t 题反馈更新各条规则的可信程度，得到反馈后信念 π_t^+。假设更新模块在此基础上，结合近期失败经历，调整下一题的候选集合 $\mathcal{A}_{t+1}$，并确定其初始

信念 π_{t+1}^{-}。这一过程决定哪些解释继续被考虑、何时引入新解释，以及新解释从已有知识中获得多少支持。

本节描述从第 t 题走向第 $t+1$ 题的候选更新。它使用已经获得的反馈，准备下一题的候选集合和初始信念。计算顺序是：更新失败状态与搜索控制，处理旧候选退出；发生搜索时，再生成新规则、处理容量并分配信念。第一题按第2节初始化。规则怎样影响作答，见第7节。

5.1 近期失败：保留多少过去的反馈影响

本题失败程度为 $f_t = 1 - r_t$。二值反馈对应0或1；三值反馈对应0、0.5或1。它表示本题目标还有多少未达到。模型用失败状态 F_t 汇总近期经历：

$$F_{t+1} = \delta_s F_t + (1 - \delta_s) f_t, \qquad F_1 = 0, \qquad 0 \le \delta_s < 1. \tag{10}$$

δ_s 是被试层面的失败保持参数，决定旧状态在更新中占多少比例。较小的值使状态更快响应最新反馈；较大的值使单次反馈改变较小、影响持续更久。例如 $\delta_s = 0.6$ 时，从0开始连续两次失败得到0.4、0.64，再成功一次降到0.384。0.6在这里用于演示计算。

失败状态按有效作答试次顺序递推，跨实验段（session）时延续已有状态。它为搜索提供近期表现的信息；记忆保持参数 γ_s 则控制各规则保留多少旧证据。

5.2 搜索控制：是否搜索，以及采用哪种来源

下一题的搜索概率为

$$e_{t+1} = \mathrm{sigmoid}[\mathrm{logit}(e_{0,s}) + a_{e,s} F_{t+1}], \tag{11}$$

其中 $\mathrm{sigmoid}(v) = 1/(1+e^{-v})$，$\mathrm{logit}(p) = \log[p/(1-p)]$。基础概率 $e_{0,s} \in (0,1)$ 表示近期没有失败影响时，仍有多大机会搜索；增益 $a_{e,s} \ge 0$ 表示失败使搜索概率上升得多快。连续成功使搜索逐渐回到基础水平，连续失败提高搜索机会。

搜索发生后，以概率 g_{t+1} 使用全局来源，以概率 $1 - g_{t+1}$ 使用局部来源：

$$g_{t+1} = g_{0,s} + (1 - g_{0,s}) a_{g,s} F_{t+1}, \qquad g_{0,s}, a_{g,s} \in [0,1]. \tag{12}$$

$g_{0,s}$ 是基础全局比例，$a_{g,s}$ 控制失败使搜索偏向整个目录的程度。失败状态为0时，全局比例为 $g_{0,s}$；达到1时，为 $g_{0,s} + (1 - g_{0,s}) a_{g,s}$。局部来源利用现有候选，全局来源在可引入的规则中按基础先验搜索。

因此，e_{t+1} 控制搜索是否发生，g_{t+1} 控制发生搜索时采用哪类来源。下一步先确定哪些旧候选保留，再据此生成新规则。

5.3 候选退出：逐渐减少低信念规则

每条旧候选根据反馈后信念，独立产生一次退出提议：

$$P(h\text{提议退出} \mid \mathcal{A}_t, \pi_t^{+}) = \rho_s [1 - \pi_t^{+}(h)], \qquad h \in \mathcal{A}_t, \quad \rho_s \in [0,1]. \tag{13}$$

ρ_s 是被试的退出率参数。相对信念越低，候选越容易退出；上一题的主导规则也按同一概率判断。例如，三条候选的信念为0.72、0.18和0.10，$\rho_s = 0.2$ 时，退出提议概率分别为0.056、0.164和0.18。

学习者至少保留一个可用解释。若退出提议使集合为空，或保留规则的信念总和为0，模型恢复一条原本信念最高的规则；最高值并列时等概率选取。用 $\mathcal{D}_t$ 表示处理这一情况后实际退出的规则，保留集合及其信念为

$$\mathcal{A}_t^{\mathrm{ret}} = \mathcal{A}_t \setminus \mathcal{D}_t, \qquad \pi_t^{\mathrm{ret}}(h) = \frac{\pi_t^+(h)}{\sum_{v \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^+(v)}, \quad h \in \mathcal{A}_t^{\mathrm{ret}}. \tag{14}$$

上标 ret 表示退出后保留的阶段。归一化使集合内的信念总和恢复为1，同时保留各规则之间的比例。上例中，若第三条退出，剩下的0.72和0.18就归一化为0.8和0.2。

每次候选更新抽取一次搜索事件：

$$I_{t+1}^{\mathrm{search}} \sim \mathrm{Bernoulli}(e_{t+1}). \tag{15}$$

事件取0时，令 $\mathcal{A}_{t+1} = \mathcal{A}_t^{\mathrm{ret}}$、$\pi_{t+1}^- = \pi_t^{\mathrm{ret}}$，空位留待后续搜索。事件取1时，按以下步骤引入一条新规则。只剩一条候选时，其相对信念为1，退出提议概率为0；后续搜索仍可引入其他规则。

退出表示停止主动考虑该规则，其精度记录与反馈学习随之结束。仍在集合中的候选继续积累证据，旧证据由 γ_s 控制保持程度。

5.4 候选生成：怎样选出一条新规则

搜索发生后，模型要为下一题选出一条新规则，记为 u。可选范围是 $\mathcal{U}_t = \mathcal{H} \setminus \mathcal{A}_t$：从完整规则目录 $\mathcal{H}$ 中，去掉本题已经考虑过的规则 $\mathcal{A}_t$。本题刚刚退出的规则也暂时排除，后续试次才有机会重新进入。

模型首先选择全局搜索或局部搜索。全局搜索直接从 $\mathcal{U}_t$ 中按基础先验抽取一条规则。局部搜索先从保留的旧规则中选一条作为起点，再选择一种方法寻找新规则：对旧规则做一次结构编辑，或寻找与它分类结果相近的规则。选定方法后，按该方法给出的概率抽取一条新规则。

这两种局部方法分别描述规则之间的结构关系和功能关系。结构编辑关注判断步骤怎样改变，例如把“看脖子长短”改成“看尾巴长短”；功能相似性关注两条规则会怎样给刺激分类。一次简单的修改也可能改变许多刺激的类别，因此模型分别计算这两种方法的抽取概率，再将它们结合起来。下面依次说明这两个概率，以及局部、全局搜索如何共同决定最终的抽取概率。

5.4.1 结构编辑：对旧规则做一次修改

结构编辑从旧规则 h 出发，对它做一次规定的修改。每条规则都包含判断特征、比较关系、参照值、分支和类别输出。允许的修改有四种：更换一个特征，更换比较关系及相应的标准参照，修改一个参照值，或改写条件树的一条下级判断。改写下级判断时，其余判断和类别输出布局保持原样。修改后的结果必须是规则目录中的一条完整规则；满足这一条件的修改称为合法编辑。

模型用编辑成本表示这些修改的相对难易。上述四种修改的成本依次为1、1.5、1和2。编辑成本越低，修改后对应的新规则获得的抽取权重越大。等价的判断先整理为统一形式，再计算成本。

用 $\mathcal{E}(h)$ 表示对 h 可以进行的全部合法编辑，op 表示其中一次编辑，$c_{\mathrm{edit}}(\mathrm{op})$ 表示这次编辑的成本。若几种单次编辑都能将 h 改成 u，就取其中最低的成本，记为编辑距

离 $d_{\text{edit}}(h,u)$：

$$d_{\text{edit}}(h,u)=\begin{cases}\min_{\text{op}\in\mathcal{E}(h):\,\text{op}(h)=u} c_{\text{edit}}(\text{op}), & \text{有合法编辑},\\ \infty, & \text{否则}.\end{cases} \tag{16}$$

如果规定的一次编辑无法将 h 改成 u，就将这个距离记为无穷大。因此，距离有限的新规则都能通过一次合法编辑得到。

接着，从这些规则中选出本轮允许引入的规则，组成集合 $\mathcal{N}_t(h)=\{u\in\mathcal{U}_t:\ d_{\text{edit}}(h,u)<\infty\}$。当这个集合非空时，先把每条规则的编辑距离转为权重 $e^{-d_{\text{edit}}(h,u)}$，再用各自的权重除以全部权重之和。这一步称为归一化，得到的抽取概率加起来等于1：

$$K_{\text{edit},t}(u\mid h)=\frac{\mathbb{I}[u\in\mathcal{N}_t(h)]e^{-d_{\text{edit}}(h,u)}}{\sum_{v\in\mathcal{N}_t(h)}e^{-d_{\text{edit}}(h,v)}}. \tag{17}$$

$K_{\text{edit},t}(u\mid h)$ 表示已经选定旧规则 h 时，通过结构编辑抽中 u 的概率。编辑距离越小，指数权重越大，抽取概率越高。指示函数 $\mathbb{I}[\cdot]$ 在括号内条件成立时取1，否则取0；它使 $\mathcal{N}_t(h)$ 以外的规则概率为0。

5.4.2 功能相似性：寻找分类结果接近的规则

按功能相似性搜索时，模型更容易选中与旧规则 h 分类结果接近的新规则。比较方法是让两条规则给同一批参考刺激分类，再计算分类一致率。例如，100个刺激中有80个被两条规则判为同一类别，一致率就是0.8。

为计算这个比例，用 $c_h(\boldsymbol{x})$ 表示规则 h 给刺激 $\boldsymbol{x}$ 指定的类别，μ_X 表示参考刺激的分布，c,c' 表示类别编号。先统计各类别组合所占的比例：

$$T_{cc'}(h,u)=\Pr_{\boldsymbol{x}\sim\mu_X}[c_h(\boldsymbol{x})=c,\ c_u(\boldsymbol{x})=c']. \tag{18}$$

$T_{cc'}(h,u)$ 是参考刺激中同时满足“h 判为 c、u 判为 c'”的比例。这些比例组成一个矩阵，其中对角线上的 T_{cc} 对应两条规则判为同一类别的情况。将对角线各项相加，就得到分类一致率 $S(h,u)$。再用1减去一致率，得到功能距离 $d_{\text{func}}(h,u)$，其中 C 是类别总数：

$$S(h,u)=\sum_{c=1}^{C}T_{cc}(h,u),\qquad d_{\text{func}}(h,u)=1-S(h,u). \tag{19}$$

功能距离越小，两条规则的分类结果越一致。上例中，一致率为0.8，功能距离就是0.2。计算始终使用规则原有的类别标签；参考刺激在 $[0,1]^4$ 中均匀抽取，共100,000个，随机种子固定为0。各被试共用这批刺激及由此得到的类别组合比例。

一致率还取决于各类别占参考刺激的比例。例如，两条规则都将20%的刺激判为带内、80%判为带外，即使两条规则的判断相互独立，一致率也有 $0.2^2+0.8^2=0.68$。其中0.64来自共同判为带外。解释功能距离时，要同时考虑这种类别比例的影响。

有了功能距离，就可以计算每条新规则的抽取概率。对每条 $u\in\mathcal{U}_t$，将基础先验 $p_0(u)$ 乘以距离权重 $e^{-d_{\text{func}}(h,u)/\tau_{\text{prop}}}$，再将所得权重归一化：

$$K_{\text{func},t}(u\mid h)=\frac{\mathbb{I}(u\in\mathcal{U}_t)p_0(u)e^{-d_{\text{func}}(h,u)/\tau_{\text{prop}}}}{\sum_{v\in\mathcal{U}_t}p_0(v)e^{-d_{\text{func}}(h,v)/\tau_{\text{prop}}}},\qquad \tau_{\text{prop}}=0.10. \tag{20}$$

$K_{\text{func},t}(u\mid h)$ 表示已经选定 h 时，按功能相似性抽中 u 的概率。当前基础先验 p_0 对目录内各规则赋予相同权重，因此分类一致率较高的规则具有更大的抽取概率。搜索距离尺度 τ_{prop} 固定为0.10，各被试共用。这个尺度越小，抽取概率就越集中于功能距离较小的规则。

5.4.3 结合局部搜索与全局搜索

现在将两种局部方法合在一起。局部搜索先从退出后保留的集合 $\mathcal{A}_t^{\mathrm{ret}}$ 中选择一条旧规则 h，选择概率为它的信念 $\pi_t^{\mathrm{ret}}(h)$。例如，两条旧规则的信念为0.8和0.2，它们被选为起点的概率也分别为0.8和0.2。这样，局部搜索更常从已有支持较多的规则出发。

选定 h 后，用被试参数 ω_s 决定采用哪种局部方法。当 $\mathcal{N}_t(h)$ 非空时，以概率 ω_s 采用结构编辑，以概率 $1-\omega_s$ 按功能相似性搜索。例如，$\omega_s = 0.7$ 表示这两种方法的使用概率分别为70%和30%。由此，以 h 为起点抽中 u 的概率为：

$$K_{\mathrm{loc},t}(u \mid h) = \omega_s K_{\mathrm{edit},t}(u \mid h) + (1-\omega_s) K_{\mathrm{func},t}(u \mid h), \qquad \omega_s \in [0,1]. \tag{21}$$

$K_{\mathrm{loc},t}(u \mid h)$ 是两种方法各自的抽取概率按使用概率加权得到的结果。若 $\mathcal{N}_t(h)$ 为空，从这条旧规则出发，所有允许的一次编辑都无法产生本轮可引入的新规则。这次局部搜索便全部采用功能相似性，即 $K_{\mathrm{loc},t}(u \mid h) = K_{\mathrm{func},t}(u \mid h)$；程序记录这一情况。

局部搜索有多条可能的起点。从某条旧规则出发并抽中 u 的概率，等于“选中这条旧规则的概率”乘以“从它出发抽中 u 的概率”。把所有起点的这部分概率相加，就得到局部搜索的总体抽取概率 $Q_{\mathrm{loc},t}(u)$。全局搜索的概率记为 $Q_{\mathrm{glob},t}(u)$，由 $\mathcal{U}_t$ 内的基础先验归一化得到；当前先验均匀，因此全局搜索中各条可引入规则的抽取概率相同。

最后，前文的搜索控制给出两种搜索的使用概率：全局搜索为 g_{t+1}，局部搜索为 $1-g_{t+1}$。将两种搜索各自的抽取概率按这一比例加权，就得到新规则 u 最终被抽中的概率 $Q_t(u)$：

$$Q_{\mathrm{loc},t}(u) = \sum_{h \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^{\mathrm{ret}}(h) K_{\mathrm{loc},t}(u \mid h), \tag{22}$$

$$Q_{\mathrm{glob},t}(u) = \frac{\mathbb{I}(u \in \mathcal{U}_t) p_0(u)}{\sum_{v \in \mathcal{U}_t} p_0(v)}, \tag{23}$$

$$Q_t(u) = (1-g_{t+1}) Q_{\mathrm{loc},t}(u) + g_{t+1} Q_{\mathrm{glob},t}(u). \tag{24}$$

ω_s 控制局部搜索内部两种方法的比例；g_{t+1} 控制全局与局部搜索的比例，并随近期失败状态变化。上述公式将这些搜索步骤汇总为一个分布 Q_t，模型据此抽取一条新规则 u。

抽取完成后，进入容量管理：检查是否有空位，确定最终保留哪些旧规则，再向新规则分配初始信念。

5.5 容量管理：确定最终保留的旧规则

上一节已经抽出一条新规则 u。接下来，模型检查退出后保留的集合 $\mathcal{A}_t^{\mathrm{ret}}$ 是否还有空位，确保加入 u 后的规则数符合被试的容量上限 $M_s^{\max}$。这个参数规定最多同时考虑多少条规则，实际数量随候选的进入和退出变化。

有空位时，保留全部旧规则，令 $\mathcal{A}_t^{\mathrm{keep}} = \mathcal{A}_t^{\mathrm{ret}}$。容量已满时，删除信念最低的一条旧规则，为 u 腾出位置。记被删除的规则为 h_t^{drop}，保留的旧集合为：

$$h_t^{\mathrm{drop}} \in \arg\min_{h \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^{\mathrm{ret}}(h), \qquad \mathcal{A}_t^{\mathrm{keep}} = \mathcal{A}_t^{\mathrm{ret}} \setminus \{h_t^{\mathrm{drop}}\}. \tag{25}$$

$\arg\min$ 表示取得最小信念值的规则；多条规则并列最低时，等概率选择其中一条。所有旧规则都按这一标准处理，包括本题作答时的主导规则。上标 keep 表示容量处理后最终保留的旧规则。

确定旧集合后，将其中各规则的信念除以它们的信念总和，得到归一化后的 π_t^{keep}。它表示向新规则分配支持前，保留的旧规则之间的相对信念。随后将 u 加入集合，得到下一题的候选集合 $\mathcal{A}_{t+1}$：

$$\pi_t^{\text{keep}}(h) = \frac{\pi_t^{\text{ret}}(h)}{\sum_{v\in\mathcal{A}_t^{\text{keep}}} \pi_t^{\text{ret}}(v)}, \quad h \in \mathcal{A}_t^{\text{keep}}, \qquad \mathcal{A}_{t+1} = \mathcal{A}_t^{\text{keep}} \cup \{u\}. \tag{26}$$

例如，容量上限为3，退出处理后仍有三条旧规则，信念分别为0.72、0.18和0.10。为了加入新规则，先删除第三条。前两条的信念总和为0.90，归一化后分别为 $0.72/0.90 = 0.8$ 和 $0.18/0.90 = 0.2$。下一节将从这份总和为1的旧规则信念中，计算新规则的初始支持。

容量上限参数的最小允许值为2，因此容量已满时删除一条旧规则后，至少还有一条旧规则参与后续信念分配。

5.6 信念分配：按功能关系形成新规则的初始支持

现在，下一题的候选集合已经确定，还需要为其中的新规则 u 设置初始信念。模型让每条保留的旧规则留下一部分信念，并将另一部分分给 u；新规则把这些分出的部分相加，形成自己的初始支持。这一步表示已有分类知识向新规则的推广。

每条旧规则分出多少支持，取决于它与新规则的功能关系。两条规则对参考刺激的分类越一致，旧规则就向新规则分配越多支持。为计算这个比例，先将前文的功能距离 $d_{\text{func}}(h,u)$ 转为亲和度 $\chi_s(h,u)$：

$$\chi_s(h,u) = e^{-d_{\text{func}}(h,u)/\tau_{\text{tr},s}}, \qquad \tau_{\text{tr},s} > 0. \tag{27}$$

亲和度取值在0到1之间，功能距离越小，亲和度越大；分类结果完全一致时，亲和度为1。被试参数 $\tau_{\text{tr},s}$ 是信念迁移尺度。它较小时，支持主要分给功能距离很小的新规则；它较大时，同样的功能距离对应更高的亲和度，较远的新规则也能获得更多支持。

接着，每条旧规则将自身信念按 $1:\chi_s(h,u)$ 分成两份，分别留给自己和新规则。这两份占旧规则原有信念的比例分别是 $1/[1+\chi_s(h,u)]$ 和 $\chi_s(h,u)/[1+\chi_s(h,u)]$。将这两个比例分别乘以旧规则原有的信念 $\pi_t^{\text{keep}}(h)$，再汇总新规则收到的各份支持，得到下一题作答前的信念：

$$\pi_{t+1}^{-}(h) = \frac{\pi_t^{\text{keep}}(h)}{1+\chi_s(h,u)}, \quad h \in \mathcal{A}_t^{\text{keep}}, \qquad \pi_{t+1}^{-}(u) = \sum_{h\in\mathcal{A}_t^{\text{keep}}} \frac{\pi_t^{\text{keep}}(h)\chi_s(h,u)}{1+\chi_s(h,u)}. \tag{28}$$

$\pi_{t+1}^{-}(h)$ 是分配后旧规则保留的信念，$\pi_{t+1}^{-}(u)$ 是新规则获得的总信念。每条旧规则分出的两份之和等于它原有的信念，因此新集合中的信念总和仍为1。

沿用上一节0.8和0.2的例子，假设两条旧规则与新规则的亲和度分别为0.5和0.1。第一条旧规则按 $1:0.5$ 分配，保留 $0.8/1.5 \approx 0.533$，分给新规则约0.267。第二条按 $1:0.1$ 分配，保留 $0.2/1.1 \approx 0.182$，分给新规则约0.018。新规则将两份相加，得到约 $0.267+0.018 = 0.285$ 的初始信念。分配后三条规则的信念约为0.533、0.182和0.285，总和为1。

旧规则原有信念越高、与新规则的亲和度越大，分给新规则的支持就越多。若上例中的两个亲和度都只有0.02，新规则得到的总信念约为0.020。由于亲和度至多为1，每条旧规则最多分出自身信念的一半，新规则的总初始信念也至多为 $1/2$。

候选生成中的搜索距离尺度 τ_{prop} 决定按功能相似性搜索时，各条新规则被抽中的概率；本节的迁移尺度 $\tau_{\text{tr},s}$ 决定已经抽中的新规则获得多少初始信念。完成分配后，新规则从下一题起参与预测，接受实际反馈的评价。反馈可以提高或降低它的信念，随后模型再进行下一轮退出判断。

5.7 状态衔接：保留精度与配对知识

候选集合和规则信念确定后，模型还要准备下一题使用的精度；条件3还需衔接配对知识。这些状态与规则信念一起，决定候选在下一题怎样预测类别和反馈。

精度控制单条规则的类别预测有多明确。最终保留的旧规则，继续使用已经根据本题反馈更新的精度。新规则从被试的初始精度 $\beta_{0,s}$ 开始，在下一题首次参与预测，再根据下一题的实际反馈调整精度。曾经退出的规则重新进入时，也从 $\beta_{0,s}$ 开始。

条件3中的配对知识描述哪两个反应属于同一个科。四个反应有三种可能的配对方案，模型为每种方案保存一个概率。每条旧规则都有自己的条件配对信念，即假定这条分类规则成立时，各种配对方案分别有多大可能。

在候选退出和容量处理之前，模型已经保存了本题反馈更新后的整体配对信念：将全部旧规则各自的条件配对概率，按它们的反馈后规则信念加权相加。这份分布汇总了此前积累的反应关系知识。确定下一题的候选集合后，保留的旧规则沿用各自的条件配对信念，新规则继承这份已保存的整体配对信念。具体公式见第8.4节。

至此，下一题需要的状态全部准备完成：$\mathcal{A}_{t+1}$ 记录正在考虑哪些规则，π^{-}_{t+1} 记录各规则的相对可信程度，精度决定每条规则的类别预测有多明确；条件3的配对信念还记录对反应关系的判断。这些状态共同进入下一题，并在新的选择与反馈之后继续更新。

6 精度更新模块（B）：调整规则预测的明确程度

精度更新模块用反馈校准每条规则的类别预测。它判断精度略微提高时，本次实际反馈的预测概率会怎样变化，并据此提高或降低 $\beta_t(h)$。这一调整改变规则预测的明确程度，更新后的精度从下一题起使用。

6.1 反馈允许哪些类别

先把实际反馈转为各类别与反馈的相容程度。用 $a_{t,h}(c) \in [0,1]$ 表示：假定类别为 c，在实际选择 y_t 和该规则已有知识下，收到反馈 r_t 的概率。二值反馈的相容系数为

$$a_{t,h}(c) = \begin{cases} \mathbb{I}(c = y_t), & r_t = 1, \\ \mathbb{I}(c \neq y_t), & r_t = 0. \end{cases} \tag{29}$$

正确反馈只允许已选类别，错误反馈允许其余类别。条件3还需对未知配对求平均，相容系数的定义见第8.3节。

为考察精度变化的影响，固定本题内部刺激与规则区域，将类别预测中的精度暂记为可变的 β，得到 $p_{t,h}(c;\beta)$。反馈似然以及按反馈重新加权的类别分布为

$$\ell_t(h;\beta) = \sum_{c=1}^{C} a_{t,h}(c)\, p_{t,h}(c;\beta), \tag{30}$$

$$p_t^{\mathrm{fb}}(c \mid h) = \frac{a_{t,h}(c)p_{t,h}(c)}{\ell_t(h)}, \qquad \ell_t(h) = \ell_t(h; \beta_t(h)). \tag{31}$$

式中的 $p_{t,h}(c)$ 是本题作答时使用的类别预测。将它乘以相容系数，再除以反馈似然，便得到总和为1的 p_t^{fb}。上标 fb 表示加入本题反馈后的类别条件分布。例如，正确反馈使该分布全部集中在已选类别；错误反馈使其在其余类别间按原预测比例分配。它用于本次精度计算，规则信念 π_t^+ 仍按证据记忆模块的公式更新。

6.2 根据预测距离确定调整方向

精度越高，预测越偏向距离较近的类别。因此，模型比较两种平均距离：作答时各类别按 $p_{t,h}$ 加权的平均距离，以及加入反馈后按 p_t^{fb} 加权的平均距离。两者的差恰好是反馈对数似然对精度的梯度：

$$\kappa_t(h) = \left.\frac{\partial \log \ell_t(h;\beta)}{\partial \beta}\right|_{\beta=\beta_t(h)} = \sum_{c=1}^{C} p_{t,h}(c)d_{t,h,c} - \sum_{c=1}^{C} p_t^{\mathrm{fb}}(c \mid h)d_{t,h,c}. \tag{32}$$

梯度表示精度略微增加时，对数似然的变化速度。反馈允许的类别平均更近时，梯度为正，提高精度会增加本次反馈的预测概率；这些类别平均更远时，梯度为负，降低精度会增加该概率。两种平均距离相同时，梯度为0，精度保持原值。

例如，一条四分类规则给四个类别的距离为 $(0, 0.1, 0.4, \sqrt{0.17})$。精度为5时，类别预测约为 $(0.5350, 0.3245, 0.0724, 0.0681)$，平均距离约为0.0895。若选择第二类并收到正确反馈，反馈后的类别分布集中在第二类，其距离为0.1。因此梯度约为 $0.0895 - 0.1 = -0.0105$，这次反馈使精度降低。调整方向由反馈允许的类别与当前预测之间的距离差决定。

6.3 用同一学习率调整精度

所有活跃规则用一个被试层面的学习率 η_s 更新精度：

$$\beta_{t+1}(h) = \mathrm{clip}\big(\beta_t(h) + \eta_s\kappa_t(h), \beta_{\min}, \beta_{\max}\big), \qquad 0 \le \eta_s \le 1. \tag{33}$$

这里 $\mathrm{clip}(v, l, u) = \min\{u, \max\{l, v\}\}$ 将更新后的数值限制在共同边界 $\beta_{\min} = 0.1$ 与 $\beta_{\max} = 25$ 之间。学习率越大，同样的梯度引起的调整越大；精度的增加和降低均使用 η_s。精度模块的个体参数为初值 $\beta_{0,s}$ 和学习率 η_s。

上述例子在 $\eta_s = 1$ 时，将精度由5调整到约4.9895，第二类概率由约0.32450提高到0.32454。所有活跃候选都接受更新，包括作答贡献很小的规则。保留规则沿用更新后的精度，新规则从 $\beta_{0,s}$ 开始。证据记忆与精度更新共用反馈前的类别预测；条件3的精度计算还固定使用遗忘后、加入本题反馈前的条件配对信念。三种条件均按式(32)和式(33)更新。

规则信念反映各候选之间的相对可信程度，规则精度控制单条规则的类别预测有多集中。反馈同时改变这两个量：证据记忆重新比较候选，精度更新调整每条候选解释反馈时的预测明确程度。

6.4 更新范围与拟合前检查

本模型的内部刺激和非空类别区域位于 $[0, 1]^4$，因此 $0 \le d_{t,h,c} \le 2$。固定本题距离与相容系数时，反馈对数似然的二阶导数等于反馈条件分布与原类别预测下的距离方差之

差，其绝对值至多为1。这一界限使 $0 \le \eta_s \le 1$ 的有界更新保持本次反馈似然不下降。该性质针对当前规则和本题固定状态，整体选择预测与学习轨迹的表现需另行评价。

当反馈按该规则当前的反馈分布产生时，梯度的期望为0；对未作边界裁剪的更新，平均精度变化也为0。边界裁剪会改变这一性质。正式拟合前需检查精度变化速度、学习率是否触及上界，以及错误规则在降低精度后的存活时间。单学习率精度校准已接入 `0923-full-v3`；参数恢复和行为预测检验待完成。

7 选择读出模块（RC）：从规则权重到类别选择

作答前，假设更新模块已经准备好当前候选集合 $\mathcal{A}_t$ 和规则信念 π_t^-。各条规则也已根据本题内部刺激和自身精度，给出类别预测 $p_{t,h}(c)$。选择读出模块将这些信息转为本题的选择概率，并记录主导规则，供下一题计算使用惯性。

这里需要区分两个量：规则信念表示此前证据对一条规则的相对支持；作答权重表示这条规则对本题回答的影响有多大。下面先说明作答权重，再说明怎样汇总为选择概率，最后介绍跨试次的主导规则记录和参与程度指标。本题反馈在作答完成后进入学习。

7.1 作答权重：结合规则信念与使用惯性

模型假设，上一题对回答影响最大的规则，在本题仍有继续被使用的倾向。这种倾向称为使用惯性。计算时，先取各规则的作答前信念作为基础权重，将上一题主导规则的基础权重乘以 e^{λ_s}，再归一化，使所有作答权重之和为1：

$$w_t(h) = \frac{\pi_t^-(h) e^{\lambda_s \mathbb{I}(h = h_{t-1}^\star)}}{\sum_{v \in \mathcal{A}_t} \pi_t^-(v) e^{\lambda_s \mathbb{I}(v = h_{t-1}^\star)}}, \qquad h \in \mathcal{A}_t, \quad \lambda_s \ge 0. \tag{34}$$

$w_t(h)$ 是规则 h 的作答权重，λ_s 是被试的使用惯性参数。指示函数 $\mathbb{I}(h = h_{t-1}^\star)$ 在 h 是上一题主导规则时取1，其余情况取0；因此，只有上一题主导规则获得惯性加成。分母将加成后的权重归一化。

$\lambda_s = 0$ 时，作答权重等于规则信念；λ_s 越大，上一题主导规则获得的使用优势越大。第一题尚无上一主导规则，或上一主导规则已经退出时，也直接按当前信念计算权重。

下面用两条规则 A、B 串起整个作答过程。假设 A 是上一题的主导规则，当前信念分别为0.4和0.6，且 $\lambda_s = \log 3$，即惯性倍率为3：

处理阶段	规则 A	规则 B
作答前信念	0.4	0.6
加入惯性，尚未归一化	$0.4 \times 3 = 1.2$	0.6
归一化后的作答权重	2/3	1/3

虽然此前证据给予 B 更高的信念，使用惯性仍使 A 对本题回答产生更大影响。这样，证据支持的变化与作答习惯的变化可以有时间差。

7.2 选择概率：汇总各规则的类别预测

得到作答权重后，模型将每条规则的类别预测乘以它的权重，再按类别相加。规则 h 给类别 c 的预测概率是 $p_{t,h}(c)$，因此本题选择类别 c 的概率为：

$$P(y_t = c \mid z_t) = \sum_{h \in \mathcal{A}_t} w_t(h) p_{t,h}(c). \tag{35}$$

继续上面的例子。假设本题有两个类别，A 较支持类别1，B 较支持类别2：

规则	作答权重	类别1的预测概率	类别2的预测概率
A	$2/3$	0.9	0.1
B	$1/3$	0.2	0.8

选择类别1的概率为 $(2/3) \times 0.9 + (1/3) \times 0.2 = 2/3$，类别2的概率为 $1/3$。A、B 的预测都进入了最终回答，各自的影响大小由作答权重决定。模拟行为时按这个概率分布抽取答案；拟合行为时读取实际选择对应的概率，粒子汇总见第10节。

输出层直接使用上述类别概率生成回答。随机失误（lapse）概率固定为0，作答变异来自知觉、候选状态和各规则的类别概率。

7.3 主导规则：记录作答权重最大的候选

为使使用惯性延续到下一题，模型将本题作答权重最大的规则记录为主导规则 $h_t^\star$。它在作答权重形成后、实际选择之前确定：

$$h_t^\star \in \arg\max_{h \in \mathcal{A}_t} w_t(h). \tag{36}$$

$\arg\max$ 表示取得最大权重的候选。在上面的例子中，A 的权重为 $2/3$，因此记录 A，下一题的惯性加成继续以它为对象。本题选择概率仍按式(35)汇总各候选的预测。

随着反馈积累，其他规则的信念可以增长，并超过原主导规则的惯性优势。例如，惯性倍率仍为3，若 A 的信念降至0.2、B 升至0.8，两者加成后为0.6和0.8，归一化后的权重为 $3/7$ 和 $4/7$。此时 B 成为主导规则，下一题的惯性加成转向 B。

并列最大时优先沿用上一题的主导规则；若它不在并列集合内，则等概率选择。候选退出和容量释放继续以规则信念为依据。收到反馈后，所有活跃候选都更新信念与精度，包括作答权重较小的规则，更新结果从下一题起影响回答。

7.4 有效参与数量：描述作答权重的集中程度

各规则对作答的影响随试次变化。权重分散时，多条规则共同影响回答；权重集中时，一条规则主导回答。为描述这种集中程度，模型计算有效参与数量：

$$N_{\mathrm{eff},t} = \frac{1}{\sum_{h \in \mathcal{A}_t} w_t(h)^2}, \qquad 1 \le N_{\mathrm{eff},t} \le |\mathcal{A}_t|. \tag{37}$$

两条规则的权重均为0.5时，有效参与数量为2；上面例子的权重为 $(2/3, 1/3)$，有效参与数量为1.8；权重为 $(0.98, 0.02)$ 时，它约为1.04。只有一条候选时，它等于1，选择概率也完全由该规则给出。

候选数量描述当前考虑多少条规则，有效参与数量描述这些规则的贡献有多集中。1.8这样的数值是权重分布的描述指标。λ_s 在同一被试内保持稳定，作答权重和有效参与数量随信念、候选集合与上一主导规则逐题变化。

8 条件3：层级反馈与配对学习

条件3的反馈同时涉及“科”和“种”两个层级。本节补充证据记忆、精度更新和假设更新模块在这种任务中的计算：收到反馈后，模型先分别减弱规则信念和条件配对信念中的旧差异，再用反馈更新联合信念；候选变化时，已学到的配对关系继续保留。

8.1 知道层级，不知道具体反应配对

被试知道两个科、每科两个种，但不知道哪两个反应同科。三种配对为

$$\mathcal{G}_1=\{\{1,2\},\{3,4\}\},\quad \mathcal{G}_2=\{\{1,3\},\{2,4\}\},\quad \mathcal{G}_3=\{\{1,4\},\{2,3\}\}. \tag{38}$$

三种配对的初始概率相同。数据中的 `category` 表示真实类别，`choice` 表示统一反应编号，`presskey` 表示实际按键。转换表统一数据编码，配对知识由反馈学习。

8.2 同次反馈评价规则和配对

每条规则具有条件配对信念 $q_t^-(k\mid h)$，与规则信念相乘得到联合信念：

$$\Pi_t^-(h,k)=\pi_t^-(h)q_t^-(k\mid h),\qquad q_1^-(k\mid h)=1/3. \tag{39}$$

令 $\mathrm{mate}_k(y)$ 为配对中同组的另一个反应：

$$\ell_t(h,k)=\begin{cases} p_{t,h}(y_t), & r_t=1,\\ p_{t,h}[\mathrm{mate}_k(y_t)], & r_t=0.5,\\ 1-p_{t,h}(y_t)-p_{t,h}[\mathrm{mate}_k(y_t)], & r_t=0. \end{cases} \tag{40}$$

完全正确支持所选反应，半分支持同科另一种，0分支持另科两个反应。三个事件互斥且概率和为1，0分使用另科两个反应的总概率。

收到反馈后，模型先对规则信念和各规则下的条件配对信念分别取幂，再各自归一化：

$$\widetilde{\pi}_t^-(h)=\frac{[\pi_t^-(h)]^{\gamma_s}}{\sum_{v\in\mathcal{A}_t}[\pi_t^-(v)]^{\gamma_s}}, \tag{41}$$

$$\widetilde{q}_t^-(k\mid h)=\frac{[q_t^-(k\mid h)]^{\gamma_s}}{\sum_{j=1}^{3}[q_t^-(j\mid h)]^{\gamma_s}}. \tag{42}$$

第一式压缩规则之间的旧信念差异，第二式压缩每条规则内部的配对差异。共用 γ_s 表示两类旧证据按相同的保持率衰减。每条规则继续保留自己的条件配对分布，规则与配对的关联随联合反馈更新。$\widetilde{\pi}_t^-$ 和 $\widetilde{q}_t^-$ 是本题反馈学习的中间分布；本题作答使用的仍是反馈前的 π_t^-。

当 $\gamma_s = 1$ 时，两类旧信念完整保留；当 $\gamma_s = 0$ 时，直接设置 $\widetilde{\pi}_t^-(h) = 1/N_t$ 与 $\widetilde{q}_t^-(k \mid h) = 1/3$，随后由当前反馈分配支持。

将遗忘后的两个分布相乘，再乘以反馈似然并归一化，得到联合更新：

$$\Pi_t^+(h,k) = \frac{\widetilde{\pi}_t^-(h)\widetilde{q}_t^-(k \mid h)\ell_t(h,k)}{\sum_{v\in\mathcal{A}_t}\sum_{k'=1}^{3}\widetilde{\pi}_t^-(v)\widetilde{q}_t^-(k' \mid v)\ell_t(v,k')}. \tag{43}$$

规则边际为 $\pi_t^+(h) = \sum_k \Pi_t^+(h,k)$，条件配对为 $q_t^+(k \mid h) = \Pi_t^+(h,k)/\pi_t^+(h)$。在反馈前或反馈后，若某条规则的边际为0，其条件配对均约定为均匀分布。规则的边际反馈似然为 $\ell_t(h) = \sum_k \widetilde{q}_t^-(k \mid h)\ell_t(h,k)$，因此规则间的更新由各自旧信念和该似然共同决定。

例如，两条规则的旧信念均为0.5。第一条规则的条件配对为 $(0.8, 0.1, 0.1)$，第二条在三种配对间均匀分配信念。若本题选择得到正确反馈，且两条规则给所选类别的概率均为0.6，则二者更新后的规则信念仍各为0.5；各自的配对分布按 γ_s 保留旧差异。该设计假定规则与配对证据共用保持率，完整模型仍为13项个体参数。分层遗忘已接入 `0923-full-v3`，其行为预测与参数可辨认性待检验。

配对信念均匀时，半分反馈给各规则的证据为 $[1 - p_{t,h}(y_t)]/3$，0分反馈给出的证据是该值的两倍。这个倍数对所有规则都相同，因此归一化后，两种反馈对规则之间的相对支持相同。它们对具体配对方案的支持仍可能不同。配对知识积累后，半分和0分可以给分类规则提供更具体的线索。

8.3 三值反馈怎样更新精度

精度更新与证据记忆共用式(42)中的 $\widetilde{q}_t^-$，即遗忘后、加入本题反馈前的条件配对分布。本题计算一次该分布，两个模块均从同一反馈前状态评价反馈。

给定配对 k，用 $\mathcal{Y}_k(y_t, r_t)$ 表示与选择及实际反馈相容的类别集合：

$$\mathcal{Y}_k(y_t, r_t) = \begin{cases} \{y_t\}, & r_t = 1, \\ \{\mathrm{mate}_k(y_t)\}, & r_t = 0.5, \\ \{1,2,3,4\} \setminus \{y_t, \mathrm{mate}_k(y_t)\}, & r_t = 0. \end{cases} \tag{44}$$

三种集合分别包含已选类别、同科另一类别和另科两个类别。用反馈前的条件配对信念对这些集合求平均，得到第6节所需的相容系数及反馈似然：

$$a_{t,h}(c) = \sum_{k=1}^{3} \widetilde{q}_t^-(k \mid h)\mathbb{I}[c \in \mathcal{Y}_k(y_t, r_t)], \tag{45}$$

$$\ell_t(h) = \sum_{c=1}^{4} a_{t,h}(c)p_{t,h}(c) = \sum_{k=1}^{3} \widetilde{q}_t^-(k \mid h)\ell_t(h,k). \tag{46}$$

相容系数表示当前配对知识下，各类别能够产生本次反馈的概率。将它代入式(31)计算反馈条件分布，再按式(32)与式(33)调整精度。本次精度微分固定本题距离和 $\widetilde{q}_t^-$；反馈后的配对信念 q_t^+ 保存用于候选衔接和后续试次。半分和0分分别允许不同的类别集合，因此可以产生不同的精度调整方向和幅度。搜索控制继续使用 $1 - r_t$，表示本题目标未达成的程度。

8.4 候选变化后保留配对知识

迁移前保存整体边际 $\bar{q}_t^{+}(k) = \sum_{h\in\mathcal{A}_t} \Pi_t^{+}(h,k)$。保留旧规则的条件配对，新规则继承 $\bar{q}_t^{+}$：

$$\Pi_{t+1}^{-}(h,k) = \pi_{t+1}^{-}(h) \begin{cases} q_t^{+}(k \mid h), & h\text{为保留的旧规则}, \\ \bar{q}_t^{+}(k), & h\text{为新规则}. \end{cases} \tag{47}$$

新规则继承此前积累的反应关系知识，局部与全局来源使用相同的继承规则。规则权重变化后，整体配对边际也可能变化。

配对的集中程度、配对正确性和按刺激分科的能力分别评价，同时报告科、种和平均分表现。

9 单试次顺序：哪些信息何时使用

第一题先按基础先验初始化一条候选及其精度；条件3还初始化配对信念。随后完成知觉、预测与作答，再进行反馈学习。

从第二题起，每题按照以下顺序进行：

1. 读取上一题保存的反馈与状态，递推失败状态 F_t、搜索概率 e_t 和全局比例 g_t。
2. 形成本题内部刺激 $\tilde{\boldsymbol{x}}_t$。假设更新读取此前反馈与候选状态，为本题准备候选集合。
3. 处理旧候选退出，将保留集合内的信念归一化；按 e_t 决定是否搜索新规则。
4. 发生搜索时生成一条新规则；容量已满时删除信念最低的旧规则，再归一化保留的旧信念，并按功能关系分配支持。
5. 保留旧规则的精度，新规则恢复初值；条件3同步设置规则与配对的联合信念。
6. 计算各候选的类别概率。选择读出形成 w_t，确定 $h_t^{\star}$，汇总选择概率。
7. 生成行为时按选择概率抽取答案；拟合时读取实际选择并更新粒子权重。
8. 收到反馈后计算各活跃规则的反馈似然；条件3计算规则与配对的联合反馈似然。
9. 证据记忆模块累积本题证据；精度更新模块使用更新前的规则预测调整精度。保存反馈，供下一题更新搜索控制。

代码在下一题开始时读取保存的反馈，完成失败状态递推，与式(10)的概念时序一致。本题回答使用本题反馈进入学习前的状态；反馈造成的变化影响下一题。

10 粒子滤波：推断可能的内部路径

10.1 行为预测与路径权重

设粒子数为 N_{PF}，用上标 (n) 标记第 n 条内部路径。其作答前权重为 $W_t^{(n),\mathrm{pre}}$，类别预测为 $p_t^{(n)}(c) = P(y_t = c \mid z_t^{(n)})$：

$$\widehat{P}_t(c) = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} p_t^{(n)}(c). \tag{48}$$

权重满足 $\sum_n W_t^{(n),\mathrm{pre}} = 1$。观察实际选择后，

$$W_t^{(n),\mathrm{choice}} = \frac{W_t^{(n),\mathrm{pre}} p_t^{(n)}(y_t)}{\sum_{n'=1}^{N_{\mathrm{PF}}} W_t^{(n'),\mathrm{pre}} p_t^{(n')}(y_t)}. \tag{49}$$

能解释选择的路径获得高权重；随后各路径按实际选择与反馈学习。路径权重是研究者对路径的判断，路径内规则信念是被试对候选的判断。

例如，两条路径原来各占一半，分别以0.8和0.2预测被试实际选择的答案，总体预测为0.5。观察这个选择后，两条路径的权重变为0.8和0.2。这使第一条内部过程在研究者的推断中获得更高权重；各路径内的规则信念按自身反馈更新。

有效样本量 $\mathrm{ESS}_t = 1/\sum_{n=1}^{N_{\mathrm{PF}}} (W_t^{(n),\mathrm{choice}})^2$ 衡量路径权重有多集中。所有粒子等权时，它等于粒子总数；少数粒子占据大部分权重时，它会下降。低于配置阈值后，按当前权重抽取新的粒子集合，这一操作称为重采样，使计算更多地分配给能解释行为的路径。抽中的粒子继承已有的候选、信念、精度、主导规则、失败与配对状态，并使用独立的后续随机流。

10.2 怎样读懂候选数量与参与程度

某规则出现在候选集合中的概率，可以按路径权重汇总其是否活跃：

$$\widehat{P}_t(h \in \mathcal{A}_t) = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} \mathbb{I}(h \in \mathcal{A}_t^{(n)}), \qquad \overline{N}_t = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} |\mathcal{A}_t^{(n)}|. \tag{50}$$

每条路径的候选数量是整数，加权平均可以是2.3，表示研究者对不同可能路径的汇总。有效参与数量先在每条路径内按式(37)计算，再按粒子权重平均。某规则成为主导的概率，则汇总各路径是否由它主导。

这些量分别回答：规则是否已被考虑，得到多少信念，对本题作答有多大贡献，以及是否成为贡献最大的规则。分析时将它们与候选数量、有效参与数量一起报告。

使用选择前权重 $W_t^{(n),\mathrm{pre}}$ 汇总，得到作答前的状态预测；使用 $W_t^{(n),\mathrm{choice}}$ 汇总，则得到结合本题实际选择后的在线推断。分析图应标明采用的权重和汇总时点。

11 个体参数估计：估计什么，怎样评价

11.1 参数清单

搜索控制与候选管理共9项，选择读出中的使用惯性1项，证据记忆1项，精度更新2项：

$$\begin{aligned}\boldsymbol{\theta}_s = (&e_{0,s}, a_{e,s}, \delta_s, g_{0,s}, a_{g,s}, M_s^{\max}, \rho_s, \omega_s, \tau_{\mathrm{tr},s}, \lambda_s,\\ &\gamma_s, \beta_{0,s}, \eta_s).\end{aligned} \tag{51}$$

行为模型包含13项被试参数。拟合前规定哪些参数自由估计、哪些固定，以及各项的估计范围。参数恢复使用已知参数生成模拟数据，再重新估计参数，检查这些参数能否被辨认。下表沿用三条件配置例值；学习率 $\eta_s = 0.1$ 用于小规模流程检查（smoke）。将学习率设为自由参数时，由选择数据与其他自由参数联合估计。`0923-full-v3` 已实现本设计，λ_s 按修订后的作答惯性解释。

参数	认知含义	数学范围	例值
$e_{0,s}$	基础搜索概率。	$(0,1)$	0.05
$a_{e,s}$	失败推动搜索的增益。	$[0,\infty)$	1.0
δ_s	失败状态保持。	$[0,1)$	0.6
$g_{0,s}$	基础全局比例。	$[0,1]$	0.2
$a_{g,s}$	失败对范围的增益。	$[0,1]$	0.5
$M_s^{\max}$	候选数量上限。	整数；$2 \le M_s^{\max} < J$	3
ρ_s	候选退出率。	$[0,1]$	0.1
ω_s	局部结构来源倾向。	$[0,1]$	0.5
$\tau_{\mathrm{tr},s}$	功能支持泛化尺度。	$(0,\infty)$	0.1
λ_s	上一主导规则的作答惯性。	$[0,\infty)$	1.0
γ_s	规则与条件配对共用的证据保持率。	$[0,1]$	0.8
$\beta_{0,s}$	新规则初始精度。	$[\beta_{\min}, \beta_{\max}]$	5.0
η_s	精度校准学习率。	$[0,1]$	0.1

知觉参数来自独立测量。规则信念、配对信念、失败状态、精度、实际候选数量和主导规则随试次变化。作答权重与有效参与数量由这些状态计算。

11.2 用反馈前选择概率评价参数

行为拟合使用平均选择负对数似然（negative log-likelihood，NLL）：

$$\mathrm{NLL}_{\mathrm{choice}}(\boldsymbol{\theta}_s) = -\frac{1}{T_{\mathrm{score}}} \sum_{t \in \mathcal{T}_{\mathrm{score}}} \log \widehat{P}_t(y_t; \boldsymbol{\theta}_s). \tag{52}$$

$\mathcal{T}_{\mathrm{score}}$ 是计分试次集合，$T_{\mathrm{score}} = |\mathcal{T}_{\mathrm{score}}|$ 是计分试次数。模型给实际选择的概率越低，该题的负对数似然越大；对计分试次取平均后，得到整段行为的拟合分数，分数越小表示预测越好。

计分使用本题反馈进入学习前的选择概率。应保存计分集合、试次顺序、训练／评价边界，以及粒子数、重复次数和种子等计算设置。多次独立运行时，先逐题平均类别

概率，再计算 NLL。先平均概率再取对数，与先计算各次 NLL 再平均，得到的分数会不同。

当前运行入口将第一条有效试次作为初始化试次，并从后续有效试次计算预测分数。训练与评价划分进一步确定计分集合，漏答记录保留原始位置标识。

粒子表示可能的隐藏路径，多次独立运行用于检查数值稳定性。参数估计的不确定性还需通过另行规定的统计方法评价。完整行为序列选出的参数在同序列上仍是样本内拟合，即使状态递推没有使用未来反馈。

11.3 完整参数搜索：分散发现、联合追加与独立审查

本流程将完整有效行为序列、独立测量的知觉参数和13项行为参数的共同支持表作为输入，交付入选参数、近优候选、逐题选择概率和验收状态。参数搜索在完整行为序列之外比较不同参数点；第5节的规则搜索则在每条内部学习路径中随反馈发生。估计程序复用共享的自适应控制器，按 Model 0826 Plus 第2节组织发现、追加、挑战和独立审查。

完整搜索支持表为 `configs/shared/model0923_adaptive_parameter_space.yaml`。其中候选容量为 $2, 3, 4, 6, 8$，每个参数的候选值、参考点和数学定义域均显式保存。当前将13个配置字段各视为一个参数块；联合提案同时改变两个字段。所有参数点保持 `0923-full-v3` 的认知方程、类别与反馈约定，以及固定的精度边界和规则目录。

11.3.1 分散起点与分层评分

从45个分散参数点开始。先在参考参数下覆盖5种容量，再对其余起点分层抽取各参数的候选值，使记忆、搜索、候选管理、惯性和精度也得到变化。用32粒子、4组种子发现候选，再将分数较好的8个、最多4个分散候选和最多2个随机抽查候选送入128粒子、16组种子的引导评分。后续搜索按引导分数选择起点；每个粒子预算下先平均逐题概率，再按式(52)计分。

同一评分角色中的不同候选共用随机种子。这种共同随机数设置有助于减小候选差值的计算波动。发现、引导和独立审查使用不同种子族；同一批数值证据的用途记录在输出中。新流程声明基础种子 `2026101401` 和 `model0923_adaptive_full_v1` 种子命名空间。粒子数和重复数属于数值积分预算，内部学习路径仍各自保存候选、信念和精度。

11.3.2 常规追加与搜索平台

每轮从最多两个较好且有差异的候选出发，每个至多48个提案：25%用于相邻值调整，25%用于单块远跳，50%用于同时改变两个参数块；另加入18个分散点。已有参数点复用同角色、同粒子数和同种子的概率文件。去重后实际提案数量可以减少。

每个搜索循环最多四轮。连续两轮的最佳引导分数改善不超过平均NLL 0.001时，记录搜索平台；达到四轮上限时仍需根据实际改善另记状态。平台说明当前提案方式近期找到的改善较小，搜索覆盖由后续挑战继续检查。

11.3.3 联合挑战与边界提案

常规追加结束后执行一轮挑战：从最多两个较好候选再次生成混合提案，并加入90个分散点。对最多两个得分接近、触及人为边界的候选，各追加4个混合提案和4个方向提案。边界提案直接进入引导评分，保留它们作为必须检查的点。

数学定义域中的闭合端点记录为机制边界，例如 $g_{0,s}=1$、$\eta_s=0$ 或 $\gamma_s=1$；候选支持表中的有限端点若位于数学定义域内部，则记录为人为边界。当前扩展表为空，边界提案使用原支持内的允许值。人为边界保留 `boundary_review_required`，范围外扩展须事先共同声明合法值和预算。

11.3.4 冻结候选后做一层分级独立审查

审查前冻结最终提名、挑战前代表、挑战后代表和复核库。复核库保留常规搜索前4名、挑战前4名及必要代表。使用新的共同种子，同时评价两个预先规定的问题：最终提名相对复核库最佳者的平均NLL损失是否小于实用容差0.005，以及挑战是否带来超过0.005的可靠改善。

独立审查从128粒子、16组种子开始。若尚未确认需要重搜，且任一比较仍不明确，则升到256粒子、32组种子。同一粒子数下复用同一独立种子族的前缀；粒子数增加后重新计算该档概率。审查在满足判断条件后结束，该批概率同时用于诊断和后续行为图。

以完整PF种子为单位做6000次配对bootstrap，估计固定数据、固定候选下的数值损失区间。总 $\alpha=0.05$ 按两个问题、两个预算档和最多两个循环分配，默认每项每次为0.00625。损失上界不超过0.005时记为本库内可接受，下界超过0.005时记为提名较差，其余记为不确定。这些区间描述有限粒子和随机种子的计算波动；参数的统计区间、粒子积分偏差及参数恢复分别检验。

若独立审查确认提名较差、确认挑战有实用改善，或常规搜索仍未出现平台，则再开一个搜索循环，最多两循环。已见审查结果可以用于指定下一轮的起点，下一轮使用新的审查种子。数值不确定到顶后保留 `unresolved` 与近优候选。

11.3.5 停止状态、旧结果复用与后分析

搜索平台、独立评分、挑战和边界四项均通过时，输出 `provisional_stop_within_tested_scope`，表示在本次已检验范围内暂时停止。其余情况保存入选参数和候选库，并逐项列出搜索预算、评分、挑战或边界的未解决原因。流程完成状态记录程序是否运行结束，验收状态记录各项证据是否满足停止条件。

已有12人的两起点、每起点最多三轮Hyper-CD结果保留为初始搜索记录。兼容的完整参数点可作为额外候选进入新流程，并统一使用新引导种子评分。旧概率文件只有在参数、数据、模型设置、粒子数、种子和预测时点均一致时才可作为同一数值任务的缓存；独立审查按预先声明的新种子族计算。

完整流程保存逐种子的类别概率、实际选择、计分掩码、参数来源、预算、种子、提案与停止记录，以及数据和源码指纹。绘制条件预测图时，复用所需角色的已保存概率。内部表征需要的详细状态尚未保存时，再固定参数生成并检查状态精度。自主行为由模型自己的选择和反馈递推；学习曲线及达标能力作为独立的生成检验。

正式入口为 `python -m src.Bayesian_state.run_model_0923_fit`。MEG 335配置为 `configs/meg/model0923_adaptive_335.yaml`，随后exp123 307使用 `configs/exp123/specific_models/model0923_adaptive_307.yaml`，并导入原4组入围

候选。MEG配置保留均匀知觉误差和 `iSession,iRun,iTrial` 顺序；exp123配置保留该实验的知觉测量和 `iSession,iBlock,iTrial` 顺序。正式运行最多128个worker，每个一个数值线程，使用单层进程并行；短检查使用一个被试、32个有效试次、2粒子、2组种子和一个worker。

11.4 可识别性与行为生成的验收

当失败对搜索的影响很小时，行为数据对失败保持参数 δ_s 的约束较弱；$g_{0,s}$ 接近1时，$a_{g,s}$ 对全局比例的进一步影响也很小。结构编辑与功能相似性给出的抽取概率接近，或结构编辑经常没有可用的新规则时，ω_s 较难估计。候选数量很少达到上限时，容量参数也可能只能确定一个较宽的范围。信念迁移尺度、使用惯性、精度和记忆的作用还可能互相补偿，需要通过参数恢复与针对性模型比较检查。

是否达到与0826相当的效果，需要在可比数据、计分试次和计算预算下，分别比较选择预测与学习过程。各项比较的指标和允许差异在分析前确定。

12 个体评估：固定参数后逐人检查什么

本节以第11节保存的入选参数、搜索记录和原始试次顺序为输入，规定每位被试的评估步骤与交付内容。评估固定13项行为参数，依次检查输入与搜索、选择预测、数值稳定性、内部状态和自主学习。各步骤回答不同的问题，报告分别保存其结果与状态。统一协议标识为 `model0923_subject_evaluation_v1`；同一版本采用相同的步骤、指标和文件名，实际预算、任务标准和执行状态由配置与清单记录。

12.1 第一步：核对输入、参数来源和搜索状态

先确认源拟合程序已完成，读取被试编号、条件、入选参数、规则目录、数据文件及源码指纹。指纹是文件内容的哈希值，用于检查输入是否发生变化。初始 Hyper-CD 与完整自适应搜索使用不同的结果布局，输入适配器将二者转换为同一评估接口，同时保留原始格式与验收状态。初始搜索记录标为 `initial_search_only`；完整搜索逐项保留平台、独立评分、挑战与边界检查的结论。

随后核对完整有效试次数、首题初始化、漏答过滤和原始试次键。每条记录保留 session、run 或 block、trial 等现存标识。参数、数据、任务编码与认知计算源码必须符合源拟合记录；变化后的评价和绘图源码单独登记。数值核心或数据指纹不一致时，评估终止并报告具体文件。旧结果继续由其冻结版本解释。

参数审查逐项列出估计值、搜索支持范围、数学边界或人为范围端点，并标记入选组合下影响通道关闭的参数。例如，全局搜索比例为1时，局部来源倾向与失败对全局比例的增益处于条件性不可辨识状态。程序完成、有限范围内拟合验收和参数可解释性分别报告。

12.2 第二步：检查真实历史条件下的选择预测

固定参数后，以真实刺激、此前选择和反馈递推状态。当前题的类别概率在观察当前选择之前取得，再由实际选择评价。第一条有效试次用于初始化，后续有效试次进入计分集合。跨独立PF种子先逐题平均类别概率，再用式(52)计算平均选择NLL。

每人固定报告平均选择NLL、多类别Brier分数和相对均匀选择的改善。Brier分数衡量整个类别分布与实际选择之间的平方差：

$$\mathrm{Brier}_s = \frac{1}{T_{\mathrm{score}}} \sum_{t \in \mathcal{T}_{\mathrm{score}}} \sum_{c=1}^{C} \left[\overline{P}_t(c) - \mathbb{I}(y_t = c) \right]^2 . \tag{53}$$

这里 $\overline{P}_t(c)$ 是跨PF种子平均后的反馈前类别概率，C 是类别数，$\mathbb{I}(y_t = c)$ 在实际选择为类别 c 时等于1，其余等于0。类别平方差相加后对计分试次取平均，分数越小表示预测分布越接近实际选择。均匀选择的平均NLL为 $\log C$，改善量为 $\log C - \mathrm{NLL}_{\mathrm{choice}}$；正值表示优于本条件的均匀选择基线。

逐题表保存各类别概率、实际选择的概率、单题NLL和计分掩码。行为图同时展示真实精确正确率、条件预测的正确概率、单题NLL及正确率残差。精确正确指反馈等于1；条件3分别保存种正确率、科正确率和平均得分的真实值、条件预测值及自主轨迹分布；半分保留为原始得分。滚动曲线默认使用32个有效试次，分段描述从第二条有效试次开始，每64题一段；末期描述使用最后64个计分试次，短序列使用实际可用长度。

这些参数来自完整观察序列，因此同序列的预测分数属于样本内描述。留出预测需要预先确定时间边界，仅用训练段估计参数，再冻结参数评价留出段。该专项检验的执行状态单独登记。

12.3 第三步：检查数值复现与粒子预算敏感性

先按源拟合保存的原始粒子数和种子重放入选参数的单次评分，将平均选择NLL与保存值比较，绝对容差为 10^{-12}。原始重放使用源记录自己的预算，独立评估使用新种子。源重放失败时，评估保留未完成状态并报告差值。

默认独立评估使用128粒子、16组PF种子，基础分析种子为 `2026101301`，种子角色为 `model0923_postfit_independent_pf`。每人比较前8组与全部16组种子的平均概率评分，再将前4组相同种子分别用128和256粒子计算。配对预算检查保存NLL差值及逐题类别概率的平均、最大绝对差值。每人均执行相同的配对检查，预算按配置保存。

同时保存作答前与观察当前选择后的有效样本量ESS占粒子数的比例，以及各题发生重采样的种子比例。较低ESS表示路径权重集中；预算差值描述当前数值积分的敏感性。当前v1报告这些诊断量，数值稳定性的共同验收门槛尚待规定。结果状态为“已测量，尚未设置验收门槛”。搜索阶段的独立候选验收仍沿用第11.3节的规则。

PF种子变化描述固定数据、固定参数下的数值波动。参数统计区间需要额外的数据层面分析；两类不确定性分别保存。

12.4 第四步：检查内部表征与状态时序

每人保存两组在线边际分布：一组在当前选择之前，另一组在观察当前选择之后；两组均位于当前反馈之前。前一组用于行为预测，后一组用于展示哪些内部状态更能解释本题实际选择。表征图固定使用后一组，条件3的配对面板另标明其反馈后时点。

固定输出包括完整规则目录、逐题候选包含概率、规则信念、作答贡献、主导规则概率、候选数量、有效参与数量、作答加权精度，以及搜索概率、全局来源比例、失败状态和候选进入事件。候选数量与有效参与数量先在每条路径内计算，再按粒子权重及等权PF种子汇总。逐题均值和10%--90%范围描述固定入选参数下的隐藏状态分布。

检查概率有限、非负且归一化，候选数量满足容量上限，有效参与数量不超过同路径候选数量，状态数组与有效试次逐项对应。候选包含概率、规则信念与作答贡献分别回答“是否正在考虑”“有多可信”和“对本题回答影响多大”。主导规则和配对知识也分别保存，供第13节解释。

本步骤交付逐题状态边际。完整内部路径的转变时点、路径形态和祖先充分性需要保留连续路径，并通过单独的路径评价协议检验。该专项检验在v1清单中标记执行状态。

12.5 第五步：检查模型自主学习及实验达标

每人默认生成64条独立自主轨迹。各轨迹沿用真实刺激顺序和有效长度，模型按自己的类别概率抽取答案，由任务规则给出该答案的反馈，再以自己的选择和反馈更新后续状态。真实选择参与前述条件预测；自主轨迹中的每次回答由模型生成。

固定报告整体、早期、末期与各64题段的精确正确率，以及自主预期正确概率的10%、50%、90%分位数。描述性目标正确率默认设为0.8，用于统计各段达到该水平的轨迹比例。行为图保存逐点自主学习曲线范围，完整选择、反馈、预期正确概率和随机种子保留在轨迹文件中。

实验达标按任务自身的标准另行计算。exp123原程序以64题正式区块为单位，排除模糊刺激后分别计算各类别的精确正确率，所有类别均达到90%时记为该区块达标。该统计包含区块首题。配置中的区块大小和阈值须与原程序一致；报告列出各区块真实达标情况、模拟达标比例及每条轨迹首次达标的区块。不完整区块保留明确状态，全部区块不完整时也保留相同的输出文件。MEG Task3b的实验结束标准尚待独立核对和配置，其任务达标步骤记录为“未配置”。

自主结果描述固定真实刺激顺序及记录长度内的学习能力。原实验根据表现调整后续刺激，并在达标时结束；完整自适应实验生成需要按每条模拟轨迹重建这两步。逐点学习范围、整段轨迹覆盖及实验停止分布分别检验。

12.6 固定报告、代码入口与专项检验状态

每人固定生成三张PNG：`behavior.png`展示条件预测与自主行为，`representations.png`展示内部状态，`diagnostics.png`展示ESS、搜索控制与配对粒子预算差异。总体固定生成参数审查和评分对照两张PNG；S名被试共交付 $3S + 2$ 张图。逐题与规则状态表、种子评分表、预算差值表、学习分段表、任务区块表和步骤状态文件均使用固定名称。必需产物缺失时，统一清单保留未完成状态。

统一入口为 `python -m CategoryLearning_codes.figures.fig3.model0923_evaluation`。共享评估流程位于 `src/Bayesian_state/workflows/analysis/evaluate_model_0923.py`；协议与产物契约位于 `src/Bayesian_state/evaluation/model_0923_protocol.py`；数值计算复用现有共享指标和模型核心。exp123与MEG各提供一份v1配置，具体命令见实现与运行说明。历史后分析和通用评价入口保留原用途，Model 0923逐人标准报告由本入口交付。

每次评估使用新的报告与图目录，清单记录协议版本、入选参数来源、数据与源码指纹、实际预算、种子、试次时序、图表文件及执行状态。短检查仅使用首位配置被试、16个有效试次、4粒子、2组种子、2条自主轨迹和一个worker，并用8粒子做配对通路检查；原始完整评分复现与任务达标保留“短检查未执行”状态。

留出预测、参数统计区间、参数恢复、状态与模型恢复、机制比较、口述验证、完整内部路径及自适应实验生成分别登记为专项检验。未执行项目在每位被试报告中保留

“尚未执行”。数值复现、样本内选择预测和自主行为描述提供各自范围内的证据；参数个体差异和认知机理结论随相应专项证据确定。

13 从模块状态到认知机理解释

13.1 发现、支持和参与分开看

相近正确率可能来自不同过程：尚未想到有效规则，规则已进入候选集合但信念较低，信念提高后作答惯性仍偏向旧规则，或规则已有较大作答贡献但精度较低。分析时联合查看候选可访问性（规则出现在活跃集合中的概率）、信念、作答权重和精度。进入集合到成为主导规则的时间差反映新规则从被考虑到明显影响回答的过程。

这些轨迹是模型根据选择和历史反馈，对隐藏学习过程作出的推断。候选、信念、作答权重和精度分别表示不同环节，使模型能够提出可检验的解释。现有数据能否分别辨认这些环节，还需通过参数恢复和模型比较检查。

13.2 候选数量变化的含义

连续成功使失败回落、搜索减少，低信念候选仍可退出，集合可能收缩到一条。再次失败可以增加新规则，集合扩张。信念较低且仍在集合内的规则继续参与学习；已退出的规则通过后续搜索重新进入。作答权重集中也可在集合尚有多条时出现。

13.3 结构与功能变化分别量化

只改一个特征就可能改变很多分类；两条分类结果相近的规则，也可能包含很不同的判断步骤。分析编辑类型、功能距离和来源，有助于区分调整思路与想到功能相近的另一解释。共同距离和编辑成本给出可复现的关系定义。

后续机理图可以展示候选何时进入、信念怎样积累、作答权重何时集中、主导规则何时切换，以及精度怎样变化。图中同时呈现不同粒子路径的不确定性。快速学会、逐渐改善和晚期突变是模型需要解释的行为现象；拟合时输入选择及历史反馈，通过上述轨迹检验模型的解释。

A　四分类目录的完整分组

下表按实际家族计数。交叉表示同时使用两个判断，条件分支表示先判断、再在相应分支区分。

代码家族	内容	数量
2d_axis_pair	两个单特征阈值交叉。	6
2d_equality_sum	同一特征对的顺序与和交叉。	6
3d_axis_equality	单特征阈值与另两特征顺序。	12
3d_axis_sum	单特征阈值与另两特征和。	12
3d_axis_triple	三阈值的条件分支。	24
3d_axis_equality_sum	阈值分支下顺序或和。	24
4d_equality_pair	不重叠特征对的顺序交叉。	3
4d_sum_pair	不重叠特征对的和交叉。	3
4d_equality_axis_pair	顺序分支与剩余特征阈值。	12
4d_sum_axis_pair	和分支与剩余特征阈值。	12
dimension_max/min	最大／最小特征分类。	2
axis_pair_overlap	阈值与共享一特征的顺序交叉。	12
shared_pair_comparisons	围绕同一部位做两次比较。	12
similarity_axis_disjoint	两部位是否相近与第三部位长短交叉。	12
合计		152

规则程序用于检查规则表示，并确定一步编辑能够到达哪些规则；类别概率由共享几何计算。程序判断与几何区域的标签对应已核对。

B 辅助符号索引

核心状态见第2.5节；这里按使用位置列出辅助符号。同一规则索引中的 h, u, v 分别用于当前规则、新规则和求和中的其他规则。类别用 c, c' 编号。上下标中的文字标签标明用途。

符号	定义或用途
知觉、预测与反馈	
$\varepsilon_{t,j}$	本题第 j 个特征的知觉误差。
$\mathcal{C}_{h,c}, \boldsymbol{\xi}, d_{t,h,c}$	规则的类别区域、区域中的几何点、内部刺激到该区域的距离。
$c_h(\boldsymbol{x}), p_0(h)$	规则给出的确定类别，以及规则的基础先验。
$\ell_t(h,k), \ell_t(h;\beta)$	规则与配对下的反馈似然，以及固定本题其他状态时随精度变化的反馈似然。
$a_{t,h}(c), p_t^{\mathrm{fb}}(c \mid h)$	类别与实际反馈的相容系数，以及按该反馈重新加权的类别分布。
$\kappa_t(h), \eta_s$	反馈对数似然对精度的梯度，以及被试的精度学习率。
候选管理与搜索	
$\mathcal{D}_t, \mathcal{A}_t^{\mathrm{ret}}, \mathcal{A}_t^{\mathrm{keep}}$	实际退出集合、退出后集合、容量处理后保留的旧集合。
$\mathcal{U}_t, \mathcal{N}_t(h)$	本轮可引入的规则，以及其中可由 h 一步编辑得到的邻居。
$I_{t+1}^{\mathrm{search}}, h_t^{\mathrm{drop}}$	下一题前是否搜索的二值事件，以及容量满时删除的旧规则。
$\mathcal{E}(h), \mathrm{op}, c_{\mathrm{edit}}(\mathrm{op})$	合法编辑集合、一次编辑及其成本。
$d_{\mathrm{edit}}(h,u), d_{\mathrm{func}}(h,u)$	编辑距离与功能距离。
$\mu_X, T_{cc'}(h,u), S(h,u)$	参考刺激分布、类别对应比例与分类一致率。
$K_{\mathrm{edit},t}, K_{\mathrm{func},t}, K_{\mathrm{loc},t}$	给定旧规则时，按结构编辑、功能相似性或两者结合抽取新规则的概率。
$Q_{\mathrm{loc},t}, Q_{\mathrm{glob},t}, Q_t$	考虑各起点后，局部搜索、全局搜索及两者结合时的新规则抽取概率。
$\tau_{\mathrm{prop}}, \chi_s(h,u)$	功能搜索的共同距离尺度，以及信念分配中的亲和度。
选择读出	
$N_{\mathrm{eff},t}$	由作答权重计算的有效参与数量。
配对学习、粒子推断与计分	
$\mathcal{G}_k, \mathrm{mate}_k(y)$	第 k 种反应配对，以及该配对下与 y 同科的另一个反应。
$\widetilde{\pi}_t^-(h), \widetilde{q}_t^-(k \mid h)$	旧证据分别衰减并归一化后、本题反馈进入前的规则信念与条件配对信念。
$\mathcal{Y}_k(y_t, r_t)$	给定配对 k 时，与实际选择和反馈相容的类别集合。
$z_t^{(n)}, p_t^{(n)}(c)$	第 n 条内部路径的状态与类别预测。
$W_t^{(n),\mathrm{choice}}, \mathrm{ESS}_t$	按实际选择更新的粒子权重，以及粒子有效样本量。
$\widehat{P}_t, \overline{N}_t$	粒子加权预测分布，以及候选数量的粒子加权平均。
$\mathcal{T}_{\mathrm{score}}, T_{\mathrm{score}}$	计分试次集合与其大小。
$\mathbb{I}[\cdot]$	指示函数，条件成立时为1，否则为0。