Model 0923：有限候选与反馈学习

以认知模块为线索的完整模型说明

2026年10月11日

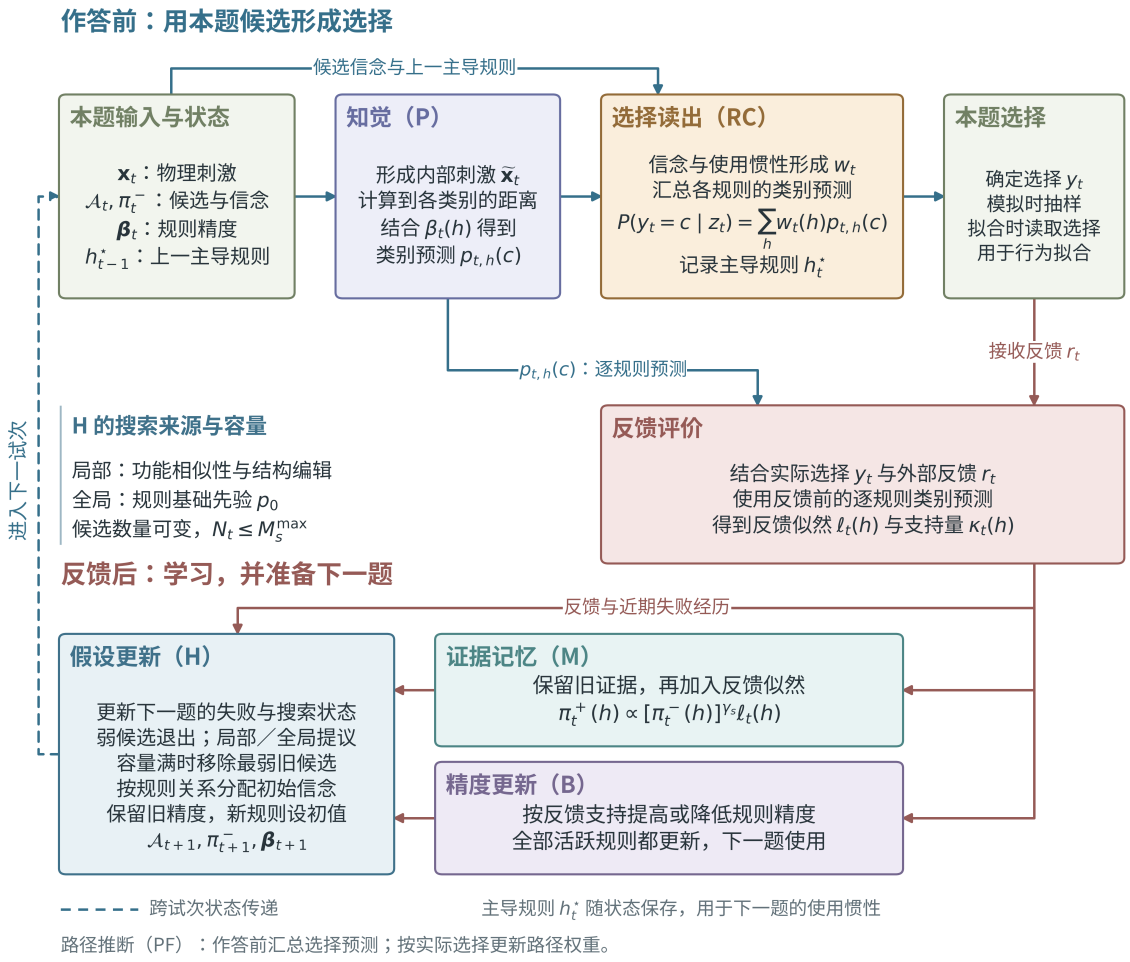


图 1: Model 0923 的机制总览。知觉模块形成内部刺激，各条规则的类别预测供选择读出和反馈评价共用。选择读出汇总作答概率。收到反馈后，证据记忆与精度更新并行调整规则信念和预测精度，假设更新为下一题准备候选。虚线表示跨试次状态传递。选择数据用于估计参数和更新粒子权重。图示为修订设计。图中反馈更新以二值任务为例，条件3的配对学习见第11节。

本文给出 Model 0923 的修订设计。目标是用简洁、容易解释的机制，保持0826的行为预测能力。搜索控制、规则目录、信念与精度更新已有实现；本文重写的候选准入与连续作答权重机制尚待同步代码。

正文先介绍任务、规则表示和证据更新，再说明各认知模块怎样完成一次学习过程。第5节统一说明假设更新模块的搜索与候选管理，第7节说明选择读出。被试参数在同一被试内保持不变，状态随试次递推。

行为参数由选择数据估计。规则信念由反馈更新，粒子权重按实际选择更新。

目录

1 模型概述：几个认知模块怎样一起工作 3
2 任务输入、规则目录与潜在状态 4
3 知觉模块（P）：从刺激到规则预测 6
4 证据记忆模块（M）：根据反馈更新规则信念 7
5 假设更新模块（H）：搜索与候选管理 7
6 精度更新模块（B）：调整规则预测的明确程度 13
7 选择读出模块（RC）：从规则权重到类别选择 14
8 单试次顺序：哪些信息何时使用 16
9 粒子滤波：推断可能的内部路径 17
10 个体参数估计：估计什么，怎样评价 18
11 条件3：层级反馈与配对学习 19
12 从模块状态到认知机理解释 21
A 四分类目录的完整分组 22
B 辅助符号索引 23

1　模型概述：几个认知模块怎样一起工作

模型假设，学习者每次只考虑少量规则。他可能同时保留“看脖子长短”和“比较脖子与尾巴”这两种解释，却在当前题主要使用其中一条。收到反馈后，他会重新评价这些解释，也可能想到一条新规则，或不再考虑某条弱规则。候选数量可以变化，容量只规定最多能同时保留多少条。

规则信念表示“在当前候选中，更相信哪条”；作答权重表示“本题判断受哪条影响较多”；规则精度表示“按这条规则判断，类别预测有多明确”。作答权重由信念和上一题的主导规则共同形成，权重分散时多条规则共同影响回答，集中时一条规则主导回答。精度越高，单条规则的类别预测越集中；这条规则是否可信，仍由反馈评价。

学习者先作答，之后收到外部反馈。模型根据这次反馈更新规则信念和精度，并为下一题准备候选。

模型按功能分为知觉（P，perception）、证据记忆（M，memory）、假设更新（H，hypothesis updating）和精度更新（B）四个模块。B 对应精度参数 β。选择读出模块（RC，choice readout）将各规则的类别预测汇总为选择概率。各模块的职责如下。

模块	处理的问题	主要输出
知觉（P）	形成怎样的内部刺激？各条规则怎样预测类别？	内部刺激 $\tilde{\boldsymbol{x}}_t$；类别概率 $p_{t,h}(c)$。
证据记忆（M）	反馈怎样改变候选的可信程度？	反馈后信念 π_t^+；条件3还更新配对信念。
假设更新（H）	何时搜索？哪些规则进入或退出候选集合？	失败状态 F_{t+1}、搜索概率 e_{t+1}、全局比例 g_{t+1}；下一题候选 $\mathcal{A}_{t+1}$ 及信念 π_{t+1}^-。
精度更新（B）	反馈使规则的类别预测更明确还是更模糊？	更新后的规则精度 $\beta_{t+1}(h)$。
选择读出（RC）	各候选对本题作答有多大影响？选择概率是多少？	作答权重 w_t、主导规则 $h_t^\star$ 与选择概率 $P(y_t = c \mid z_t)$。

模型统一命名为 `model_0923`，完整模型称为 full model。后续消融名称按保留的 P、M、H、B 模块组合，例如 PMH；RC 的设置随配置说明。每种消融还需规定被去掉模块的固定设置和状态处理。完整模型的学习结构为 PMHB，当前运行入口为 full。

选择读出使用本题内部刺激、规则预测和作答权重，得到的选择概率用于行为拟合。

粒子滤波（particle filter，PF）用于推断这些隐藏过程。每个粒子代表一条可能的内部学习路径。把多条路径的预测按权重汇总，可以同时计算行为预测和内部状态的不确定性。

2　任务输入、规则目录与潜在状态

2.1　每题输入什么

对被试 s 的第 t 题，物理刺激、实际选择和外部反馈分别记为

$$\boldsymbol{x}_{s,t} \in [0,1]^4, \qquad y_{s,t} \in \{1,\dots,C\}, \qquad r_{s,t}. \tag{1}$$

四维刺激记录四个部位的归一化长度，按该被试任务的实际特征顺序排列。

条件1为二分类二值反馈，$C = 2$，$r_t \in \{0,1\}$；条件2为四分类二值反馈，$C = 4$，$r_t \in \{0,1\}$；条件3为四分类三值反馈，$r_t \in \{0,0.5,1\}$。下文省略观测量和状态量的被试下标 s，被试层面参数始终保留 s。

实际选择用于计算行为分数和修正粒子权重，选择与反馈随后用于被试模型的学习。反应时不进入本版模型。

搜索和学习根据历史反馈与候选状态进行。真实类别用于环境评分和结果评价。条件3从三种配对等可能的初始信念开始学习。

2.2　固定规则目录

目录记为 $\mathcal{H} = \{1,\dots,J\}$。条件1有29条规则：

规则形式	判断例子或边界	数量
单特征阈值	$x_i \le 0.5$，按某个部位的长短分类。	4
两个特征的顺序	$x_i \le x_j$，比较脖子和尾巴。	6
两个特征的和	$x_i + x_j \le 1$。	6
两组特征和的顺序	$x_i + x_j \le x_k + x_l$。	3
两个特征是否接近	$\lvert x_i - x_j\rvert \le 0.10$。	6
单特征是否在中间	$\lvert x_i - 0.5\rvert \le 0.10$。	4

条件2和3使用152条四分类规则，包括两个判断的交叉组合、条件分支、最大／最小特征，以及共享判断特征的组合。完整分组见附录A。其中，有12条规则围绕同一个部位做两次比较，例如同时判断脖子是否比腿长、是否比尾巴长；另有12条规则先判断两个部位是否相近，再判断第三个部位的长短。相近的容差为0.10，第三个部位的长短分界为0.5。三条件分别使用与各自类别数相匹配的规则目录。

每条规则的类别区域及标签固定。目录定义模型允许考虑的解释范围；被试当前考虑的规则由候选集合表示。

基础先验 p_0 表示尚无学习证据时各条规则被考虑的概率，在相应目录内均匀：

$$p_0(h) = 1/J, \qquad h \in \mathcal{H}. \tag{2}$$

它为初始候选、全局搜索和按功能相似性进行的局部搜索提供基础权重，各被试使用同一目录定义。

2.3　容量上限与初始候选

容量参数为 $M_s^{\max}$，实际集合为 $\mathcal{A}_t$，数量为 N_t：

$$\mathcal{A}_t \subset \mathcal{H}, \qquad N_t = |\mathcal{A}_t|, \qquad 1 \le N_t \le M_s^{\max}. \tag{3}$$

实际候选数量随学习过程变化。第一题从 p_0 抽取一条规则，令 $\mathcal{A}_1 = \{h_1\}$，由它作答。要求整数 $2 \le M_s^{\max} < J$，以允许旧候选和新规则同时保留，并使目录中存在非活跃候选；实际数量仍可以为1。

只保留一条候选时，其候选内信念为1，表示当前的相对信念全部集中在这一个解释上。它的精度继续根据反馈调整，近期失败也继续影响后续搜索。因此，模型可以从一条候选开始，并在需要时考虑新规则。

2.4 需要保存哪些状态

候选、信念和精度等内部量无法从行为中直接观察，统称为潜在状态。每条内部路径保存一组可能的状态；作答前状态记为

$$z_t = \big(\widetilde{\boldsymbol{x}}_t, \mathcal{A}_t, \pi_t^-, F_t, \boldsymbol{\beta}_t, h_{t-1}^\star, \Pi_t^- \ \text{（仅条件3）}\big). \tag{4}$$

其中，内部刺激记录本题被知觉到的特征；候选集合与信念记录当前考虑哪些解释，以及各解释的可信程度。失败状态汇总此前反馈，精度向量保存各规则的预测精度，上一题主导规则用于计算使用惯性。条件3还保存规则与配对方案的联合信念 Π_t^-，详见第11节。

π_t^- 在活跃集合内归一化，非活跃规则的信念为0。上一题主导规则可能已退出当前集合；第一题尚无上一主导规则，惯性加成统一为1。模型由这些状态计算本题作答权重 w_t 和主导规则 $h_t^\star$。

2.5 符号约定与阅读方法

下标 t 表示试次，s 表示被试，j 表示刺激特征，h 表示规则，k 表示条件3的配对方案。参数保留被试下标，状态和观测省略这一层下标。粗体表示向量，花体表示集合；附录B集中列出各模块的辅助符号，个体参数见第10节。

规则信念的上标用于标明时点或处理阶段：$-$ 表示候选管理完成后的作答前信念，$+$ 表示本题反馈更新后的信念，ret 表示退出处理后，keep 表示容量处理后。后两个量都是从第 t 题走向第 $t+1$ 题时的中间结果。这些上标均为标签。

符号	含义
$\boldsymbol{x}_t, \widetilde{\boldsymbol{x}}_t$	物理刺激与知觉形成的内部刺激。
y_t, r_t	实际选择与外部反馈。
$\mathcal{H}, J, C$	完整规则目录、规则总数与类别总数。
$\mathcal{A}_t, N_t, M_s^{\max}$	活跃候选集合、实际候选数与被试容量上限。
$\pi_t^-(h), \pi_t^+(h)$	作答前、反馈后的相对规则信念。
$\pi_t^{\text{ret}}, \pi_t^{\text{keep}}$	退出后、容量处理后的旧规则信念，各自在对应集合内归一化。
$\beta_t(h), p_{t,h}(c)$	规则精度，以及该规则给类别 c 的预测概率。
$\ell_t(h), \kappa_t(h)$	反馈似然，以及用于精度更新的反馈支持量。
f_t, F_t	本题失败程度，以及进入本题的累计失败状态。
e_t, g_t	搜索启动概率，以及搜索发生时采用全局来源的概率。
$w_t(h), h_t^\star$	规则的作答贡献，以及贡献最大的主导规则。
$\Pi_t^{\pm}(h,k)$	规则与配对方案的联合信念。

符号	含义
$q_t^{\pm}(k \mid h), \bar{q}_t^{+}(k)$	给定规则的条件配对信念，以及反馈后的整体配对信念。
$z_t, \boldsymbol{\theta}_s$	一条内部路径的作答前状态，以及被试行为参数向量。
$N_{\mathrm{PF}}, W_t^{(n),\mathrm{pre}}$	粒子数，以及第 n 条路径的作答前权重。

π_t、w_t 和 $W_t^{(n),\mathrm{pre}}$ 分别描述规则可信程度、规则作答贡献和研究者对内部路径的权重。前两者在一条路径内部定义，粒子权重用于汇总多条路径的预测。

3 知觉模块（P）：从刺激到规则预测

知觉模块将物理刺激转为带有误差的内部刺激。随后，各条规则结合自己的精度，给出类别预测。这些预测供选择读出和反馈评价共同使用。

3.1 形成带有误差的内部刺激

同一物理刺激在不同试次可以引起略有差异的知觉：

$$\widetilde{x}_{t,j} = \mathrm{clip}(x_{t,j} + \varepsilon_{t,j}, 0, 1). \tag{5}$$

$\mathrm{clip}(v, 0, 1) = \min\{1, \max\{0, v\}\}$ 将内部刺激限制在合法特征范围。误差参数来自学习任务前的独立知觉测量，并按实际特征顺序排列。当前个体化配置通常使用测量得到的逐维正态误差；共享模块也允许按测量定义使用均匀误差。具体分布与参数以运行配置为准。

各条规则使用本题的同一内部刺激形成预测。粒子分别模拟可能的知觉结果，随机流独立且可复现。

3.2 单条规则怎样给出类别概率

规则 h 将刺激空间划分为类别区域 $\mathcal{C}_{h,1}, \ldots, \mathcal{C}_{h,C}$。每个区域包含按该规则会被分到同一类别的所有刺激。例如，以脖子长度0.5为界的规则，把脖子不超过0.5和超过0.5的刺激分别划入两个区域。

距离表示当前内部刺激至少改变多少，才能进入某个类别区域。模型计算到各区域的最短欧氏距离：

$$d_{t,h,c} = \inf_{\boldsymbol{\xi} \in \mathcal{C}_{h,c}} \|\widetilde{\boldsymbol{x}}_t - \boldsymbol{\xi}\|_2. \tag{6}$$

内部刺激落在某类别区域内时，到该区域的距离为0；一个类别有多个分离区域时，取最近区域的距离。模型再用精度参数将这些距离转为类别概率：

$$p_{t,h}(c) = \frac{\exp[-\beta_t(h) d_{t,h,c}]}{\sum_{a=1}^{C} \exp[-\beta_t(h) d_{t,h,a}]}. \tag{7}$$

精度越高，较近类别越占优势；精度越低，预测越接近均匀。知觉误差改变输入，精度改变对距离的反应，作用位置不同。

这里得到的是每条规则对各类别的预测。选择读出按规则权重汇总这些预测；收到反馈后，证据记忆和精度更新模块用同一组预测评价结果。

4　证据记忆模块（M）：根据反馈更新规则信念

证据记忆模块在收到反馈后，重新比较各条活跃规则的可信程度。它先计算每条规则能以多大概率解释这次反馈，再将当前证据与保留下来的旧证据结合。

4.1　规则是否能解释当前反馈

给定实际选择 y_t，规则 h 预测到本次二值反馈的概率，即反馈似然，为

$$\ell_t(h) = r_t p_{t,h}(y_t) + (1 - r_t)[1 - p_{t,h}(y_t)]. \tag{8}$$

答对支持能预测已选类别的规则；答错支持倾向其他类别的规则。四分类错误反馈提供“当前所选答案错误”这一信息，对应其余三个类别的总概率 $1 - p_{t,h}(y_t)$。

条件3的0分和半分含义不同，使用第11节的联合概率。

4.2　保留旧证据，再加入新证据

反馈后信念为

$$\pi_t^+(h) = \frac{\mathbb{I}(h \in \mathcal{A}_t)[\pi_t^-(h)]^{\gamma_s}\ell_t(h)}{\sum_{v\in\mathcal{A}_t}[\pi_t^-(v)]^{\gamma_s}\ell_t(v)}, \qquad 0 \le \gamma_s \le 1. \tag{9}$$

公式包含三个步骤。先将旧信念取 γ_s 次幂，保留或压缩候选之间原有的差异；再乘以反馈似然，使更能解释本题反馈的规则得到更大权重；最后归一化，使活跃集合内的信念总和为1。

例如，两条规则原有信念为0.9和0.1，比例为9比1。$\gamma_s = 0.5$ 时，加入新反馈前的比例变为3比1；本题反馈再根据两条规则的似然改变这一比例。γ_s 越大，旧差异保留得越多；越小，差异压缩得越强。$\gamma_s = 1$ 表示完整保留旧证据的顺序更新；$\gamma_s = 0$ 时，活跃候选按当前反馈重新比较。

规则信念随反馈递推。候选管理负责设置新集合的初始信念，证据记忆模块负责将后续反馈累积到这些信念中。

所有活跃候选都接受同一结果的评价，包括贡献很小的备选，表示“如果按另一条候选判断，能不能解释这个结果”。反馈学习作用于当前活跃集合。

5　假设更新模块（H）：搜索与候选管理

证据记忆模块根据第 t 题反馈更新各条规则的可信程度，得到反馈后信念 π_t^+。假设更新模块在此基础上，结合近期失败经历，调整下一题的候选集合 $\mathcal{A}_{t+1}$，并确定其初始信念 π_{t+1}^-。这一过程决定哪些解释继续被考虑、何时引入新解释，以及新解释从已有知识中获得多少支持。

本节描述从第 t 题走向第 $t+1$ 题的候选更新。它使用已经获得的反馈，准备下一题的候选集合和初始信念。计算顺序是：更新失败状态与搜索控制，处理旧候选退出；发生搜索时，再生成新规则、处理容量并分配信念。第一题按第2节初始化。规则怎样影响作答，见第7节。

5.1 近期失败：保留多少过去的反馈影响

本题失败程度为 $f_t = 1 - r_t$。二值反馈对应0或1；三值反馈对应0、0.5或1。它表示本题目标还有多少未达到。模型用失败状态 F_t 汇总近期经历：

$$F_{t+1} = \delta_s F_t + (1 - \delta_s) f_t, \qquad F_1 = 0, \qquad 0 \le \delta_s < 1. \tag{10}$$

δ_s 是被试层面的失败保持参数，决定旧状态在更新中占多少比例。较小的值使状态更快响应最新反馈；较大的值使单次反馈改变较小、影响持续更久。例如 $\delta_s = 0.6$ 时，从0开始连续两次失败得到0.4、0.64，再成功一次降到0.384。0.6在这里用于演示计算。

失败状态按完整试次顺序递推，跨实验段（session）时延续已有状态。它为搜索提供近期表现的信息；记忆保持参数 γ_s 则控制各规则保留多少旧证据。

5.2 搜索控制：是否搜索，以及采用哪种来源

下一题的搜索概率为

$$e_{t+1} = \mathrm{sigmoid}[\mathrm{logit}(e_{0,s}) + a_{e,s} F_{t+1}], \tag{11}$$

其中 $\mathrm{sigmoid}(v) = 1/(1 + e^{-v})$，$\mathrm{logit}(p) = \log[p/(1-p)]$。基础概率 $e_{0,s} \in (0,1)$ 表示近期没有失败影响时，仍有多大机会搜索；增益 $a_{e,s} \ge 0$ 表示失败使搜索概率上升得多快。连续成功使搜索逐渐回到基础水平，连续失败提高搜索机会。

搜索发生后，以概率 g_{t+1} 使用全局来源，以概率 $1 - g_{t+1}$ 使用局部来源：

$$g_{t+1} = g_{0,s} + (1 - g_{0,s}) a_{g,s} F_{t+1}, \qquad g_{0,s}, a_{g,s} \in [0,1]. \tag{12}$$

$g_{0,s}$ 是基础全局比例，$a_{g,s}$ 控制失败使搜索偏向整个目录的程度。失败状态为0时，全局比例为 $g_{0,s}$；达到1时，为 $g_{0,s} + (1 - g_{0,s}) a_{g,s}$。局部来源利用现有候选，全局来源在可引入的规则中按基础先验搜索。

因此，e_{t+1} 控制搜索是否发生，g_{t+1} 控制发生搜索时采用哪类来源。下一步先确定哪些旧候选保留，再据此生成新规则。

5.3 候选退出：逐渐减少低信念规则

每条旧候选根据反馈后信念，独立产生一次退出提议：

$$P(h\text{提议退出} \mid \mathcal{A}_t, \pi_t^+) = \rho_s [1 - \pi_t^+(h)], \qquad h \in \mathcal{A}_t, \quad \rho_s \in [0,1]. \tag{13}$$

ρ_s 是被试的退出率参数。相对信念越低，候选越容易退出；上一题的主导规则也按同一概率判断。例如，三条候选的信念为0.72、0.18和0.10，$\rho_s = 0.2$ 时，退出提议概率分别为0.056、0.164和0.18。

学习者至少保留一个可用解释。若退出提议使集合为空，或保留规则的信念总和为0，模型恢复一条原本信念最高的规则；最高值并列时等概率选取。用 $\mathcal{D}_t$ 表示处理这一情况后实际退出的规则，保留集合及其信念为

$$\mathcal{A}_t^{\mathrm{ret}} = \mathcal{A}_t \setminus \mathcal{D}_t, \qquad \pi_t^{\mathrm{ret}}(h) = \frac{\pi_t^+(h)}{\sum_{v \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^+(v)}, \quad h \in \mathcal{A}_t^{\mathrm{ret}}. \tag{14}$$

上标 ret 表示退出后保留的阶段。归一化使集合内的信念总和恢复为1，同时保留各规则之间的比例。上例中，若第三条退出，剩下的0.72和0.18就归一化为0.8和0.2。

每次候选更新抽取一次搜索事件：

$$I_{t+1}^{\text{search}} \sim \text{Bernoulli}(e_{t+1}). \tag{15}$$

事件取0时，令 $\mathcal{A}_{t+1} = \mathcal{A}_t^{\text{ret}}$、$\pi_{t+1}^{-} = \pi_t^{\text{ret}}$，空位留待后续搜索。事件取1时，按以下步骤引入一条新规则。只剩一条候选时，其相对信念为1，退出提议概率为0；后续搜索仍可引入其他规则。

退出表示停止主动考虑该规则，其精度记录与反馈学习随之结束。仍在集合中的候选继续积累证据，旧证据由 γ_s 控制保持程度。

5.4 候选生成：怎样选出一条新规则

搜索发生后，模型要为下一题选出一条新规则，记为 $u_\circ$ 可选范围是 $\mathcal{U}_t = \mathcal{H} \setminus \mathcal{A}_t$：从完整规则目录 $\mathcal{H}$ 中，去掉本题已经考虑过的规则 $\mathcal{A}_t$。本题刚刚退出的规则也暂时排除，后续试次才有机会重新进入。

模型首先选择全局搜索或局部搜索。全局搜索直接从 $\mathcal{U}_t$ 中按基础先验抽取一条规则。局部搜索先从保留的旧规则中选一条作为起点，再选择一种方法寻找新规则：对旧规则做一次结构编辑，或寻找与它分类结果相近的规则。选定方法后，按该方法给出的概率抽取一条新规则。

这两种局部方法分别描述规则之间的结构关系和功能关系。结构编辑关注判断步骤怎样改变，例如把“看脖子长短”改成“看尾巴长短”；功能相似性关注两条规则会怎样给刺激分类。一次简单的修改也可能改变许多刺激的类别，因此模型分别计算这两种方法的抽取概率，再将它们结合起来。下面依次说明这两个概率，以及局部、全局搜索如何共同决定最终的抽取概率。

5.4.1 结构编辑：对旧规则做一次修改

结构编辑从旧规则 h 出发，对它做一次规定的修改。每条规则都包含判断特征、比较关系、参照值、分支和类别输出。允许的修改有四种：更换一个特征，更换比较关系及相应的标准参照，修改一个参照值，或改写条件树的一条下级判断。改写下级判断时，其余判断和类别输出布局保持原样。修改后的结果必须是规则目录中的一条完整规则；满足这一条件的修改称为合法编辑。

模型用编辑成本表示这些修改的相对难易。上述四种修改的成本依次为1、1.5、1和2。编辑成本越低，修改后对应的新规则获得的抽取权重越大。等价的判断先整理为统一形式，再计算成本。

用 $\mathcal{E}(h)$ 表示对 h 可以进行的全部合法编辑，op 表示其中一次编辑，$c_{\text{edit}}(\text{op})$ 表示这次编辑的成本。若几种单次编辑都能将 h 改成 u，就取其中最低的成本，记为编辑距离 $d_{\text{edit}}(h, u)$：

$$d_{\text{edit}}(h,u) = \begin{cases} \min_{\text{op}\in\mathcal{E}(h):\,\text{op}(h)=u} c_{\text{edit}}(\text{op}), & \text{有合法编辑,} \\ \infty, & \text{否则.} \end{cases} \tag{16}$$

如果规定的一次编辑无法将 h 改成 u，就将这个距离记为无穷大。因此，距离有限的新规则都能通过一次合法编辑得到。

接着，从这些规则中选出本轮允许引入的规则，组成集合 $\mathcal{N}_t(h) = \{u \in \mathcal{U}_t : d_{\text{edit}}(h,u) < \infty\}$。当这个集合非空时，先把每条规则的编辑距离转为权重 $e^{-d_{\text{edit}}(h,u)}$，再用各自的权重除以全部权重之和。这一步称为归一化，得到的抽取概率加起来等于1：

$$K_{\text{edit},t}(u \mid h) = \frac{\mathbb{I}[u \in \mathcal{N}_t(h)] e^{-d_{\text{edit}}(h,u)}}{\sum_{v \in \mathcal{N}_t(h)} e^{-d_{\text{edit}}(h,v)}}. \tag{17}$$

$K_{\text{edit},t}(u \mid h)$ 表示已经选定旧规则 h 时，通过结构编辑抽中 u 的概率。编辑距离越小，指数权重越大，抽取概率越高。指示函数 $\mathbb{I}[\cdot]$ 在括号内条件成立时取1，否则取0；它使 $\mathcal{N}_t(h)$ 以外的规则概率为0。

5.4.2 功能相似性：寻找分类结果接近的规则

按功能相似性搜索时，模型更容易选中与旧规则 h 分类结果接近的新规则。比较方法是让两条规则给同一批参考刺激分类，再计算分类一致率。例如，100个刺激中有80个被两条规则判为同一类别，一致率就是0.8。

为计算这个比例，用 $c_h(\boldsymbol{x})$ 表示规则 h 给刺激 $\boldsymbol{x}$ 指定的类别，μ_X 表示参考刺激的分布，c, c' 表示类别编号。先统计各类别组合所占的比例：

$$T_{cc'}(h,u) = \Pr_{\boldsymbol{x} \sim \mu_X} [c_h(\boldsymbol{x}) = c,\ c_u(\boldsymbol{x}) = c']. \tag{18}$$

$T_{cc'}(h,u)$ 是参考刺激中同时满足“h 判为 c、u 判为 c'”的比例。这些比例组成一个矩阵，其中对角线上的 T_{cc} 对应两条规则判为同一类别的情况。将对角线各项相加，就得到分类一致率 $S(h,u)$。再用1减去一致率，得到功能距离 $d_{\text{func}}(h,u)$，其中 C 是类别总数：

$$S(h,u) = \sum_{c=1}^{C} T_{cc}(h,u), \qquad d_{\text{func}}(h,u) = 1 - S(h,u). \tag{19}$$

功能距离越小，两条规则的分类结果越一致。上例中，一致率为0.8，功能距离就是0.2。计算始终使用规则原有的类别标签；参考刺激在 $[0,1]^4$ 中均匀抽取，共100,000个，随机种子固定为0。各被试共用这批刺激及由此得到的类别组合比例。

一致率还取决于各类别占参考刺激的比例。例如，两条规则都将20%的刺激判为带内、80%判为带外，即使两条规则的判断相互独立，一致率也有 $0.2^2 + 0.8^2 = 0.68$。其中0.64来自共同判为带外。解释功能距离时，要同时考虑这种类别比例的影响。

有了功能距离，就可以计算每条新规则的抽取概率。对每条 $u \in \mathcal{U}_t$，将基础先验 $p_0(u)$ 乘以距离权重 $e^{-d_{\text{func}}(h,u)/\tau_{\text{prop}}}$，再将所得权重归一化：

$$K_{\text{func},t}(u \mid h) = \frac{\mathbb{I}(u \in \mathcal{U}_t) p_0(u) e^{-d_{\text{func}}(h,u)/\tau_{\text{prop}}}}{\sum_{v \in \mathcal{U}_t} p_0(v) e^{-d_{\text{func}}(h,v)/\tau_{\text{prop}}}}, \qquad \tau_{\text{prop}} = 0.10. \tag{20}$$

$K_{\text{func},t}(u \mid h)$ 表示已经选定 h 时，按功能相似性抽中 u 的概率。当前基础先验 p_0 对目录内各规则赋予相同权重，因此分类一致率较高的规则具有更大的抽取概率。搜索距离尺度 τ_{prop} 固定为0.10，各被试共用。这个尺度越小，抽取概率就越集中于功能距离较小的规则。

5.4.3 结合局部搜索与全局搜索

现在将两种局部方法合在一起。局部搜索先从退出后保留的集合 $\mathcal{A}_t^{\text{ret}}$ 中选择一条旧规则 h，选择概率为它的信念 $\pi_t^{\text{ret}}(h)$。例如，两条旧规则的信念为0.8和0.2，它们被选为起点的概率也分别为0.8和0.2。这样，局部搜索更常从已有支持较多的规则出发。

选定 h 后，用被试参数 ω_s 决定采用哪种局部方法。当 $\mathcal{N}_t(h)$ 非空时，以概率 ω_s 采用结构编辑，以概率 $1-\omega_s$ 按功能相似性搜索。例如，$\omega_s = 0.7$ 表示这两种方法的使用概率分别为70%和30%。由此，以 h 为起点抽中 u 的概率为：

$$K_{\mathrm{loc},t}(u \mid h) = \omega_s K_{\mathrm{edit},t}(u \mid h) + (1-\omega_s) K_{\mathrm{func},t}(u \mid h), \qquad \omega_s \in [0,1]. \tag{21}$$

$K_{\mathrm{loc},t}(u \mid h)$ 是两种方法各自的抽取概率按使用概率加权得到的结果。若 $\mathcal{N}_t(h)$ 为空，从这条旧规则出发，所有允许的一次编辑都无法产生本轮可引入的新规则。这次局部搜索便全部采用功能相似性，即 $K_{\mathrm{loc},t}(u \mid h) = K_{\mathrm{func},t}(u \mid h)$；程序记录这一情况。

局部搜索有多条可能的起点。从某条旧规则出发并抽中 u 的概率，等于“选中这条旧规则的概率”乘以“从它出发抽中 u 的概率”。把所有起点的这部分概率相加，就得到局部搜索的总体抽取概率 $Q_{\mathrm{loc},t}(u)$。全局搜索的概率记为 $Q_{\mathrm{glob},t}(u)$，由 $\mathcal{U}_t$ 内的基础先验归一化得到；当前先验均匀，因此全局搜索中各条可引入规则的抽取概率相同。

最后，前文的搜索控制给出两种搜索的使用概率：全局搜索为 g_{t+1}，局部搜索为 $1-g_{t+1}$。将两种搜索各自的抽取概率按这一比例加权，就得到新规则 u 最终被抽中的概率 $Q_t(u)$：

$$Q_{\mathrm{loc},t}(u) = \sum_{h \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^{\mathrm{ret}}(h) K_{\mathrm{loc},t}(u \mid h), \tag{22}$$

$$Q_{\mathrm{glob},t}(u) = \frac{\mathbb{I}(u \in \mathcal{U}_t) p_0(u)}{\sum_{v \in \mathcal{U}_t} p_0(v)}, \tag{23}$$

$$Q_t(u) = (1-g_{t+1}) Q_{\mathrm{loc},t}(u) + g_{t+1} Q_{\mathrm{glob},t}(u). \tag{24}$$

ω_s 控制局部搜索内部两种方法的比例；g_{t+1} 控制全局与局部搜索的比例，并随近期失败状态变化。上述公式将这些搜索步骤汇总为一个分布 Q_t，模型据此抽取一条新规则 u。

抽取完成后，进入容量管理：检查是否有空位，确定最终保留哪些旧规则，再向新规则分配初始信念。

5.5 容量管理：确定最终保留的旧规则

上一节已经抽出一条新规则 u。接下来，模型检查退出后保留的集合 $\mathcal{A}_t^{\mathrm{ret}}$ 是否还有空位，确保加入 u 后的规则数符合被试的容量上限 $M_s^{\max}$。这个参数规定最多同时考虑多少条规则，实际数量随候选的进入和退出变化。

有空位时，保留全部旧规则，令 $\mathcal{A}_t^{\mathrm{keep}} = \mathcal{A}_t^{\mathrm{ret}}$。容量已满时，删除信念最低的一条旧规则，为 u 腾出位置。记被删除的规则为 h_t^{drop}，保留的旧集合为：

$$h_t^{\mathrm{drop}} \in \arg\min_{h \in \mathcal{A}_t^{\mathrm{ret}}} \pi_t^{\mathrm{ret}}(h), \qquad \mathcal{A}_t^{\mathrm{keep}} = \mathcal{A}_t^{\mathrm{ret}} \setminus \{h_t^{\mathrm{drop}}\}. \tag{25}$$

$\arg\min$ 表示取得最小信念值的规则；多条规则并列最低时，等概率选择其中一条。所有旧规则都按这一标准处理，包括本题作答时的主导规则。上标 keep 表示容量处理后最终保留的旧规则。

确定旧集合后，将其中各规则的信念除以它们的信念总和，得到归一化后的 π_t^{keep}。它表示向新规则分配支持前，保留的旧规则之间的相对信念。随后将 u 加入集合，得到下一题的候选集合 $\mathcal{A}_{t+1}$：

$$\pi_t^{\mathrm{keep}}(h) = \frac{\pi_t^{\mathrm{ret}}(h)}{\sum_{v \in \mathcal{A}_t^{\mathrm{keep}}} \pi_t^{\mathrm{ret}}(v)}, \quad h \in \mathcal{A}_t^{\mathrm{keep}}, \qquad \mathcal{A}_{t+1} = \mathcal{A}_t^{\mathrm{keep}} \cup \{u\}. \tag{26}$$

例如，容量上限为3，退出处理后仍有三条旧规则，信念分别为0.72、0.18和0.10。为了加入新规则，先删除第三条。前两条的信念总和为0.90，归一化后分别为 $0.72/0.90 = 0.8$ 和 $0.18/0.90 = 0.2$。下一节将从这份总和为1的旧规则信念中，计算新规则的初始支持。

容量上限参数的最小允许值为2，因此容量已满时删除一条旧规则后，至少还有一条旧规则参与后续信念分配。

5.6 信念分配：按功能关系形成新规则的初始支持

现在，下一题的候选集合已经确定，还需要为其中的新规则 u 设置初始信念。模型让每条保留的旧规则留下一部分信念，并将另一部分分给 u；新规则把这些分出的部分相加，形成自己的初始支持。这一步表示已有分类知识向新规则的推广。

每条旧规则分出多少支持，取决于它与新规则的功能关系。两条规则对参考刺激的分类越一致，旧规则就向新规则分配越多支持。为计算这个比例，先将前文的功能距离 $d_{\text{func}}(h,u)$ 转为亲和度 $\chi_s(h,u)$：

$$\chi_s(h,u) = e^{-d_{\text{func}}(h,u)/\tau_{\text{tr},s}}, \qquad \tau_{\text{tr},s} > 0. \tag{27}$$

亲和度取值在0到1之间，功能距离越小，亲和度越大；分类结果完全一致时，亲和度为1。被试参数 $\tau_{\text{tr},s}$ 是信念迁移尺度。它较小时，支持主要分给功能距离很小的新规则；它较大时，同样的功能距离对应更高的亲和度，较远的新规则也能获得更多支持。

接着，每条旧规则将自身信念按 $1:\chi_s(h,u)$ 分成两份，分别留给自己和新规则。这两份占旧规则原有信念的比例分别是 $1/[1+\chi_s(h,u)]$ 和 $\chi_s(h,u)/[1+\chi_s(h,u)]$。将这两个比例分别乘以旧规则原有的信念 $\pi_t^{\text{keep}}(h)$，再汇总新规则收到的各份支持，得到下一题作答前的信念：

$$\pi_{t+1}^{-}(h) = \frac{\pi_t^{\text{keep}}(h)}{1+\chi_s(h,u)}, \quad h \in \mathcal{A}_t^{\text{keep}}, \qquad \pi_{t+1}^{-}(u) = \sum_{h \in \mathcal{A}_t^{\text{keep}}} \frac{\pi_t^{\text{keep}}(h)\chi_s(h,u)}{1+\chi_s(h,u)}. \tag{28}$$

$\pi_{t+1}^{-}(h)$ 是分配后旧规则保留的信念，$\pi_{t+1}^{-}(u)$ 是新规则获得的总信念。每条旧规则分出的两份之和等于它原有的信念，因此新集合中的信念总和仍为1。

沿用上一节0.8和0.2的例子，假设两条旧规则与新规则的亲和度分别为0.5和0.1。第一条旧规则按 $1:0.5$ 分配，保留 $0.8/1.5 \approx 0.533$，分给新规则约0.267。第二条按 $1:0.1$ 分配，保留 $0.2/1.1 \approx 0.182$，分给新规则约0.018。新规则将两份相加，得到约 $0.267 + 0.018 = 0.285$ 的初始信念。分配后三条规则的信念约为0.533、0.182和0.285，总和为1。

旧规则原有信念越高、与新规则的亲和度越大，分给新规则的支持就越多。若上例中的两个亲和度都只有0.02，新规则得到的总信念约为0.020。由于亲和度至多为1，每条旧规则最多分出自身信念的一半，新规则的总初始信念也至多为 $1/2$。

候选生成中的搜索距离尺度 τ_{prop} 决定按功能相似性搜索时，各条新规则被抽中的概率；本节的迁移尺度 $\tau_{\text{tr},s}$ 决定已经抽中的新规则获得多少初始信念。完成分配后，新规则从下一题起参与预测，接受实际反馈的评价。反馈可以提高或降低它的信念，随后模型再进行下一轮退出判断。

5.7 状态衔接：保留精度与配对知识

候选集合和规则信念确定后，模型还要准备下一题使用的精度；条件3还需衔接配对知识。这些状态与规则信念一起，决定候选在下一题怎样预测类别和反馈。

精度控制单条规则的类别预测有多明确。最终保留的旧规则，继续使用已经根据本题反馈更新的精度。新规则从被试的初始精度 $\beta_{0,s}$ 开始，在下一题首次参与预测，再根据下一题的实际反馈调整精度。曾经退出的规则重新进入时，也从 $\beta_{0,s}$ 开始。

条件3中的配对知识描述哪两个反应属于同一个科。四个反应有三种可能的配对方案，模型为每种方案保存一个概率。每条旧规则都有自己的条件配对信念，即假定这条分类规则成立时，各种配对方案分别有多大可能。

在候选退出和容量处理之前，模型已经保存了本题反馈更新后的整体配对信念：将全部旧规则各自的条件配对概率，按它们的反馈后规则信念加权相加。这份分布汇总了此前积累的反应关系知识。确定下一题的候选集合后，保留的旧规则沿用各自的条件配对信念，新规则继承这份已保存的整体配对信念。具体公式见第11.4节。

至此，下一题需要的状态全部准备完成：$\mathcal{A}_{t+1}$ 记录正在考虑哪些规则，π^{-}_{t+1} 记录各规则的相对可信程度，精度决定每条规则的类别预测有多明确；条件3的配对信念还记录对反应关系的判断。这些状态共同进入下一题，并在新的选择与反馈之后继续更新。

6 精度更新模块（B）：调整规则预测的明确程度

精度更新模块更新每条规则的 $\beta_t(h)$，从而调整类别预测的明确程度。能较好解释反馈的规则提高精度，受到反驳的规则降低精度；更新后的精度从下一题起使用。

6.1 实际结果是否比机会水平更符合规则

二值反馈任务中的精度更新，比较规则的反馈似然与均匀类别预测的基准。若对 C 个类别都给出 $1/C$ 的概率，正确反馈的概率为 $1/C$，错误反馈的概率为 $1-1/C$。这个基准称为机会概率，根据本题实际反馈取值：

$$\ell_{\text{chance}}(r_t) = \frac{r_t}{C} + (1 - r_t)(1 - 1/C). \tag{29}$$

二分类两种反馈的机会概率均为0.5；四分类正确为0.25、错误为0.75。规则自身的反馈似然 $\ell_t(h)$ 按式(8)计算。将它与机会概率比较，得到支持量：

$$\kappa_t(h) = \begin{cases} \dfrac{\ell_t(h) - \ell_{\text{chance}}}{1 - \ell_{\text{chance}}}, & \ell_t(h) \geq \ell_{\text{chance}}, \\ \dfrac{\ell_t(h) - \ell_{\text{chance}}}{\ell_{\text{chance}}}, & \ell_t(h) < \ell_{\text{chance}}. \end{cases} \tag{30}$$

式中的 ℓ_{chance} 表示本题反馈的机会概率 $\ell_{\text{chance}}(r_t)$。支持量 $\kappa_t(h)$ 取值在 $[-1, 1]$：规则比均匀预测更能解释反馈时为正，两者相同时为0，更难解释时为负。二分类可简化为 $2[\ell_t(h) - 0.5]$。

例如，四分类收到错误反馈时，机会概率为0.75。某规则给这次错误反馈的似然为0.90，支持量为0.60，表示错误反馈支持它原先对其他类别的判断；若似然为0.60，支持量为 -0.20，表示该规则受到反驳。

6.2 支持时增加，反驳时降低

支持量决定精度变化的方向和幅度。所有活跃规则按下式更新：

$$\beta_{t+1}(h)=\begin{cases}\min\{\beta_t(h)+\eta_{+,s}\kappa_t(h)[\beta_{\max}-\beta_t(h)],\beta_{\max}\}, & \kappa_t(h)\geq 0,\\ \max\{\beta_t(h)-\eta_{-,s}\beta_t(h)\min[1,-\kappa_t(h)],\beta_{\min}\}, & \kappa_t(h)<0.\end{cases}\tag{31}$$

共同边界为 $\beta_{\min}=0.1,\beta_{\max}=25$。$\beta_{0,s}$ 是初值，$\eta_{+,s},\eta_{-,s}$ 是增长和下降速率。支持时增长取决于到上限的余量，反驳时按当前值的一定比例下降。

所有活跃候选都更新，包括作答贡献很小的规则。新精度从下一题起影响预测。条件3使用第11.3节的三值支持量进入同一更新结构。

规则信念反映各候选之间的相对可信程度，规则精度控制单条规则的类别预测有多集中。两者根据同一次反馈更新，因此一条规则可以预测很明确，却因判断错误而具有较低信念。

7 选择读出模块（RC）：从规则权重到类别选择

作答前，假设更新模块已经准备好当前候选集合 $\mathcal{A}_t$ 和规则信念 π_t^-。各条规则也已根据本题内部刺激和自身精度，给出类别预测 $p_{t,h}(c)$。选择读出模块将这些信息转为本题的选择概率，并记录主导规则，供下一题计算使用惯性。

这里需要区分两个量：规则信念表示此前证据对一条规则的相对支持；作答权重表示这条规则对本题回答的影响有多大。下面先说明作答权重，再说明怎样汇总为选择概率，最后介绍跨试次的主导规则记录和参与程度指标。本题反馈在作答完成后进入学习。

7.1 作答权重：结合规则信念与使用惯性

模型假设，上一题对回答影响最大的规则，在本题仍有继续被使用的倾向。这种倾向称为使用惯性。计算时，先取各规则的作答前信念作为基础权重，将上一题主导规则的基础权重乘以 e^{λ_s}，再归一化，使所有作答权重之和为1：

$$w_t(h)=\frac{\pi_t^-(h)e^{\lambda_s\mathbb{I}(h=h_{t-1}^\star)}}{\sum_{v\in\mathcal{A}_t}\pi_t^-(v)e^{\lambda_s\mathbb{I}(v=h_{t-1}^\star)}},\qquad h\in\mathcal{A}_t,\quad \lambda_s\geq 0.\tag{32}$$

$w_t(h)$ 是规则 h 的作答权重，λ_s 是被试的使用惯性参数。指示函数 $\mathbb{I}(h=h_{t-1}^\star)$ 在 h 是上一题主导规则时取1，其余情况取0；因此，只有上一题主导规则获得惯性加成。分母将加成后的权重归一化。

$\lambda_s=0$ 时，作答权重等于规则信念；λ_s 越大，上一题主导规则获得的使用优势越大。第一题尚无上一主导规则，或上一主导规则已经退出时，也直接按当前信念计算权重。

下面用两条规则 A、B 串起整个作答过程。假设 A 是上一题的主导规则，当前信念分别为0.4和0.6，且 $\lambda_s=\log 3$，即惯性倍率为3：

处理阶段	规则 A	规则 B
作答前信念	0.4	0.6
加入惯性，尚未归一化	$0.4 \times 3 = 1.2$	0.6
归一化后的作答权重	$2/3$	$1/3$

虽然此前证据给予 B 更高的信念，使用惯性仍使 A 对本题回答产生更大影响。这样，证据支持的变化与作答习惯的变化可以有时间差。

7.2 选择概率：汇总各规则的类别预测

得到作答权重后，模型将每条规则的类别预测乘以它的权重，再按类别相加。规则 h 给类别 c 的预测概率是 $p_{t,h}(c)$，因此本题选择类别 c 的概率为：

$$P(y_t = c \mid z_t) = \sum_{h \in \mathcal{A}_t} w_t(h) p_{t,h}(c). \tag{33}$$

继续上面的例子。假设本题有两个类别，A 较支持类别1，B 较支持类别2：

规则	作答权重	类别1的预测概率	类别2的预测概率
A	$2/3$	0.9	0.1
B	$1/3$	0.2	0.8

选择类别1的概率为 $(2/3) \times 0.9 + (1/3) \times 0.2 = 2/3$，类别2的概率为 $1/3$。A、B 的预测都进入了最终回答，各自的影响大小由作答权重决定。模拟行为时按这个概率分布抽取答案；拟合行为时读取实际选择对应的概率，粒子汇总见第9节。

输出层直接使用上述类别概率生成回答。随机失误（lapse）概率固定为0，作答变异来自知觉、候选状态和各规则的类别概率。

7.3 主导规则：记录作答权重最大的候选

为使使用惯性延续到下一题，模型将本题作答权重最大的规则记录为主导规则 $h_t^\star$。它在作答权重形成后、实际选择之前确定：

$$h_t^\star \in \arg\max_{h \in \mathcal{A}_t} w_t(h). \tag{34}$$

$\arg\max$ 表示取得最大权重的候选。在上面的例子中，A 的权重为 $2/3$，因此记录 A，下一题的惯性加成继续以它为对象。本题选择概率仍按式(33)汇总各候选的预测。

随着反馈积累，其他规则的信念可以增长，并超过原主导规则的惯性优势。例如，惯性倍率仍为3，若 A 的信念降至0.2、B 升至0.8，两者加成后为0.6和0.8，归一化后的权重为 $3/7$ 和 $4/7$。此时 B 成为主导规则，下一题的惯性加成转向 B。

并列最大时优先沿用上一题的主导规则；若它不在并列集合内，则等概率选择。候选退出和容量释放继续以规则信念为依据。收到反馈后，所有活跃候选都更新信念与精度，包括作答权重较小的规则，更新结果从下一题起影响回答。

7.4 有效参与数量：描述作答权重的集中程度

各规则对作答的影响随试次变化。权重分散时，多条规则共同影响回答；权重集中时，一条规则主导回答。为描述这种集中程度，模型计算有效参与数量：

$$N_{\mathrm{eff},t} = \frac{1}{\sum_{h\in\mathcal{A}_t} w_t(h)^2}, \qquad 1 \le N_{\mathrm{eff},t} \le |\mathcal{A}_t|. \tag{35}$$

两条规则的权重均为0.5时，有效参与数量为2；上面例子的权重为 $(2/3, 1/3)$，有效参与数量为1.8；权重为 $(0.98, 0.02)$ 时，它约为1.04。只有一条候选时，它等于1，选择概率也完全由该规则给出。

候选数量描述当前考虑多少条规则，有效参与数量描述这些规则的贡献有多集中。1.8这样的数值是权重分布的描述指标。λ_s 在同一被试内保持稳定，作答权重和有效参与数量随信念、候选集合与上一主导规则逐题变化。

8 单试次顺序：哪些信息何时使用

第一题先按基础先验初始化一条候选及其精度；条件3还初始化配对信念。随后完成知觉、预测与作答，再进行反馈学习。

从第二题起，每题按照以下顺序进行：

1. 读取上一题保存的反馈与状态，递推失败状态 F_t、搜索概率 e_t 和全局比例 g_t。
2. 形成本题内部刺激 $\tilde{\boldsymbol{x}}_t$。假设更新读取此前反馈与候选状态，为本题准备候选集合。
3. 处理旧候选退出，将保留集合内的信念归一化；按 e_t 决定是否搜索新规则。
4. 发生搜索时生成一条新规则；容量已满时删除信念最低的旧规则，再归一化保留的旧信念，并按功能关系分配支持。
5. 保留旧规则的精度，新规则恢复初值；条件3同步设置规则与配对的联合信念。
6. 计算各候选的类别概率。选择读出形成 w_t，确定 $h_t^\star$，汇总选择概率。
7. 生成行为时按选择概率抽取答案；拟合时读取实际选择并更新粒子权重。
8. 收到反馈后计算各活跃规则的反馈似然；条件3计算规则与配对的联合反馈似然。
9. 证据记忆模块累积本题证据；精度更新模块使用更新前的规则预测调整精度。保存反馈，供下一题更新搜索控制。

代码在下一题开始时读取保存的反馈，完成失败状态递推，与式(10)的概念时序一致。本题回答使用本题反馈进入学习前的状态；反馈造成的变化影响下一题。

9 粒子滤波：推断可能的内部路径

9.1 行为预测与路径权重

设粒子数为 N_{PF}，用上标 (n) 标记第 n 条内部路径。其作答前权重为 $W_t^{(n),\mathrm{pre}}$，类别预测为 $p_t^{(n)}(c) = P(y_t = c \mid z_t^{(n)})$：

$$\widehat{P}_t(c) = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} p_t^{(n)}(c). \tag{36}$$

权重满足 $\sum_n W_t^{(n),\mathrm{pre}} = 1$。观察实际选择后，

$$W_t^{(n),\mathrm{choice}} = \frac{W_t^{(n),\mathrm{pre}} p_t^{(n)}(y_t)}{\sum_{n'=1}^{N_{\mathrm{PF}}} W_t^{(n'),\mathrm{pre}} p_t^{(n')}(y_t)}. \tag{37}$$

能解释选择的路径获得高权重；随后各路径按实际选择与反馈学习。路径权重是研究者对路径的判断，路径内规则信念是被试对候选的判断。

例如，两条路径原来各占一半，分别以0.8和0.2预测被试实际选择的答案，总体预测为0.5。观察这个选择后，两条路径的权重变为0.8和0.2。这使第一条内部过程在研究者的推断中获得更高权重；各路径内的规则信念按自身反馈更新。

有效样本量 $\mathrm{ESS}_t = 1/\sum_{n=1}^{N_{\mathrm{PF}}} (W_t^{(n),\mathrm{choice}})^2$ 衡量路径权重有多集中。所有粒子等权时，它等于粒子总数；少数粒子占据大部分权重时，它会下降。低于配置阈值后，按当前权重抽取新的粒子集合，这一操作称为重采样，使计算更多地分配给能解释行为的路径。抽中的粒子继承已有的候选、信念、精度、主导规则、失败与配对状态，并使用独立的后续随机流。

9.2 怎样读懂候选数量与参与程度

某规则出现在候选集合中的概率，可以按路径权重汇总其是否活跃：

$$\widehat{P}_t(h \in \mathcal{A}_t) = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} \mathbb{I}(h \in \mathcal{A}_t^{(n)}), \qquad \overline{N}_t = \sum_{n=1}^{N_{\mathrm{PF}}} W_t^{(n),\mathrm{pre}} |\mathcal{A}_t^{(n)}|. \tag{38}$$

每条路径的候选数量是整数，加权平均可以是2.3，表示研究者对不同可能路径的汇总。有效参与数量先在每条路径内按式(35)计算，再按粒子权重平均。某规则成为主导的概率，则汇总各路径是否由它主导。

这些量分别回答：规则是否已被考虑，得到多少信念，对本题作答有多大贡献，以及是否成为贡献最大的规则。分析时将它们与候选数量、有效参与数量一起报告。

使用选择前权重 $W_t^{(n),\mathrm{pre}}$ 汇总，得到作答前的状态预测；使用 $W_t^{(n),\mathrm{choice}}$ 汇总，则得到结合本题实际选择后的在线推断。分析图应标明采用的权重和汇总时点。

10 个体参数估计：估计什么，怎样评价

10.1 参数清单

搜索控制与候选管理共9项，选择读出中的使用惯性1项，证据记忆1项，精度更新3项：

$$\begin{aligned}\boldsymbol{\theta}_s = (&e_{0,s}, a_{e,s}, \delta_s, g_{0,s}, a_{g,s}, M_s^{\max}, \rho_s, \omega_s, \tau_{\mathrm{tr},s}, \lambda_s,\\ &\gamma_s, \beta_{0,s}, \eta_{+,s}, \eta_{-,s}).\end{aligned} \tag{39}$$

行为模型包含14项被试参数。拟合前规定哪些参数自由估计、哪些固定，以及各项的估计范围。参数恢复使用已知参数生成模拟数据，再重新估计参数，检查这些参数能否被辨认。下表沿用现有三条件配置例值用于说明量级；新机制需同步实现后才能用于拟合，λ_s 按修订后的作答惯性解释。

参数	认知含义	数学范围	例值
$e_{0,s}$	基础搜索概率。	$(0,1)$	0.05
$a_{e,s}$	失败推动搜索的增益。	$[0,\infty)$	1.0
δ_s	失败状态保持。	$[0,1)$	0.6
$g_{0,s}$	基础全局比例。	$[0,1]$	0.2
$a_{g,s}$	失败对范围的增益。	$[0,1]$	0.5
$M_s^{\max}$	候选数量上限。	整数；$2 \le M_s^{\max} < J$	3
ρ_s	候选退出率。	$[0,1]$	0.1
ω_s	局部结构来源倾向。	$[0,1]$	0.5
$\tau_{\mathrm{tr},s}$	功能支持泛化尺度。	$(0,\infty)$	0.1
λ_s	上一主导规则的作答惯性。	$[0,\infty)$	1.0
γ_s	规则及联合配对证据保持。	$[0,1]$	0.8
$\beta_{0,s}$	新规则初始精度。	$[\beta_{\min}, \beta_{\max}]$	5.0
$\eta_{+,s}$	精度增长速率。	$[0,1]$	0.04
$\eta_{-,s}$	精度下降速率。	$[0,1]$	0.15

知觉参数来自独立测量。规则信念、配对信念、失败状态、精度、实际候选数量和主导规则随试次变化。作答权重与有效参与数量由这些状态计算。

10.2 用反馈前选择概率评价参数

行为拟合使用平均选择负对数似然（negative log-likelihood，NLL）：

$$\mathrm{NLL}_{\mathrm{choice}}(\boldsymbol{\theta}_s) = -\frac{1}{T_{\mathrm{score}}} \sum_{t \in \mathcal{T}_{\mathrm{score}}} \log \widehat{P}_t(y_t; \boldsymbol{\theta}_s). \tag{40}$$

$\mathcal{T}_{\mathrm{score}}$ 是计分试次集合，$T_{\mathrm{score}} = |\mathcal{T}_{\mathrm{score}}|$ 是计分试次数。模型给实际选择的概率越低，该题的负对数似然越大；对计分试次取平均后，得到整段行为的拟合分数，分数越小表示预测越好。

计分使用本题反馈进入学习前的选择概率。应保存计分集合、试次顺序、训练／评价边界，以及粒子数、重复次数和种子等计算设置。多次独立运行时，先逐题平均类别概率，再计算 NLL。先平均概率再取对数，与先计算各次 NLL 再平均，得到的分数会不同。

粒子表示可能的隐藏路径，多次独立运行用于检查数值稳定性。参数估计的不确定性还需通过另行规定的统计方法评价。完整行为序列选出的参数在同序列上仍是样本内拟合，即使状态递推没有使用未来反馈。

10.3 参数搜索与可识别性检查

现有工具可以指定待估计的配置字段，并比较不同参数组合。搜索可按证据记忆、搜索控制、候选管理和精度等参数组组织。比较参数组合时，可使用共同随机数，即让不同组合使用相同的随机数序列，减少随机波动对比较的干扰；选出的参数随后用独立种子检查稳定性。正式搜索还需确定参数范围、网格、粒子数、停止条件和断点恢复方式。小规模检查（smoke）配置用于确认流程能够运行。

当失败对搜索的影响很小时，行为数据对失败保持参数 δ_s 的约束较弱；$g_{0,s}$ 接近1时，$a_{g,s}$ 对全局比例的进一步影响也很小。结构编辑与功能相似性给出的抽取概率接近，或结构编辑经常没有可用的新规则时，ω_s 较难估计。候选数量很少达到上限时，容量参数也可能只能确定一个较宽的范围。信念迁移尺度、使用惯性、精度和记忆的作用还可能互相补偿，需要通过参数恢复与针对性模型比较检查。

是否达到与0826相当的效果，需要在可比数据、计分试次和计算预算下，分别比较选择预测与学习过程。各项比较的指标和允许差异在分析前确定。

11 条件3：层级反馈与配对学习

条件3的反馈同时涉及“科”和“种”两个层级。本节补充证据记忆、精度更新和假设更新模块在这种任务中的计算：反馈先更新规则与反应配对的联合信念；候选变化时，已学到的配对关系继续保留。

11.1 知道层级，不知道具体反应配对

被试知道两个科、每科两个种，但不知道哪两个反应同科。三种配对为

$$\mathcal{G}_1 = \{\{1,2\},\{3,4\}\}, \quad \mathcal{G}_2 = \{\{1,3\},\{2,4\}\}, \quad \mathcal{G}_3 = \{\{1,4\},\{2,3\}\}. \tag{41}$$

三种配对的初始概率相同。数据中的 `category` 表示真实类别，`choice` 表示统一反应编号，`presskey` 表示实际按键。转换表统一数据编码，配对知识由反馈学习。

11.2 同次反馈评价规则和配对

每条规则具有条件配对信念 $q_t^-(k \mid h)$，与规则信念相乘得到联合信念：

$$\Pi_t^-(h,k) = \pi_t^-(h) q_t^-(k \mid h), \qquad q_1^-(k \mid h) = 1/3. \tag{42}$$

令 $\mathrm{mate}_k(y)$ 为配对中同组的另一个反应：

$$\ell_t(h,k)=\begin{cases} p_{t,h}(y_t), & r_t=1,\\ p_{t,h}[\mathrm{mate}_k(y_t)], & r_t=0.5,\\ 1-p_{t,h}(y_t)-p_{t,h}[\mathrm{mate}_k(y_t)], & r_t=0. \end{cases} \tag{43}$$

完全正确支持所选反应，半分支持同科另一种，0分支持另科两个反应。三个事件互斥且概率和为1，0分使用另科两个反应的总概率。

联合更新为

$$\Pi_t^{+}(h,k)=\frac{[\Pi_t^{-}(h,k)]^{\gamma_s}\ell_t(h,k)}{\sum_{v\in\mathcal{A}_t}\sum_{k'=1}^{3}[\Pi_t^{-}(v,k')]^{\gamma_s}\ell_t(v,k')}. \tag{44}$$

规则边际为 $\pi_t^{+}(h)=\sum_k\Pi_t^{+}(h,k)$，条件配对为 $q_t^{+}(k\mid h)=\Pi_t^{+}(h,k)/\pi_t^{+}(h)$。规则边际为0时，条件配对约定为均匀分布。$\gamma_s$ 作用于规则与配对的联合信念，规则信念和配对信念都从更新后的联合分布计算。

配对信念均匀时，半分反馈给各规则的证据为 $[1-p_{t,h}(y_t)]/3$，0分反馈给出的证据是该值的两倍。这个倍数对所有规则都相同，因此归一化后，两种反馈对规则之间的相对支持相同。它们对具体配对方案的支持仍可能不同。配对知识积累后，半分和0分可以给分类规则提供更具体的线索。

11.3 三值反馈怎样更新精度

遗忘后、加入本题反馈前的条件配对为

$$\widetilde{q}_t^{-}(k\mid h)=\frac{[\Pi_t^{-}(h,k)]^{\gamma_s}}{\sum_{k'=1}^{3}[\Pi_t^{-}(h,k')]^{\gamma_s}}. \tag{45}$$

当 $\gamma_s=0$ 时，活跃规则与各配对方案的组合按等权处理；某条规则的联合信念总和为0时，其条件配对使用均匀分布。 边际反馈概率 $\ell_t(h)=\sum_k\widetilde{q}_t^{-}(k\mid h)\ell_t(h,k)$。均匀四类下，正确、半分、0分的机会概率为 $1/4,1/4,1/2$，支持量为

$$\kappa_t^{(3)}(h)=\frac{\ell_t(h)-\ell_{\mathrm{chance}}(r_t)}{\ell_t(h)+\ell_{\mathrm{chance}}(r_t)}. \tag{46}$$

将该支持量代入式(31)，更新规则精度。规则对实际反馈给出的概率等于机会水平时，支持量为0，精度保持不变；高于机会水平时提高精度，低于机会水平时降低精度。因此，半分反馈也可以提高或降低精度，取决于该规则原先有多大概率预测到半分。反馈证据由更新前的规则预测与配对信念计算，随后用于本题的精度更新。搜索控制使用 $1-r_t$，表示本题目标未达成的程度。

11.4 候选变化后保留配对知识

迁移前保存整体边际 $\bar{q}_t^{+}(k)=\sum_{h\in\mathcal{A}_t}\Pi_t^{+}(h,k)$。保留旧规则的条件配对，新规则继承 $\bar{q}_t^{+}$：

$$\Pi_{t+1}^{-}(h,k)=\pi_{t+1}^{-}(h)\begin{cases} q_t^{+}(k\mid h), & h\text{为保留的旧规则},\\ \bar{q}_t^{+}(k), & h\text{为新规则}. \end{cases} \tag{47}$$

新规则继承此前积累的反应关系知识，局部与全局来源使用相同的继承规则。规则权重变化后，整体配对边际也可能变化。

配对的集中程度、配对正确性和按刺激分科的能力分别评价，同时报告科、种和平均分表现。

12　从模块状态到认知机理解释

12.1　发现、支持和参与分开看

相近正确率可能来自不同过程：尚未想到有效规则，规则已进入候选集合但信念较低，信念提高后作答惯性仍偏向旧规则，或规则已有较大作答贡献但精度较低。分析时联合查看候选可访问性（规则出现在活跃集合中的概率）、信念、作答权重和精度。进入集合到成为主导规则的时间差反映新规则从被考虑到明显影响回答的过程。

这些轨迹是模型根据选择和历史反馈，对隐藏学习过程作出的推断。候选、信念、作答权重和精度分别表示不同环节，使模型能够提出可检验的解释。现有数据能否分别辨认这些环节，还需通过参数恢复和模型比较检查。

12.2　候选数量变化的含义

连续成功使失败回落、搜索减少，低信念候选仍可退出，集合可能收缩到一条。再次失败可以增加新规则，集合扩张。信念较低且仍在集合内的规则继续参与学习；已退出的规则通过后续搜索重新进入。作答权重集中也可在集合尚有多条时出现。

12.3　结构与功能变化分别量化

只改一个特征就可能改变很多分类；两条分类结果相近的规则，也可能包含很不同的判断步骤。分析编辑类型、功能距离和来源，有助于区分调整思路与想到功能相近的另一解释。共同距离和编辑成本给出可复现的关系定义。

后续机理图可以展示候选何时进入、信念怎样积累、作答权重何时集中、主导规则何时切换，以及精度怎样变化。图中同时呈现不同粒子路径的不确定性。快速学会、逐渐改善和晚期突变是模型需要解释的行为现象；拟合时输入选择及历史反馈，通过上述轨迹检验模型的解释。

A　四分类目录的完整分组

下表按实际家族计数。交叉表示同时使用两个判断，条件分支表示先判断、再在相应分支区分。

代码家族	内容	数量
2d_axis_pair	两个单特征阈值交叉。	6
2d_equality_sum	同一特征对的顺序与和交叉。	6
3d_axis_equality	单特征阈值与另两特征顺序。	12
3d_axis_sum	单特征阈值与另两特征和。	12
3d_axis_triple	三阈值的条件分支。	24
3d_axis_equality_sum	阈值分支下顺序或和。	24
4d_equality_pair	不重叠特征对的顺序交叉。	3
4d_sum_pair	不重叠特征对的和交叉。	3
4d_equality_axis_pair	顺序分支与剩余特征阈值。	12
4d_sum_axis_pair	和分支与剩余特征阈值。	12
dimension_max/min	最大／最小特征分类。	2
axis_pair_overlap	阈值与共享一特征的顺序交叉。	12
shared_pair_comparisons	围绕同一部位做两次比较。	12
similarity_axis_disjoint	两部位是否相近与第三部位长短交叉。	12
合计		152

规则程序用于检查规则表示，并确定一步编辑能够到达哪些规则；类别概率由共享几何计算。程序判断与几何区域的标签对应已核对。

B 辅助符号索引

核心状态见第2.5节；这里按使用位置列出辅助符号。同一规则索引中的 h, u, v 分别用于当前规则、新规则和求和中的其他规则。类别用 c, c' 编号。上下标中的文字标签标明用途。

符号	定义或用途
知觉、预测与反馈	
$\varepsilon_{t,j}$	本题第 j 个特征的知觉误差。
$\mathcal{C}_{h,c}, \boldsymbol{\xi}, d_{t,h,c}$	规则的类别区域、区域中的几何点、内部刺激到该区域的距离。
$c_h(\boldsymbol{x}), p_0(h)$	规则给出的确定类别，以及规则的基础先验。
$\ell_t(h,k), \ell_{\text{chance}}(r_t)$	规则与配对下的反馈似然，以及机会水平的反馈概率。
$\kappa_t^{(3)}(h)$	条件3用于精度更新的反馈支持量。
候选管理与搜索	
$\mathcal{D}_t, \mathcal{A}_t^{\text{ret}}, \mathcal{A}_t^{\text{keep}}$	实际退出集合、退出后集合、容量处理后保留的旧集合。
$\mathcal{U}_t, \mathcal{N}_t(h)$	本轮可引入的规则，以及其中可由 h 一步编辑得到的邻居。
$I_{t+1}^{\text{search}}, h_t^{\text{drop}}$	下一题前是否搜索的二值事件，以及容量满时删除的旧规则。
$\mathcal{E}(h), \text{op}, c_{\text{edit}}(\text{op})$	合法编辑集合、一次编辑及其成本。
$d_{\text{edit}}(h,u), d_{\text{func}}(h,u)$	编辑距离与功能距离。
$\mu_X, T_{cc'}(h,u), S(h,u)$	参考刺激分布、类别对应比例与分类一致率。
$K_{\text{edit},t}, K_{\text{func},t}, K_{\text{loc},t}$	给定旧规则时，按结构编辑、功能相似性或两者结合抽取新规则的概率。
$Q_{\text{loc},t}, Q_{\text{glob},t}, Q_t$	考虑各起点后，局部搜索、全局搜索及两者结合时的新规则抽取概率。
$\tau_{\text{prop}}, \chi_s(h,u)$	功能搜索的共同距离尺度，以及信念分配中的亲和度。
选择读出	
$N_{\text{eff},t}$	由作答权重计算的有效参与数量。
配对学习、粒子推断与计分	
$\mathcal{G}_k, \text{mate}_k(y)$	第 k 种反应配对，以及该配对下与 y 同科的另一个反应。
$\widetilde{q_t^-}(k \mid h)$	旧证据衰减后、本题反馈进入前的条件配对信念。
$z_t^{(n)}, p_t^{(n)}(c)$	第 n 条内部路径的状态与类别预测。
$W_t^{(n),\text{choice}}, \text{ESS}_t$	按实际选择更新的粒子权重，以及粒子有效样本量。
$\widehat{P}_t, \overline{N}_t$	粒子加权预测分布，以及候选数量的粒子加权平均。
$\mathcal{T}_{\text{score}}, T_{\text{score}}$	计分试次集合与其大小。
$\mathbb{I}[\cdot]$	指示函数，条件成立时为1，否则为0。